



FOM Hochschule für Oekonomie & Management

Hochschulzentrum Frankfurt a. M.

Bachelor-Thesis

im Studiengang Wirtschaftsinformatik

zur Erlangung des Grades eines
Bachelor of Science (B.Sc.)

über das Thema

**Wie funktionieren KI-gestützte Monitoring-Systeme als
digitale Informationssysteme und inwiefern ermöglichen
sie datenbasierte Analyse und Beeinflussung von
Verhalten?**

von

Meshan Fernando

Erstgutachter/in

Dr. phil. Patrick Hedfeld

Matrikelnummer

617993

Abgabedatum

25.06.2026

Inhaltsverzeichnis

I.	Abbildungsverzeichnis	IV
II.	Abkürzungsverzeichnis	V
III.	Formelverzeichnis	VI
IV.	Tabellenverzeichnis	VII
1.	Einleitung	1
1.1	Problemstellung	1
1.2	Zielsetzung und Forschungsfrage	2
1.3	Methodisches Vorgehen	3
1.4	Aufbau der Arbeit	4
2.	Theoretische und technologische Grundlagen	5
2.1	Künstliche Intelligenz und Machine Learning	5
2.1.1	Grundbegriffe	5
2.1.2	Überwachungs- und Analyseverfahren	5
2.1.3	Empfehlungssysteme, Predictive Analytics und Verhaltenssteuerung	7
2.2	Digitale Informationssysteme	8
2.2.1	Informationssysteme als soziotechnische Systeme	8
2.2.2	Funktionale Architektur KI-gestützter Monitoring-Systeme	10
2.2.3	Datenflüsse und Entscheidungslogiken	12
2.2.4	Plattformökosysteme	13
2.3	Monitoring- und Bewertungssysteme	15
2.3.1	Begriffliche und soziotechnische Einordnung	15
2.3.2	Datenerfassung	17
2.3.3	Analyse und Modellbildung	18
2.3.4	Algorithmische Bewertung und Klassifikation	19
2.4	Methodisches Vorgehen	20
2.4.1	Forschungsansatz	20
2.4.2	Literaturrecherche	21
2.4.3	Auswahlkriterien der Quellen	21
2.4.4	Methodische Grenzen	21
3.	KI-gestützte Monitoring-Systeme in digitalen Informationsumgebungen	23
3.1	Datenerfassung und digitale Verhaltensanalyse	23
3.1.1	Social-Media-Plattformen	23
3.1.2	Plattformökosysteme	24
3.1.3	Digitale Fußabdrücke und Nutzungsprofile	25
3.2	Algorithmische Steuerungs- und Bewertungsmechanismen	26
3.2.1	Personalisierung	26

III

3.2.2	Ranking-Algorithmen	27
3.2.3	Reputations- und Scoring-Systeme	27
3.2.4	Interaktionsoptimierung und Verhaltensprognosen	28
3.3	Vergleich unterschiedlicher Systemlogiken	30
3.3.1	Plattformzentrierte Systeme westlicher Plattformunternehmen	30
3.3.2	Staatlich integrierte Monitoring-Systeme	31
3.3.3	Vergleich westlicher Plattformlogiken und staatlicher Monitoring-Systeme	31
4.	Sozioökonomische und gesellschaftliche Implikationen	34
4.1	Auswirkungen auf digitale Informationsumgebungen	35
4.2	Verhaltensdynamiken und Personalisierungseffekte	37
4.3	Ökonomische Interessen und Plattformlogiken	40
4.4	Politische und gesellschaftliche Einflussmechanismen	42
4.5	Governance- und Kontrollstrukturen	45
5.	Kritische Betrachtung	49
5.1	Grenzen der technologischen Analyse	49
5.2	Grenzen der Literaturbasis	50
5.3	Aussagekraft und methodische Limitationen	51
5.4	Normative und empirische Perspektiven	52
6.	Fazit und Ausblick	54
	Literaturverzeichnis	56

I Abbildungsverzeichnis

II Abkürzungsverzeichnis

AI	Artificial Intelligence
AIS	Association for Information Systems
DSGVO	Datenschutz-Grundverordnung
DSS	Decision Support System
HMM	Hidden-Markov-Modell
KI	Künstliche Intelligenz
MIS	Management-Informationssystem
ML	Machine Learning
NLP	Natural Language Processing
SCS	Social Credit System

III Formelverzeichnis

IV Tabellenverzeichnis

1 Einleitung

Die fortschreitende Digitalisierung hat in den vergangenen Jahren zur Entstehung komplexer, datengetriebener Plattformökosysteme geführt, die nahezu alle Bereiche des gesellschaftlichen, wirtschaftlichen und politischen Lebens durchdringen. Soziale Netzwerke, Suchmaschinen und digitale Plattformen wie Google, TikTok, Meta oder X setzen zunehmend Künstliche Intelligenz (KI)-gestützte Systeme ein, um Nutzerverhalten zu erfassen, zu analysieren und gezielt zu beeinflussen. Durch algorithmische Steuerungsmechanismen und Interaktionsoptimierung werden Inhalte personalisiert, Aufmerksamkeit kanalisiert und Interaktionsmuster systematisch gelenkt.¹

Moderne KI-gestützte Personalisierungssysteme erzeugen individualisierte Informationsumgebungen, die Wahrnehmung, Meinungsbildung und Entscheidungsprozesse der Nutzer nachhaltig prägen können.² Die daraus resultierende Verhaltensbeeinflussung wirft Fragen hinsichtlich individueller Autonomie, informationeller Selbstbestimmung und demokratischer Willensbildung auf.³

Gleichzeitig zeigen wissenschaftliche Untersuchungen, dass algorithmisch gesteuerte Plattformen zur Verbreitung von Desinformation sowie zur Fragmentierung öffentlicher Diskurse beitragen können. Im Kontext des von Zuboff beschriebenen Überwachungskapitalismus werden diese Mechanismen für ökonomische Verwertungslogiken instrumentalisiert, während staatliche Akteure vergleichbare Technologien zur sozialen Kontrolle und politischen Steuerung einsetzen.⁴

Zudem ist festzustellen, dass viele dieser Systeme bislang nur unzureichend reguliert sind. Trotz weitreichender gesellschaftlicher Auswirkungen operieren algorithmische Monitoring- und Bewertungssysteme häufig in regulatorischen Grauzonen, in denen weder ausreichende Transparenzpflichten noch wirksame Kontrollmechanismen existieren.⁵

Vor diesem Hintergrund untersucht die vorliegende Arbeit, wie KI-gestützte Monitoring-Systeme als digitale Informationssysteme funktionieren und inwiefern sie datenbasierte Analyse und Beeinflussung menschlichen Verhaltens ermöglichen.

1.1 Problemstellung

Die zunehmende Durchdringung digitaler Lebenswelten durch algorithmische Systeme hat dazu geführt, dass Verhaltensbeeinflussung als strukturelles Merkmal moderner Plattformökonomien betrachtet werden kann.⁶ Digitale Informationssysteme und KI-gestützte

¹Vgl. Srnicek(2017), S. 36ff.

²Vgl. Srnicek(2017), S. 9ff.

³Vgl. Zuboff(2019), S. 69.

⁴Vgl. Pasquale(2015), S. 19.

⁵Vgl. Kitchin(2014), S. 722.

⁶Vgl. Zuboff(2019), S. 69.

Plattformen erfassen kontinuierlich nutzerbezogene Daten und setzen diese mittels Machine Learning (ML)-basierter Analyseverfahren ein, um personalisierte Inhalte zu generieren, Nutzerverhalten zu prognostizieren und Interaktionen gezielt zu steuern.⁷

Die dabei eingesetzten Mechanismen der Interaktionsoptimierung zielen primär auf die Maximierung von Verweildauer, Interaktionsraten und datenbasierter Monetarisierung ab. Empfehlungssysteme, Ranking-Algorithmen und personalisierte Werbesysteme bilden die technologische Grundlage einer umfassenden algorithmischen Steuerung, die über neutrale Informationsvermittlung hinausgeht.⁸

Parallel dazu gewinnen staatlich geprägte Überwachungs- und Bewertungssysteme an Bedeutung. Im Kontext des chinesischen Social Credit System (SCS) wird deutlich, wie datenbasierte Monitoring-Infrastrukturen mit Mechanismen sozialer Bewertung und Verhaltensregulierung verknüpft werden können.⁹ Die Konvergenz kommerzieller und staatlicher Überwachungslogiken verdeutlicht die gesellschaftspolitische Tragweite algorithmischer Monitoring-Systeme.¹⁰

Aus wissenschaftlicher Perspektive ergeben sich hieraus mehrere zentrale Problemfelder: Erstens erschwert die Intransparenz proprietärer Algorithmen eine unabhängige Bewertung ihrer Wirkungsmechanismen.¹¹ Zweitens werden Desinformationsdynamiken und soziale Fragmentierung durch algorithmische Verstärkungseffekte begünstigt.¹² Drittens erweisen sich bestehende regulatorische Rahmen als unzureichend, um den Herausforderungen algorithmischer Verhaltensbeeinflussung angemessen zu begegnen.¹³

Die vorliegende Arbeit adressiert diese Problemstellung durch eine systematische Untersuchung der Funktionsweise, Wirkungsmechanismen und gesellschaftlichen Implikationen KI-gestützter Monitoring-Systeme.

1.2 Zielsetzung und Forschungsfrage

Ziel der vorliegenden Arbeit ist die systematische Untersuchung KI-gestützter Monitoring-Systeme als digitale Informationssysteme sowie die Analyse ihrer Möglichkeiten zur datenbasierten Erfassung, Bewertung und Beeinflussung menschlichen Verhaltens.

Im Mittelpunkt stehen dabei folgende Untersuchungsschwerpunkte: die technologischen Grundlagen algorithmischer Steuerung und Interaktionsoptimierung, die Mechanismen der Verhaltensbeeinflussung durch KI-gestützte Personalisierungssysteme, die Rolle von Desinformation und sozialer Fragmentierung im Kontext algorithmischer Plattformlogiken, die ökonomischen Verwertungsstrukturen des Überwachungskapitalismus sowie die

⁷Vgl. K. C. Laudon & J. P. Laudon(2018), S. 418–420, 467, 493–494.

⁸Vgl. K. C. Laudon & J. P. Laudon(2018), S. 419–421, 467.

⁹Vgl. Zuboff(2019), S. 69.

¹⁰Vgl. Woolley & Howard(2017), S. 1.

¹¹Vgl. Srnicek(2017), S. 27.

¹²Vgl. Pasquale(2015), S. 4.

¹³Vgl. O’Neil(2016), S. 145.

Möglichkeiten politischer Einflussnahme durch datenbasierte Monitoring-Systeme.¹⁴

Darüber hinaus werden auf Grundlage der Literaturanalyse Hypothesen zur Wirkungsweise algorithmischer Monitoring-Systeme formuliert, die als Ausgangspunkt für weiterführende empirische Forschung dienen können.

Die zentrale Forschungsfrage der Arbeit lautet:

„Wie funktionieren KI-gestützte Monitoring-Systeme als digitale Informationssysteme und inwiefern ermöglichen sie datenbasierte Analyse und Beeinflussung menschlichen Verhaltens?“

Zur Beantwortung dieser Forschungsfrage wird ein literaturbasierter, konzeptionell-analytischer Forschungsansatz verfolgt. Die Untersuchung stützt sich auf eine systematische Literaturrecherche und theoriegeleitete Analyse wissenschaftlicher Fachliteratur aus den Bereichen KI, digitale Informationssysteme, Plattformökonomie, algorithmische Überwachung sowie Verhaltens- und Kommunikationsforschung.

1.3 Methodisches Vorgehen

Die vorliegende Arbeit folgt einem literaturbasierten, konzeptionell-analytischen Forschungsansatz. Es wird keine empirische Datenerhebung durchgeführt. Stattdessen werden wissenschaftliche Publikationen systematisch ausgewertet, um die Funktionsweise KI-gestützter Monitoring-Systeme sowie deren sozioökonomische Implikationen zu analysieren.

Die Wahl dieses methodischen Vorgehens begründet sich durch den soziotechnischen Charakter des Untersuchungsgegenstandes: KI-gestützte Monitoring-Systeme operieren als proprietäre Systeme, deren interne Algorithmen und Datenstrukturen für externe Forschung nicht unmittelbar zugänglich sind.¹⁵ Eine literaturbasierte Analyse ermöglicht es, bestehende wissenschaftliche Erkenntnisse systematisch zusammenzuführen und in einen kohärenten analytischen Rahmen zu überführen.

Die Literaturrecherche orientiert sich an den Grundsätzen systematischer Literaturanalysen. Zur Identifikation relevanter Quellen werden wissenschaftliche Datenbanken wie Google Scholar, SpringerLink, IEEE Xplore, ACM Digital Library sowie Web of Science herangezogen. Die Auswahl der Literatur erfolgt anhand definierter Kriterien hinsichtlich wissenschaftlicher Qualität, thematischer Relevanz, Aktualität und methodischer Transparenz.

Die Analyse der identifizierten Literatur erfolgt durch thematische Kategorisierung und systematische Synthese. Dabei werden technologische Systemstrukturen, Datenverarbeitungsmechanismen und sozioökonomische Wirkungszusammenhänge herausgearbeitet und in Bezug zur Forschungsfrage gesetzt.

¹⁴Vgl. Bradshaw & Howard(2018), S. 4–5.

¹⁵Vgl. Pasquale(2015), S. 19.

1.4 Aufbau der Arbeit

Die vorliegende Bachelorarbeit gliedert sich in sechs Kapitel, die aufeinander aufbauend die Forschungsfrage systematisch bearbeiten.

Kapitel 2 behandelt die theoretischen und technologischen Grundlagen. Zunächst werden zentrale Begriffe und Konzepte aus den Bereichen KI, ML und digitale Informationssysteme erläutert. Anschließend werden Monitoring- und Bewertungssysteme sowie relevante Verfahren der Datenerfassung, algorithmischen Analyse und Klassifikation dargestellt.

Kapitel 3 untersucht KI-gestützte Monitoring-Systeme in digitalen Informationsumgebungen. Der Schwerpunkt liegt auf der Datenerfassung und digitalen Verhaltensanalyse innerhalb moderner Plattformökosysteme. Zudem werden algorithmische Steuerungs- und Bewertungsmechanismen wie Personalisierung, Ranking-Algorithmen, Reputations- und Scoring-Systeme sowie Interaktionsoptimierung analysiert. Abschließend erfolgt ein Vergleich unterschiedlicher Systemlogiken zwischen plattformzentrierten und staatlich integrierten Monitoring-Systemen.

Kapitel 4 widmet sich den sozioökonomischen und gesellschaftlichen Implikationen algorithmischer Monitoring-Systeme. Dabei werden Auswirkungen auf digitale Informationsumgebungen, Verhaltensdynamiken, ökonomische Plattformlogiken sowie politische und gesellschaftliche Einflussmechanismen betrachtet. Darüber hinaus werden Governance- und Kontrollstrukturen diskutiert.

Kapitel 5 bietet eine kritische Betrachtung der Arbeit, einschließlich der Grenzen der technologischen Analyse, der Literaturbasis sowie methodischer Limitationen.

Kapitel 6 fasst die zentralen Erkenntnisse zusammen, beantwortet die Forschungsfrage und gibt einen Ausblick auf zukünftige Entwicklungen im Bereich KI-gestützter Monitoring-Systeme und digitaler Informationssysteme.

2 Theoretische und technologische Grundlagen

2.1 Künstliche Intelligenz und Machine Learning

2.1.1 Grundbegriffe

Künstliche Intelligenz (KI) befasst sich im Kern mit der Frage, wie Maschinen eine Welt, die weit größer und komplizierter ist als sie selbst, wahrnehmen, verstehen, vorhersagen und manipulieren können.¹⁶ Ein zentrales Konzept ist hierbei der rationale Agent, der seine Umwelt durch Sensoren wahrnimmt und über Aktuatoren darauf einwirkt. Ein solcher Agent gilt als rational, wenn er für jede mögliche Wahrnehmungssequenz eine Aktion wählt, die unter Berücksichtigung seines Wissens das erwartete Leistungsmaß maximiert.¹⁷

Machine Learning (ML) ist ein Teilbereich der KI, der es Systemen ermöglicht, sich an neue Umstände anzupassen sowie Muster in Daten zu erkennen und zu extrapolieren.¹⁸ Die Quellen unterscheiden dabei drei wesentliche Lernparadigmen:

- **Überwachtes Lernen (Supervised Learning):** Das System lernt Funktionen auf Basis von markierten Beispieldaten (Inputs und Zielvorgaben).¹⁹
- **Unüberwachtes Lernen (Unsupervised Learning):** Hierbei werden Kategorien oder Strukturen in Sammlungen nicht etikettierter Daten erkannt, beispielsweise durch Clustering.²⁰
- **Bestärkendes Lernen (Reinforcement Learning):** Ein Agent lernt durch Interaktion mit einer Umgebung, indem er für seine Aktionen Belohnungen oder Bestrafungen erhält, um eine optimale Strategie zu entwickeln.²¹

2.1.2 Überwachungs- und Analyseverfahren

Der funktionale Kern KI-gestützter Monitoring-Systeme liegt in der Fähigkeit, massive Mengen an Rohdaten systematisch in analysierbare Ergebnisse zu transformieren. Als konzeptionelle Synthese dieser Arbeit wird hierfür eine Prozesskette definiert, die von der Erfassung heterogener Datenquellen über die Aufbereitung und Merkmalsextraktion bis hin zur Anwendung mathematischer Modelle reicht. Die daraus resultierenden Analyseergebnisse dienen als notwendige Informationsgrundlage für algorithmische Bewertungen oder automatisierte Entscheidungen, wobei nicht jedes Analyseergebnis zwingend in eine unmittelbare Systemreaktion münden muss.

Monitoring-Systeme verarbeiten hierbei unterschiedliche Datentypen, die eine differenzier-

¹⁶Vgl. Russell & Norvig(2010), S. 2.

¹⁷Vgl. Russell & Norvig(2010), S. 34.

¹⁸Vgl. Goodfellow, Bengio & Courville(2016), S. 2–4.

¹⁹Vgl. Goodfellow, Bengio & Courville(2016), S. 104–105.

²⁰Vgl. Goodfellow, Bengio & Courville(2016), S. 104–105.

²¹Vgl. Sutton & Barto(2018), S. 1 ff..

te Vorbehandlung erfordern. Es wird zwischen strukturierten Transaktions- und Profildaten, unstrukturierten Text-, Bild- und Audiodaten sowie zeitbezogenen Sensor- und Interaktionsdaten unterschieden. Während strukturierte Daten in fest definierten Formaten vorliegen, müssen unstrukturierte Informationen zunächst durch spezialisierte Verfahren erschlossen werden.²² In der Praxis sind diese Daten häufig mit Fehlern behaftet, enthalten Inkonsistenzen oder fehlende Attributwerte, was eine systematische Datenbereinigung und Datenaufbereitung notwendig macht. Ein wesentlicher Bestandteil dieser Vorbereitungsphase ist zudem die Zusammenführung fragmentierter digitaler Fußabdrücke zu umfassenden Nutzungsprofilen, die eine ganzheitliche Analyse ermöglichen.²³

Die Transformation der aufbereiteten Daten in ein für Algorithmen nutzbares Format erfolgt durch das Feature Engineering. Hierbei werden Merkmale ausgewählt, transformiert oder neu konstruiert, die für das jeweilige Analyseverfahren geeignet sind. Moderne Deep-Learning-Verfahren erlauben es dabei zunehmend, relevante Repräsentationen direkt aus den Rohdaten zu erlernen, anstatt diese manuell definieren zu müssen.²⁴ Wissenschaftlich ist zudem präzise zwischen dem Modelltraining und der Anwendung des trainierten Modells zu trennen. In der Trainingsphase lernt das System auf Basis historischer Datenbestände eine mathematische Funktion, welche Eingabewerte auf gewünschte Ausgabewerte abbildet. In der anschließenden Anwendungsphase nutzt das System dieses gespeicherte Wissen, um neue, bisher unbekannte Datenpunkte automatisiert zu bewerten.²⁵

Innerhalb des Monitorings kommen je nach Erkenntnisziel verschiedene analytische Kernverfahren zum Einsatz. Die Klassifikation ordnet Datenpunkte vordefinierten Kategorien zu, beispielsweise zur Identifikation von Betrugsmustern.²⁶ Im Gegensatz dazu schätzen Regression und Wahrscheinlichkeitsprognosen kontinuierliche Werte, um etwa die Klickwahrscheinlichkeit eines Nutzers für einen bestimmten Inhalt zu berechnen.²⁷ Zur Identifikation natürlicher Gruppierungen oder zur Nutzersegmentierung werden Clustering-Verfahren eingesetzt, die Muster in Datenbeständen erkennen, ohne dass vorab definierte Kategorien existieren müssen.²⁸ Ergänzt werden diese Verfahren durch das Natural Language Processing (NLP), das mittels Sentiment Analysis emotionale Zustände oder Einstellungen aus Textdaten statistisch erfassbar macht.²⁹ Für die Analyse von Prozessen, die sich über die Zeit entwickeln, eignen sich zudem zeitbezogene Modelle wie Hidden-Markov-Modells (HMMs).³⁰

Ein zentraler Aspekt der algorithmischen Analyse ist die Erzeugung von Scores, die

²²Vgl. K. C. Laudon & J. P. Laudon(2018), S. 254–255, 259.

²³Vgl. Kitchin(2014), S. 722.

²⁴Vgl. Goodfellow, Bengio & Courville(2016), S. 4–5.

²⁵Vgl. Mitchell(1997), S. 9, 11–12.

²⁶Vgl. Jordan & Mitchell(2015), S. 255.

²⁷Vgl. Russell & Norvig(2010), S. 698.

²⁸Vgl. Goodfellow, Bengio & Courville(2016), S. 146–147.

²⁹Vgl. Russell & Norvig(2010), S. 860ff.

³⁰Vgl. Russell & Norvig(2010), S. 556.

zunächst als numerische Werte oder Wahrscheinlichkeiten vorliegen. Eine endgültige Klassifikation oder die Ableitung einer Intervention erfolgt erst durch die Anwendung spezifischer Schwellenwerte oder Entscheidungsregeln auf diese Scores.³¹ Die Zuverlässigkeit dieser Ergebnisse wird durch Metriken der Modellqualität gemessen, wobei insbesondere das Verhältnis von Fehlklassifikationen, wie False Positives und False Negatives, eine entscheidende Rolle für die Genauigkeit des Systems spielt.³²

Aus technischer Perspektive stellt die Datenqualität eine dauerhafte Herausforderung dar. Wenn die zugrunde liegenden Trainingsdaten nicht repräsentativ sind oder systematische Verzerrungen enthalten, werden diese durch den algorithmischen Prozess verstärkt und führen zu fehlerhaften Modellen.³³ Ein unzureichendes Monitoring der Modellleistung kann zudem dazu führen, dass die Übertragbarkeit des Modells auf neue Kontexte abnimmt.³⁴ Zusammenfassend folgt die Analyse der Logik: Rohdaten → Aufbereitung → Merkmale → Modell → Klassifikation, Prognose oder Score. Diese Ergebnisse bilden die Grundlage für Empfehlungssysteme, Rankings und automatisierte Entscheidungen.

2.1.3 Empfehlungssysteme, Predictive Analytics und Verhaltenssteuerung

Predictive Analytics nutzt maschinelle Intelligenz, um Vorhersagen über menschliches Verhalten zu erstellen, wobei diese Vorhersagen umso wertvoller werden, je näher sie der Gewissheit kommen.³⁵ Diese Systeme basieren oft auf Wahrscheinlichkeitsmodellen wie Bayesschen Netzen, die Abhängigkeiten zwischen Variablen darstellen, um auch unter Unsicherheit fundierte Schlüsse ziehen zu können.³⁶

Die Grundlage moderner Predictive-Analytics-Systeme besteht häufig in der kontinuierlichen Auswertung großer Mengen historischer und aktueller Verhaltensdaten. Ziel ist die Identifikation von Mustern, Zusammenhängen und Wahrscheinlichkeiten zukünftiger Handlungen. Die Qualität solcher Vorhersagen steigt dabei in der Regel mit der Menge und Aktualität der verfügbaren Daten.

Empfehlungssysteme sind eine spezifische Anwendung, bei der Algorithmen die Präferenzen eines Nutzers mit denen anderer abgleichen, um relevante Informationen oder kulturelle Inhalte vorzuschlagen.³⁷

Empfehlungssysteme basieren häufig auf Verfahren des kollaborativen Filterns, der Inhaltsanalyse oder hybriden Ansätzen. Dabei werden Nutzerpräferenzen analysiert, um relevante Inhalte, Produkte oder Informationen vorzuschlagen. Solche Systeme finden Anwendung in sozialen Netzwerken, Streaming-Plattformen, Suchmaschinen und E-Commerce-

³¹Vgl. Pasquale(2015), S. 19.

³²Vgl. Goodfellow, Bengio & Courville(2016), S. 422–424.

³³Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 36.

³⁴Vgl. National Institute of Standards and Technology(2023), S. 14.

³⁵Vgl. Zuboff(2019), S. 69.

³⁶Vgl. Russell & Norvig(2010), S. 510.

³⁷Vgl. Adomavicius & Tuzhilin(2005), S. 734.

Systemen.³⁸

Zwischen Nutzer und Plattform entstehen dabei kontinuierliche Rückkopplungsschleifen. Jede Interaktion eines Nutzers erzeugt neue Daten, welche zur Verbesserung zukünftiger Vorhersagen und Empfehlungen genutzt werden. Dieser Prozess ermöglicht eine fortlaufende Optimierung algorithmischer Modelle und eine zunehmend präzisere Analyse individuellen Verhaltens.³⁹

In der Logik des sogenannten Überwachungskapitalismus werden solche Systeme genutzt, um aus „Verhaltensüberschüssen“ Vorhersageprodukte zu fertigen, die in speziellen Märkten für zukünftiges Verhalten gehandelt werden.⁴⁰ Das Ziel ist hierbei oft nicht nur die Vorhersage, sondern die Verhaltensmodifikation, um garantierte kommerzielle Ergebnisse zu erzielen.

Aus Sicht digitaler Plattformen beschränkt sich die Nutzung solcher Systeme nicht ausschließlich auf die Vorhersage zukünftigen Verhaltens. Vielmehr können algorithmische Empfehlungen, Rankings und Personalisierungsmechanismen genutzt werden, um Aufmerksamkeit zu lenken, Interaktionen zu fördern und bestimmte Verhaltensweisen wahrscheinlicher zu machen. Die Übergänge zwischen Verhaltensprognose und Verhaltensbeeinflussung bilden dabei einen zentralen Untersuchungsgegenstand dieser Arbeit.⁴¹

2.2 Digitale Informationssysteme

Das Verständnis KI-gestützter Monitoring-Systeme setzt eine fundierte Auseinandersetzung mit der theoretischen Basis digitaler Informationssysteme voraus. In der Wirtschaftsinformatik werden diese Systeme nicht als rein technologische Artefakte begriffen, sondern als soziotechnische Gefüge, in denen technologische und organisatorische Komponenten zur Erreichung spezifischer Ziele zusammenwirken.⁴²

Im Zentrum steht das funktionale Zusammenspiel von Datenerfassung, Verarbeitung, Analyse und Entscheidungslogik. Dabei ist weniger die konkrete technische Implementierung entscheidend als die Frage, wie Daten, Infrastrukturen, organisatorische Ziele und menschliche Akteure miteinander verknüpft sind.⁴³ Plattformökosysteme bilden dabei einen organisatorischen und technologischen Rahmen, in dem Datenerfassung, Analyse und algorithmische Entscheidungen zusammengeführt werden.

2.2.1 Informationssysteme als soziotechnische Systeme

Ein Informationssystem (IS) lässt sich grundlegend als eine Menge miteinander verknüpfter Komponenten definieren, die Daten erfassen, verarbeiten, speichern und verteilen, um

³⁸Vgl. Adomavicius & Tuzhilin(2005), S. 734–735.

³⁹Vgl. K. C. Laudon & J. P. Laudon(2018), S. 493–494.

⁴⁰Vgl. Zuboff(2019), S. 69.

⁴¹Vgl. Adomavicius & Tuzhilin(2005), S. 734.

⁴²Vgl. K. C. Laudon & J. P. Laudon(2018), S. 56–58.

⁴³Vgl. K. C. Laudon & J. P. Laudon(2018), S. 491–492.

spezifische Ziele innerhalb einer Organisation zu erreichen.⁴⁴ In der Wirtschaftsinformatik werden diese Systeme nicht als rein technologische Artefakte begriffen, sondern als soziotechnische Systeme.⁴⁵ Diese Perspektive betont, dass ein Informationssystem ein komplexes Gefüge aus Hardware, Software, Daten, Prozessen und Menschen darstellt, die innerhalb einer organisationalen Struktur interagieren.⁴⁶ Die Leistungsfähigkeit resultiert dabei aus der wechselseitigen Abstimmung zwischen der technologischen Komponente und der sozialen Struktur der Organisation.⁴⁷ Ein umfassendes Verständnis von Informationssystemen setzt daher voraus, nicht nur die Computertechnik zu betrachten, sondern auch die Art und Weise, wie Individuen und Organisationen diese einsetzen, um betriebliche Probleme zu lösen.⁴⁸

Der funktionale Kern eines Informationssystems liegt in der Transformation von Daten zu Informationen. Während Daten als rohe Fakten gelten, die für sich genommen nur einen geringen Wert besitzen, stellen Informationen eine Sammlung von Tatsachen dar, die so organisiert und strukturiert wurden, dass sie für den Menschen einen über die Einzeldaten hinausgehenden Mehrwert sowie eine Bedeutung für Entscheidungsprozesse besitzen.⁴⁹⁵⁰ Dieser Prozess der Datenverarbeitung ist untrennbar mit der Organisation verbunden: Informationssysteme unterstützen betriebliche Abläufe, sind in organisatorische Kulturen eingebettet und dienen dazu, strategische Ziele zu erreichen.⁵¹ Ein wesentlicher Zweck ist hierbei die Entscheidungsunterstützung. Während klassische Management-Informationssysteme (Management-Informationssystem (MIS)) primär auf die operative Effizienz abzielen und Routineberichte über den Zustand der Organisation liefern, unterstützen fortgeschrittene Decision Support Systeme (Decision Support System (DSS)) die Lösung komplexer, unstrukturierter oder semistrukturierter Probleme, für die keine vordefinierten Standardlösungen existieren.⁵²⁵³ Solche Systeme fungieren als Hilfsmittel, um die Fähigkeiten menschlicher Entscheider durch quantitative Analysen zu erweitern.⁵⁴

Der Übergang von klassischen zu modernen digitalen Informationssystemen wird durch eine kontinuierliche Flut von IT-Innovationen wie Cloud Computing, mobile digitale Plattformen und die allgegenwärtige Vernetzung vorangetrieben.⁵⁵ Diese digitalen Informationssysteme zeichnen sich durch eine kontinuierliche Datenerfassung, Echtzeitverarbeitung und die Integration von Analytics aus, wodurch Manager nahezu sofortigen

⁴⁴Vgl. Stair & Reynolds(2010), S. 10.

⁴⁵Vgl. K. C. Laudon & J. P. Laudon(2018), S. 56–58.

⁴⁶Vgl. Shipsey(2010), S. 6.

⁴⁷Vgl. Shipsey(2010), S. 13.

⁴⁸Vgl. Stair & Reynolds(2010), S. 30–31.

⁴⁹Vgl. Stair & Reynolds(2010), S. 5.

⁵⁰Vgl. Shipsey(2010), S. 6.

⁵¹Vgl. Shipsey(2010), S. 9, 11.

⁵²Vgl. Rashidi, Ghodrat, Samali & Mohammadi(2018), S. 20.

⁵³Vgl. Stair & Reynolds(2010), S. 20.

⁵⁴Vgl. Rashidi, Ghodrat, Samali & Mohammadi(2018), S. 19, 22.

⁵⁵Vgl. K. C. Laudon & J. P. Laudon(2018), S. 35–36.

Zugriff auf präzise Informationen für datengetriebene Entscheidungsprozesse erhalten.⁵⁶ Dieser Wandel wird durch Treiber wie die „Packetisierung“ von Prozessen und die Einbettung von Software in Alltagsgegenstände (Internet of Things) beschleunigt, welche Informationssysteme zu den de facto Motoren neuer wirtschaftlicher Aktivitäten machen.⁵⁷ Unternehmen entwickeln sich dadurch zu digitalen Firmen, in denen Kernprozesse und Geschäftsbeziehungen primär digital abgewickelt werden.⁵⁸

In diesem Kontext haben sich digitale Plattformen als moderne Form des Informationssystems etabliert. Sie bilden modulare und erweiterbare Infrastrukturen, die Interaktionen zwischen verschiedenen Gruppen – wie Anbietern und Nutzern – koordinieren.⁵⁹ Im Gegensatz zu traditionellen „Pipeline“-Modellen, die Werte linear erzeugen, ermöglichen Plattformen komplexe, vernetzte Interaktionen innerhalb eines Ökosystems.⁶⁰ Diese Ökosysteme nutzen digitale Technologien und Daten-Feedbackschleifen, um Werte nicht mehr nur intern, sondern durch externe Beiträge und die Analyse massiver Nutzerdatenströme zu schaffen.^{61 62}

KI-gestützte Monitoring-Systeme lassen sich vor diesem Hintergrund unmittelbar als spezifische Ausprägung digitaler Informationssysteme herleiten. Ihr funktionaler Schwerpunkt liegt auf der kontinuierlichen Beobachtung und systematischen Auswertung von Datenströmen mittels Machine Learning, um Muster im Verhalten zu erkennen und Prognosen zu erstellen.⁶³ Als soziotechnische Systeme sind sie tief in die ökonomischen Zielsetzungen moderner Plattformen integriert: Sie dienen nicht nur der Analyse, sondern ermöglichen durch algorithmische Optimierung – etwa beim Behavioural Targeting – eine gezielte Beeinflussung menschlicher Interaktionsmuster.⁶⁴

2.2.2 Funktionale Architektur KI-gestützter Monitoring-Systeme

Die funktionale Architektur KI-gestützter Monitoring-Systeme kann als eine idealtypische Struktur miteinander verknüpfter Komponenten verstanden werden, die innerhalb eines soziotechnischen Rahmens operieren. In der Wirtschaftsinformatik wird ein Informationssystem nicht allein als technisches Artefakt betrachtet, sondern als ein Gefüge aus Technologie, organisatorischen Strukturen und menschlichen Akteuren, die zur Erreichung spezifischer Ziele zusammenwirken.⁶⁵ Die funktionale Organisation beschreibt dabei, wie Daten erfasst, bereitgestellt, analysiert und gegebenenfalls für Bewertungen oder Entscheidungen genutzt werden.

⁵⁶Vgl. K. C. Laudon & J. P. Laudon(2018), S. 36, 493.

⁵⁷Vgl. Tiwana(2014), S. 3–4, 10–11.

⁵⁸Vgl. K. C. Laudon & J. P. Laudon(2018), S. 40.

⁵⁹Vgl. Tiwana(2014), S. 5.

⁶⁰Vgl. Parker, Van Alstyne & Choudary(2016), S. 19.

⁶¹Vgl. Parker, Van Alstyne & Choudary(2016), S. 21.

⁶²Vgl. M. A. Evans, Gawer & Yoffie(2019), S. 16–17, 41.

⁶³Vgl. K. C. Laudon & J. P. Laudon(2018), S. 467–468, 493.

⁶⁴Vgl. K. C. Laudon & J. P. Laudon(2018), S. 56–58, 418–421.

⁶⁵Vgl. K. C. Laudon & J. P. Laudon(2018), S. 46–50, 56–58.

Den Ausgangspunkt bildet die Datenerfassung als Schnittstelle zur überwachten Umwelt. Dabei können strukturierte Transaktions- und Profildaten, unstrukturierte Text- und Bilddaten sowie zeitbezogene Interaktions- oder Sensordaten aufgenommen werden.⁶⁶ Die Daten können beispielsweise aus Nutzerinteraktionen, digitalen Plattformen, mobilen Endgeräten, Transaktionen oder technischen Sensoren stammen. Innerhalb des funktionalen Modells bilden diese Beobachtungen die Eingabebasis für die nachfolgenden Verarbeitungsschritte.⁶⁷

An die Erfassung schließt sich die Datenintegration und Bereitstellung an. Da Monitoring-Daten häufig aus unterschiedlichen Quellen und in verschiedenen Formaten vorliegen, müssen sie zusammengeführt, bereinigt und für die weitere Verarbeitung verfügbar gemacht werden. Ziel ist die Schaffung einer konsistenten Datenbasis, auf die Analyseverfahren und Modelle zugreifen können. Die konkrete technische Umsetzung kann dabei zentral, verteilt oder cloudbasiert erfolgen. Für die funktionale Betrachtung ist jedoch nicht die verwendete Speichertechnologie entscheidend, sondern die zuverlässige Bereitstellung der benötigten Daten.⁶⁸

Den analytischen Kern der Architektur bildet die Analyse- und Modellkomponente. Verfahren des maschinellen Lernens und der statistischen Analyse werden eingesetzt, um Merkmale, Regelmäßigkeiten und Zusammenhänge in den bereitgestellten Daten zu identifizieren.⁶⁹ Die daraus erzeugten Modelle stellen ausgewählte Aspekte der überwachten Umwelt, von Prozessen oder des Nutzerverhaltens in einer maschinenlesbaren Form dar. Sie können als Grundlage für Prognosen, Zustandsbewertungen oder die Erkennung auffälliger Muster dienen.

Auf Grundlage dieser Analyseergebnisse kann eine Bewertungs- oder Entscheidungskomponente eingesetzt werden. Dabei werden Ergebnisse beispielsweise anhand festgelegter Regeln, Kategorien oder Schwellenwerte weiterverarbeitet. Mögliche Ausgaben sind Wahrscheinlichkeiten, Scores, Klassifikationen, Rankings oder Entscheidungsvorschläge. Diese können sich auf Personen, Inhalte, Transaktionen, Ereignisse oder technische Systemzustände beziehen.⁷⁰ Nicht jedes Analyseergebnis führt jedoch automatisch zu einer Entscheidung oder einer unmittelbaren Systemreaktion.

Eine mögliche Interventions- oder Ausgabekomponente überführt ausgewählte Ergebnisse in eine sichtbare Handlung des Systems. Dazu können Warnmeldungen, Berichte, Empfehlungen, personalisierte Inhalte, Rankings oder automatisierte Reaktionen gehören. Ob eine solche Intervention erfolgt, hängt von der konkreten Ausgestaltung und Zielsetzung des Systems ab. Rein deskriptive Monitoring-Systeme können Ergebnisse lediglich darstellen, während adaptive Systeme aktiv auf die überwachte Umgebung einwirken.

⁶⁶Vgl. K. C. Laudon & J. P. Laudon(2018), S. 254–255, 259.

⁶⁷Vgl. Russell & Norvig(2010), S. 34.

⁶⁸Vgl. K. C. Laudon & J. P. Laudon(2018), S. 47–50, 492.

⁶⁹Vgl. Goodfellow, Bengio & Courville(2016), S. 99, 102–105.

⁷⁰Vgl. Pasquale(2015), S. 19.

Reaktionen von Nutzern oder Veränderungen innerhalb der überwachten Umgebung können wiederum neue Daten erzeugen. Dadurch entsteht eine mögliche Rückkopplung, durch die Profile, Zustände oder Bewertungen aktualisiert werden. Diese Aktualisierung ist jedoch vom erneuten Training eines Modells zu unterscheiden. Neue Beobachtungen führen nicht zwangsläufig zu einer Veränderung der zugrunde liegenden Modellparameter oder zu einem kontinuierlich selbstständig lernenden System. Die Modellleistung und ihre Übertragbarkeit auf neue Daten müssen vielmehr regelmäßig überprüft werden.⁷¹

Die funktionalen Komponenten sind in organisatorische Zielsetzungen, Regeln und Verantwortlichkeiten eingebettet, die von menschlichen Akteuren gestaltet und kontrolliert werden.⁷² Welche Daten erhoben, welche Modelle eingesetzt und welche Systemreaktionen zugelassen werden, ist daher nicht allein eine technische Entscheidung. Entscheidend für das Zusammenwirken der Komponenten ist, wie Daten zwischen ihnen übertragen und nach welchen Regeln Analyseergebnisse in Bewertungen, Entscheidungen oder mögliche Handlungen überführt werden.

2.2.3 Datenflüsse und Entscheidungslogiken

Die Funktionsweise KI-gestützter Monitoring-Systeme beruht auf der Steuerung von Datenflüssen und deren Überführung in spezifische Entscheidungslogiken. Innerhalb dieser Informationssysteme durchlaufen Daten eine Transformationskette, die über die bloße Weiterleitung von Signalen hinausgeht. Der Prozess beginnt mit der Bereitstellung von Rohdaten, die entweder strukturiert, etwa als Transaktionsprotokolle, oder unstrukturiert, beispielsweise als Text- oder Bilddaten, vorliegen können.⁷³ Durch die anschließende Modellanwendung entstehen Analyseergebnisse, die beispielsweise als Wahrscheinlichkeiten, Prognosen oder Scores ausgegeben werden können. Zwischen diesem technischen Output und seiner anschließenden Bewertung ist begrifflich zu unterscheiden.

Eine Bewertung entsteht erst, wenn der Modelloutput durch spezifische Regeln, Schwellenwerte oder Kategorisierungen interpretiert wird. Hierbei wird den identifizierten Mustern eine Bedeutung im Kontext der organisatorischen Ziele zugeordnet.⁷⁴ So stellt beispielsweise ein berechneter Score zunächst nur einen numerischen Wert dar. Erst durch den Vergleich mit einem festgelegten Schwellenwert kann daraus etwa die Einstufung einer Transaktion als risikoreich oder eines Inhalts als relevant entstehen. Die auf diese Weise bewerteten Informationen können anschließend als Grundlage für Entscheidungen dienen.

Die Entscheidungslogik kann unterschiedliche Automatisierungsgrade aufweisen. Standardisierte und zeitkritische Entscheidungen können automatisiert erfolgen, während komplexe oder folgenreiche Entscheidungen eine menschliche Prüfung oder Freigabe

⁷¹Vgl. National Institute of Standards and Technology(2023), S. 14, 29.

⁷²Vgl. K. C. Laudon & J. P. Laudon(2018), S. 44–45, 254–260.

⁷³Vgl. K. C. Laudon & J. P. Laudon(2018), S. 484–485, 490.

⁷⁴Vgl. Pasquale(2015), S. 19.

erfordern können.⁷⁵ Dabei sind Kontrollinstanzen erforderlich, um die Grenzen algorithmischer Ergebnisse zu berücksichtigen und sicherzustellen, dass automatisierte Bewertungen die menschliche Autonomie nicht unangemessen einschränken.⁷⁶ Eine Entscheidung kann schließlich in eine Intervention münden, die als sichtbare Handlung des Systems in die Informationsumgebung eingreift. Beispiele hierfür sind die Bereitstellung personalisierter Empfehlungen, die Ausgabe einer Warnmeldung oder die Sperrung einer als risikoreich bewerteten Transaktion.

Die Ausgestaltung dieser Logiken wird maßgeblich durch organisatorische Ziele, Verantwortlichkeiten und Governance-Strukturen geprägt. Das soziotechnische Design bestimmt, welche Daten als relevant gelten, welche Kriterien bei ihrer Bewertung angewendet werden und welche Optimierungsziele die Systemlogik verfolgt.⁷⁷ Entscheidungen entstehen somit nicht allein aus technischen Modellen, sondern aus der Verknüpfung von Analyseergebnissen mit organisatorisch festgelegten Regeln und Zielsetzungen.

Ein weiteres mögliches Element ist die Rückkopplung durch neue Daten. Nutzerreaktionen oder Veränderungen innerhalb der überwachten Umgebung können zusätzliche Beobachtungen erzeugen, die jedoch nicht in jedem Fall unmittelbar verarbeitet werden. Neue Informationen können zur Aktualisierung eines Profils oder eines internen Systemzustands genutzt werden.⁷⁸ Diese Aktualisierung ist von einem erneuten Training des Modells abzugrenzen. Beim erneuten Training werden die Modellparameter anhand neuer Daten angepasst. Eine Überwachung der Modellleistung kann Hinweise darauf liefern, ob eine solche Anpassung erforderlich ist.⁷⁹

In der Praxis sind Datenflüsse und Entscheidungslogiken selten auf eine einzelne geschlossene Anwendung beschränkt. Vielmehr verteilen sie sich häufig über komplexe Infrastrukturen, in denen unterschiedliche Dienste, technische Komponenten, Organisationen und Akteure zusammenwirken. Diese vernetzte Struktur der Datenverarbeitung bildet einen wesentlichen Bestandteil moderner Plattformökosysteme.

2.2.4 Plattformökosysteme

Die moderne Informationsökonomie wird maßgeblich durch digitale Plattformen geprägt, die in der Wirtschaftsinformatik als spezifische Geschäftsmodelle und technologische Architekturen begriffen werden. Eine digitale Plattform stellt eine erweiterbare Codebasis bereit, welche die Kernfunktionalität eines Systems definiert und über Schnittstellen mit ergänzenden Software-Subsystemen interagiert.⁸⁰ Das daraus resultierende Plattformökosystem umfasst die Gesamtheit der Akteure – den Plattformbetreiber, die Komplementoren

⁷⁵Vgl. K. C. Laudon & J. P. Laudon(2018), S. 484–485, 490.

⁷⁶Vgl. National Institute of Standards and Technology(2023), S. 26, 40.

⁷⁷Vgl. K. C. Laudon & J. P. Laudon(2018), S. 46–50, 492.

⁷⁸Vgl. Russell & Norvig(2010), S. 117.

⁷⁹Vgl. National Institute of Standards and Technology(2023), S. 35–36, 38.

⁸⁰Vgl. Tiwana(2014), S. 10.

sowie die Nutzer –, die auf Basis dieser technologischen Infrastruktur miteinander interagieren.⁸¹ Im Gegensatz zu traditionellen Pipeline-Geschäftsmodellen, die Werte linear entlang einer Kette vom Hersteller zum Kunden schaffen, fungiert eine Plattform als modularer Rahmen, der wertschöpfende Interaktionen zwischen verschiedenen externen Gruppen ermöglicht.⁸²

Zentral für die Funktionsweise eines Plattformökosystems ist die Koordination von Interaktionen in mehrseitigen Märkten. Plattformen bringen dabei unterschiedliche Gruppen zusammen, die über die bereitgestellte Infrastruktur Transaktionen durchführen oder Informationen austauschen.⁸³ In der Literatur wird häufig zwischen Transaktionsplattformen, die als Vermittler auf Marktplätzen agieren, und Innovationsplattformen differenziert, die technologische Bausteine für die Entwicklung komplementärer Produkte und Dienste bereitstellen.⁸⁴ Die Rolle des Plattformbetreibers besteht darin, den technologischen und organisatorischen Rahmen zu schaffen, während Komplementoren die Funktionalität und den Nutzwert des Gesamtsystems durch spezialisierte Beiträge erweitern können.⁸⁵

Ein wesentlicher ökonomischer Treiber dieser Ökosysteme sind Netzwerkeffekte. Diese treten auf, wenn der Nutzen eines Systems für einen Teilnehmer von der Anzahl oder Aktivität anderer Nutzer abhängt.⁸⁶ Dabei wird zwischen direkten Netzwerkeffekten innerhalb einer Gruppe und indirekten beziehungsweise kreuzseitigen Effekten unterschieden, bei denen die Zunahme einer Gruppe die Attraktivität der Plattform für eine andere Marktseite erhöht.⁸⁷ Solche positiven Rückkopplungen können zu einer Konzentration von Marktmacht beitragen. Eine Monopolisierung ist jedoch nicht zwingend, da differenzierte Wettbewerber oder spezialisierte Nischenanbieter die Dominanz etablierter Plattformen begrenzen können.⁸⁸

Die Steuerung dieser komplexen Gefüge erfolgt über die Plattform-Governance. Diese legt Regeln, Zugänge und Verantwortlichkeiten innerhalb des Ökosystems fest. Der Plattformbetreiber definiert dabei nicht nur die technischen Schnittstellen, sondern regelt auch, welche Akteure teilnehmen dürfen und nach welchen Kriterien Interaktionen oder ergänzende Angebote zugelassen werden.⁸⁹ Eine effektive Governance muss das Spannungsfeld zwischen technologischer Offenheit zur Förderung von Innovationen und der notwendigen Kontrolle zur Sicherstellung von Qualität und Vertrauen ausbalancieren.⁹⁰ Plattformen sind daher keine neutralen Räume, sondern technisch und organisatorisch gestaltete Umgebungen, deren Regeln die möglichen Interaktionen zwischen den beteiligten Akteuren

⁸¹Vgl. Tiwana(2014), S. 10.

⁸²Vgl. Parker, Van Alstyne & Choudary(2016), S. 20.

⁸³Vgl. Tiwana(2014), S. 10.

⁸⁴Vgl. Cusumano, Gawer & Yoffie(2019), S. 18–21.

⁸⁵Vgl. Tiwana(2014), S. 10.

⁸⁶Vgl. Parker, Van Alstyne & Choudary(2016), S. 17.

⁸⁷Vgl. Parker, Van Alstyne & Choudary(2016), S. 17.

⁸⁸Vgl. Cusumano, Gawer & Yoffie(2019), S. 41–42.

⁸⁹Vgl. Parker, Van Alstyne & Choudary(2016), S. 5.

⁹⁰Vgl. Tiwana(2014), S. 10.

strukturieren.

In diesem Kontext bilden Plattformökosysteme eine wichtige Einsatzumgebung für KI-gestützte Monitoring-Infrastrukturen. Da der Plattformbetreiber die technische Infrastruktur bereitstellt, über die ein erheblicher Teil der vermittelten Interaktionen erfolgt, nimmt er eine zentrale Position bei der Zusammenführung von Daten aus unterschiedlichen Diensten und Akteursgruppen ein.⁹¹ Diese Daten können als strategische Ressource genutzt werden, um digitale Dienste anzupassen, Abläufe zu optimieren oder algorithmische Analyseverfahren zu unterstützen.⁹² Plattformen schaffen damit eine Infrastruktur, innerhalb derer digitale Interaktionsdaten dienst- und akteursübergreifend zusammengeführt und für weiterführende Analysen bereitgestellt werden können.⁹³ Die konkrete Profilbildung und Verhaltensanalyse werden in den folgenden Abschnitten vertieft.

Zusammenfassend lässt sich festhalten, dass Plattformökosysteme einen infrastrukturellen und organisatorischen Rahmen schaffen, innerhalb dessen zahlreiche digitale Informationssysteme und datenbasierte Dienste operieren. Die Fähigkeit, Interaktionen zwischen heterogenen Gruppen zu koordinieren und Datenflüsse über verschiedene technische Komponenten hinweg zusammenzuführen, macht sie zu einer wichtigen Einsatzumgebung für Monitoring-, Analyse- und Bewertungssysteme. Wie solche Systeme Daten erfassen, analysieren und in Bewertungen überführen, ist Gegenstand des folgenden Abschnitts zu Monitoring- und Bewertungssystemen.

2.3 Monitoring- und Bewertungssysteme

Das Verständnis von KI-gestützten Monitoring-Systemen erfordert eine detaillierte Betrachtung der Prozesse, durch die Daten in verwertbare Informationen und schließlich in algorithmische Entscheidungen transformiert werden. Bevor die einzelnen Phasen dieses Prozesses im Detail analysiert werden, ist zunächst eine begriffliche und konzeptionelle Einordnung erforderlich, die das Monitoring-System als spezifische Ausprägung eines digitalen Informationssystems verortet.

2.3.1 Begriffliche und soziotechnische Einordnung

Ein Monitoring-System lässt sich als spezialisierte Ausprägung eines digitalen Informationssystems verstehen, dessen funktionaler Schwerpunkt auf der kontinuierlichen oder regelmäßigen Beobachtung und systematischen Auswertung von Zuständen, Prozessen oder Verhalten liegt.⁹⁴ Während die allgemeine soziotechnische und funktionale Architektur KI-gestützter Monitoring-Systeme bereits in Abschnitt 2.2.1 erläutert wurde, steht im Folgenden ihre begriffliche Einordnung im Mittelpunkt.

Für die Zwecke dieser Arbeit werden drei idealtypische Formen des Monitorings un-

⁹¹Vgl. Srnicek(2017), S. 27.

⁹²Vgl. Srnicek(2017), S. 27.

⁹³Vgl. Srnicek(2017), S. 27.

⁹⁴Vgl. Lyon(2012), S. 1–2.

terschieden. Deskriptives Monitoring beschränkt sich auf die Erfassung, Aufbereitung und Darstellung beobachteter Zustände. Analytisches und prädiktives Monitoring setzt zusätzlich Verfahren der Mustererkennung, Klassifikation oder Prognose ein, um weiterführende Informationen aus den erfassten Daten abzuleiten. Adaptives beziehungsweise interventionistisches Monitoring verknüpft die Analyseergebnisse schließlich mit möglichen Anpassungen der digitalen Umgebung. Diese Differenzierung ist idealtypisch, da reale Systeme mehrere Formen miteinander verbinden können. Monitoring impliziert zudem nicht zwangsläufig eine aktive Verhaltensbeeinflussung. Eine gezielte Steuerung entsteht erst dann, wenn Analyse- oder Bewertungsergebnisse mit Systementscheidungen und Interventionen verknüpft werden.⁹⁵

Von KI-gestütztem Monitoring wird in dieser Arbeit gesprochen, wenn lernende Modelle für mindestens eine zentrale Analysefunktion eingesetzt werden. Dazu können insbesondere die Erkennung von Mustern, die Klassifikation von Objekten oder Verhaltensweisen und die Prognose zukünftiger Ereignisse gehören.⁹⁶ Regelbasierte Komponenten können diese Modelle ergänzen, ohne dass dadurch die Einordnung des Gesamtsystems als KI-gestütztes Monitoring ausgeschlossen wird. Entscheidend ist, dass mindestens ein wesentlicher Analyseschritt auf einem aus Daten abgeleiteten Modell beruht.

Das Monitoring-Gesamtsystem ist dabei von seinen operativen Teilsystemen abzugrenzen. Empfehlungssysteme, Ranking-Verfahren, Scoring-Modelle und Predictive-Analytics-Module übernehmen jeweils spezifische Funktionen, stellen jedoch nicht das gesamte Monitoring-System dar.⁹⁷⁹⁸ Sie können vielmehr als Komponenten in eine umfassendere Infrastruktur aus Datenerfassung, Datenbereitstellung, Analyse, Bewertung und möglichen Systemreaktionen eingebettet sein.

Als zentrale konzeptionelle Synthese dieser Arbeit wird in Anlehnung an das allgemeine Informationssystemmodell aus Input, Verarbeitung, Output und Feedback ein idealtypischer Monitoring-Zyklus entwickelt.⁹⁹ Dieser umfasst die Phasen Datenerfassung → Datenaufbereitung und Profilbildung → Analyse → Prognose und Bewertung → mögliche algorithmische Intervention → erneute Datenerfassung. Das Modell dient der Strukturierung der nachfolgenden Untersuchung und bildet keine für alle realen Systeme verbindliche Abfolge ab. Einzelne Phasen können je nach Systemdesign fehlen oder unterschiedlich ausgeprägt sein. Insbesondere ist die algorithmische Intervention als optionale Komponente zu verstehen.

Die erneute Datenerfassung kann eine Rückkopplung ermöglichen und beispielsweise zur Aktualisierung eines Profils oder eines internen Systemzustands genutzt werden. Sie bedeutet jedoch nicht automatisch, dass die Parameter des zugrunde liegenden Modells

⁹⁵Vgl. Pasquale(2015), S. 19.

⁹⁶Vgl. Goodfellow, Bengio & Courville(2016), S. 99–102.

⁹⁷Vgl. Adomavicius & Tuzhilin(2005), S. 734.

⁹⁸Vgl. Gillespie(2014), S. 167–168.

⁹⁹Vgl. K. C. Laudon & J. P. Laudon(2018), S. 44–45.

kontinuierlich angepasst oder neu trainiert werden.¹⁰⁰ Die folgenden Abschnitte vertiefen mit der Datenerfassung, der Analyse und Modellbildung sowie der algorithmischen Bewertung die zentralen Phasen dieses idealtypischen Zyklus.

2.3.2 Datenerfassung

Die Datenerfassung bildet die Schnittstelle eines Monitoring-Systems zur überwachten Umwelt und stellt den ersten Schritt innerhalb des idealtypischen Monitoring-Zyklus dar. In diesem Zusammenhang bezeichnet Datafizierung die Übersetzung ausgewählter Aspekte menschlichen Handelns und sozialer Prozesse in quantifizierbare und maschinenlesbare Daten.¹⁰¹ In der Theorie des Überwachungskapitalismus beschreibt Zuboff eine spezifische kommerzielle Form dieser Transformation als „Rendition“, durch die menschliche Erfahrungen für datenbasierte Auswertungen verfügbar gemacht werden.¹⁰² Diese Perspektive ist jedoch nicht auf jede Form der Datenerfassung übertragbar.

Die technologische Grundlage der Erfassung bilden unterschiedliche digitale Infrastrukturen. Daten können durch Interaktionen auf Plattformen, die Nutzung von Browsern und mobilen Anwendungen sowie durch Transaktionen entstehen. Darüber hinaus ermöglichen mobile Endgeräte, Wearables und eingebettete Sensoren die Erfassung physischer, räumlicher oder zeitbezogener Parameter.¹⁰³ Innerhalb eines funktionalen Agentenmodells bilden die auf diese Weise aufgenommenen Signale die Wahrnehmungen des Systems und damit die Eingabebasis für nachgelagerte Verarbeitungsschritte.¹⁰⁴

Monitoring-Systeme können unterschiedliche Datenarten verarbeiten, die jeweils spezifische Anforderungen an Speicherung, Aufbereitung und Analyse stellen. Dazu zählen strukturierte Transaktions- und Profildaten, unstrukturierte Text-, Bild- und Audiodaten sowie zeitbezogene Sensor- und Interaktionsdaten. Eine weitere Unterscheidung betrifft die Entstehungsweise personenbezogener Informationen. Dabei kann zwischen freiwillig bereitgestellten Daten, beobachteten Daten und aus vorhandenen Informationen abgeleiteten Daten differenziert werden.¹⁰⁵ Freiwillig bereitgestellte Daten entstehen beispielsweise durch Profileingaben, während beobachtete Daten aus der tatsächlichen Nutzung eines Dienstes hervorgehen. Abgeleitete Daten entstehen dagegen erst durch analytische Schlussfolgerungen aus bereits vorhandenen Datenbeständen.

Erfassungsfrequenz, Granularität und Umfang der Datenbasis können je nach Systemarchitektur, Anwendungszweck, technischen Möglichkeiten, organisatorischen Regeln und rechtlichen Rahmenbedingungen erheblich variieren. Datenerfassung erfolgt daher weder zwangsläufig lückenlos noch immer in Echtzeit. Die entstehende Datenbasis bildet

¹⁰⁰ Vgl. Russell & Norvig(2010), S. 34.

¹⁰¹ Vgl. Dijck(2014), S. 1.

¹⁰² Vgl. Zuboff(2019), S. 223.

¹⁰³ Vgl. K. C. Laudon & J. P. Laudon(2018), S. 210–211, 254–255.

¹⁰⁴ Vgl. Russell & Norvig(2010), S. 34.

¹⁰⁵ Vgl. OECD(2013), S. 10–11.

vielmehr eine selektive und kontextabhängige Repräsentation der überwachten Umwelt.

Nach der Erfassung können fragmentierte digitale Spuren aus unterschiedlichen Quellen zusammengeführt und für weitere Verarbeitungsschritte bereitgestellt werden.¹⁰⁶ Dabei entstehen jedoch noch keine vollständigen Nutzungsprofile oder belastbaren Aussagen über Verhalten. Erst die anschließende Analyse und Modellbildung verknüpft die erfassten Daten zu Profilen, Zustandsmodellen, Mustern oder Prognosen.

2.3.3 Analyse und Modellbildung

Nachdem die Daten erfasst und für die Analyse bereitgestellt wurden (vgl. Abschnitt 2.3.2), folgt die Phase der Modellbildung. In diesem Prozessschritt werden fragmentierte Datenpunkte systematisch zu Profilen, Zustandsmodellen und Mustern verknüpft, um eine datenbasierte Repräsentation der überwachten Umwelt oder der Nutzer zu erstellen.

Ein zentrales Element ist die Profilbildung aus historischen und aktuellen Datenbeständen. Durch die Aggregation zeitlich und räumlich verteilter digitaler Spuren entstehen umfassende Datensätze, die als digitale Dossiers charakterisiert werden.¹⁰⁷ Wissenschaftlich ist dabei zu betonen, dass solche Profile zweckgebundene, vereinfachte Repräsentationen sind und keine vollständige oder objektive Identität einer Person abbilden.¹⁰⁸ Sie dienen dazu, komplexe Informationen in maschinenlesbare Kategorien zu formalisieren, die für den jeweiligen Systemzweck relevant sind.

In komplexen Monitoring-Umgebungen ist das System häufig damit konfrontiert, dass entscheidende Merkmale nicht direkt beobachtbar sind. Zur Lösung dieser Herausforderung wird die Methode der Zustandschätzung eingesetzt. Das System nutzt dabei eine Sequenz beobachtbarer Variablen, um Wahrscheinlichkeiten für nicht direkt beobachtbare, latente Zustände abzuleiten.¹⁰⁹ Hierbei handelt es sich um probabilistische Schlussfolgerungen, nicht um gesicherte Tatsachen. So können beispielsweise eine vermutete Kaufabsicht oder spezifische Präferenzen lediglich als Wahrscheinlichkeitswerte innerhalb eines Modells existieren. Der hierbei aufrechterhaltene interne Zustand des Systems über seine Umwelt wird als Belief State bezeichnet. Dieser repräsentiert eine Wahrscheinlichkeitsverteilung über die Zustände, die auf Grundlage der bisherigen Beobachtungen als möglich gelten.¹¹⁰

Die Identifikation von Regelmäßigkeiten erfolgt durch Mustererkennung und Segmentierung. Unter Einsatz statistischer Verfahren werden Ähnlichkeiten im Verhalten erkannt, die eine neutrale analytische Gruppierung von Objekten oder Nutzern ermöglichen.¹¹¹ Davon abzugrenzen ist die Anomalieerkennung, die darauf abzielt, Datenmuster zu identifizieren, die deutlich von einem erwarteten Muster oder einem etablierten Normalverhalten

¹⁰⁶ Vgl. Kitchin(2014), S. 722.

¹⁰⁷ Vgl. Kitchin(2014), S. 723.

¹⁰⁸ Vgl. Gillespie(2014), S. 174.

¹⁰⁹ Vgl. Russell & Norvig(2010), S. 556.

¹¹⁰ Vgl. Russell & Norvig(2010), S. 117.

¹¹¹ Vgl. Goodfellow, Bengio & Courville(2016), S. 104–105, 146–147.

abweichen.¹¹²

Innerhalb der Modellanwendung muss methodisch präzise zwischen der Aktualisierung eines Profils oder Systemzustands durch neue Beobachtungen und dem erneuten Training der Modellparameter unterschieden werden. Während die Aktualisierung den Belief State oder das Profil anhand neuer Beobachtungen an die aktuelle Evidenzlage anpasst¹¹³, umfasst ein erneutes Training die Anpassung der Modellparameter anhand neuer oder aktualisierter Trainingsdaten. Es ist festzuhalten, dass nicht jedes Monitoring-System kontinuierlich lernt; vielmehr muss die Modellleistung regelmäßig überwacht werden, um die Übertragbarkeit auf neue Kontexte sicherzustellen.¹¹⁴

Zusammenfassend lassen sich die erzeugten Analyseergebnisse als Informationsgrundlagen verstehen, die deskriptive Muster, Cluster, Wahrscheinlichkeiten, Prognosen oder Anomaliehinweise umfassen können. Diese Analyseergebnisse können als Eingaben für die nachfolgende algorithmische Bewertung und Klassifikation dienen (vgl. Abschnitt 2.3.4), in der sie anhand definierter Regeln, Kategorien oder Schwellenwerte interpretiert und gegebenenfalls in Systementscheidungen überführt werden können.

2.3.4 Algorithmische Bewertung und Klassifikation

Die algorithmische Bewertung bildet eine mögliche abschließende Verarbeitungsphase innerhalb des Monitoring-Zyklus, in der technische Analyseergebnisse in eine handlungsrelevante Form überführt werden können. Dabei ist zwischen dem technischen Modelloutput und seiner anschließenden Bewertung zu unterscheiden. Ein Modelloutput – etwa eine berechnete Wahrscheinlichkeit, ein statistischer Score, ein Ähnlichkeitswert oder ein Anomaliehinweis – stellt zunächst ein technisches Analyseergebnis dar. Erst durch die Anwendung spezifischer Regeln, Kategorien, Gewichtungen oder Schwellenwerte wird dieses Ergebnis im Kontext organisatorischer Ziele interpretiert und erhält eine entscheidungsbezogene Bedeutung.¹¹⁵

Innerhalb dieses Prozesses lassen sich insbesondere Klassifikation und Scoring unterscheiden. Die Klassifikation ordnet einzelne Fälle oder Datenpunkte diskreten, vordefinierten Kategorien zu. Das Scoring bildet dagegen Merkmale, Wahrscheinlichkeiten oder potenzielle Risiken in numerischen Werten ab. Ein Score stellt für sich genommen noch keine Entscheidung dar, sondern dient zunächst als quantifizierte Bewertungsgrundlage, die anschließend durch Regeln oder Schwellenwerte interpretiert werden kann.¹¹⁶

Das Ranking ordnet Informationen, Personen oder Objekte anhand eines oder mehrerer Relevanz-, Risiko- oder Prioritätskriterien in eine hierarchische Reihenfolge.¹¹⁷ Ein Ran-

¹¹²Vgl. Chandola, Banerjee & Kumar(2009), S. 1.

¹¹³Vgl. Russell & Norvig(2010), S. 562.

¹¹⁴Vgl. National Institute of Standards and Technology(2023), S. 14, 29, 38.

¹¹⁵Vgl. Pasquale(2015), S. 19.

¹¹⁶Vgl. Pasquale(2015), S. 19.

¹¹⁷Vgl. Gillespie(2014), S. 175–177.

king kann auf Scores oder anderen Modelloutputs beruhen, stellt jedoch eine eigenständige Form der algorithmischen Ordnung dar.

Hinsichtlich der Entscheidungslogik sind unterschiedliche Automatisierungsgrade zu unterscheiden. Monitoring-Systeme können Bewertungen lediglich als Unterstützung für menschliche Entscheidungen bereitstellen, eine verpflichtende menschliche Prüfung vorsehen oder bei klar definierten und standardisierten Aufgaben automatisierte Entscheidungen und Systemreaktionen ausführen.¹¹⁸ Dabei sollten Zuständigkeiten, Kontrollmöglichkeiten und Grenzen des Systems dokumentiert und regelmäßig überprüft werden.¹¹⁹

Algorithmische Bewertung und Klassifikation führen nicht zwangsläufig zu einer Verhaltensbeeinflussung. Ein steuernder Einfluss kann erst entstehen, wenn die Ergebnisse mit einer konkreten Auswahl, Empfehlung, Priorisierung oder Intervention verbunden werden. Personalisierung, Interaktionsoptimierung und Anstöße stellen mögliche Anwendungsformen dar, die in Kapitel 3 vertieft werden. Nachdem damit die theoretischen und technologischen Grundlagen des Monitoring-Zyklus dargestellt wurden, erläutert Abschnitt 2.4 das methodische Vorgehen der Untersuchung.

2.4 Methodisches Vorgehen

Die vorliegende Arbeit folgt einem systematischen, literaturbasierten Forschungsansatz, um die Funktionsweise und Auswirkungen von KI-gestützten Monitoring-Systemen theoretisch zu durchdringen. Das methodische Vorgehen orientiert sich an etablierten Standards der Wirtschaftsinformatik, um Transparenz und wissenschaftliche Strenge zu gewährleisten.

2.4.1 Forschungsansatz

Der Forschungsansatz dieser Arbeit ist als qualitative, theoriegeleitete Literaturanalyse konzipiert. Ziel ist es, den aktuellen Erkenntnisstand zu KI-gestützten Systemen systematisch zu rekonstruieren und zu synthetisieren. Dabei wird explizit auf eine eigene Primärdatenerhebung verzichtet, da die Forschungsfrage auf der theoretischen Durchdringung und Integration bestehender Konzepte der Wirtschaftsinformatik und Informatik basiert. In Anlehnung an Hevner et al. (2004) bildet die fundierte Nutzung der vorhandenen Wissensbasis die notwendige Grundlage für die wissenschaftliche Rigorosität dieser Untersuchung.¹²⁰ Wissenschaft wird hierbei als kumulatives Unterfangen verstanden, bei dem neue Erkenntnisse durch die Interpretation und Kombination bestehenden Wissens gewonnen werden, getreu dem Gleichnis vom Stehen auf den Schultern von Riesen.¹²¹

¹¹⁸Vgl. K. C. Laudon & J. P. Laudon(2018), S. 467, 493–494.

¹¹⁹Vgl. National Institute of Standards and Technology(2023), S. 22–23, 26, 29.

¹²⁰Vgl. Brocke u. a.(2009), S. 1.

¹²¹Vgl. Brocke u. a.(2009), S. 1.

2.4.2 Literaturrecherche

Die Literaturrecherche wurde als mehrstufiger Prozess gestaltet, der die Suche in wissenschaftlichen Datenbanken, Keyword-Recherchen sowie Vorwärts- und Rückwärtssuchen umfasst.¹²² Zunächst wurden zentrale Fachbegriffe definiert und in Suchphrasen überführt, um relevante Quellen in Datenbanken wie EBSCOhost oder ScienceDirect zu identifizieren. Die Rückwärtssuche beinhaltete die Analyse der Referenzen der gefundenen Kernartikel, um ältere, fundamentale Arbeiten zu erschließen, während die Vorwärtssuche dazu diente, aktuellere Quellen zu finden, die die identifizierten Artikel zitieren. Dieses Vorgehen stellt sicher, dass die Recherche über eine rein stichwortbasierte Suche hinausgeht und die Vernetzung innerhalb des wissenschaftlichen Diskurses abbildet.

2.4.3 Auswahlkriterien der Quellen

Um die Qualität der Literaturübersicht sicherzustellen, wurden die Quellen nach expliziten Kriterien ausgewählt, wobei primär Beiträge aus hochrangigen, begutachteten Fachzeitschriften und Konferenzbänden berücksichtigt wurden.¹²³ Die Bewertung der Zeitschriftenqualität orientierte sich an etablierten Rankings, wie der konsolidierten Liste der Association for Information Systems (Association for Information Systems (AIS)). Ein wesentliches Auswahlkriterium war die Relevanz der Inhalte bezüglich der technologischen Grundlagen von KI und ML sowie der soziotechnischen Architektur von Informationssystemen. Quellen, die lediglich oberflächliche Beschreibungen lieferten oder keine klare theoretische Fundierung aufwiesen, wurden im Rahmen des Evaluierungsprozesses ausgeschlossen.

2.4.4 Methodische Grenzen

Trotz des systematischen Vorgehens unterliegt die Literaturanalyse gewissen Grenzen, da die schiere Menge an Publikationen im Bereich der Wirtschaftsinformatik eine vollständige Erfassung aller Quellen zu einer Sisypusarbeit macht.¹²⁴ Es ist daher unvermeidlich, dass eine Vielzahl von Arbeiten im Suchprozess unberücksichtigt bleibt, was den Anspruch auf absolute Vollständigkeit einschränkt. Zudem kann die mangelnde Dokumentation des Suchprozesses in manchen Basisartikeln die Replikation erschweren und somit die methodische Strenge der zugrunde liegenden Literatur beeinflussen. Schließlich können redaktionelle Einschränkungen in der Veröffentlichungspraxis, wie etwa Begrenzungen der Seitenanzahl oder der Literaturverzeichnisse, die Tiefe der dokumentierten Analyse in den Primärquellen limitieren.

Über die quantitative Begrenzung hinaus ergeben sich inhaltliche Limitationen aus der Natur des Untersuchungsgegenstandes. Viele der analysierten Empfehlungssysteme und Monitoring-Logiken basieren auf proprietären Algorithmen großer Plattformbetreiber,

¹²²Vgl. Brocke u. a.(2009), S. 1.

¹²³Vgl. Brocke u. a.(2009), S. 1.

¹²⁴Vgl. Brocke u. a.(2009), S. 1.

deren exakte Funktionsweise als Geschäftsgeheimnis geschützt ist. Diese mangelnde Transparenz führt dazu, dass wissenschaftliche Analysen oft auf einer „Black-Box“-Betrachtung oder auf Reverse Engineering angewiesen sind.¹²⁵ Zudem erschweren die schnellen technologischen Entwicklungen im Bereich der KI eine zeitlose theoretische Fixierung, da neue Verfahren (z. B. im Deep Learning) die untersuchten Mechanismen der Verhaltensbeeinflussung laufend verändern und erweitern.

¹²⁵Vgl. Pasquale(2015), S. 19.

3 KI-gestützte Monitoring-Systeme in digitalen Informationsumgebungen

Die theoretischen und technologischen Grundlagen digitaler Informationssysteme finden in modernen digitalen Umgebungen ihre praktische Anwendung, wobei KI-gestützte Monitoring-Systeme als zentrale operative Einheiten fungieren. Diese Systeme operieren innerhalb von Plattformen, die nicht mehr nur als neutrale Vermittler, sondern als extraktive Apparate verstanden werden können, die darauf ausgelegt sind, menschliche Erfahrung systematisch in Verhaltensdaten zu übersetzen.¹²⁶¹²⁷ Soziotechnische Strukturen werden genutzt, um massive Volumina an Verhaltensdaten zu sammeln, zu verarbeiten und zu analysieren, was die Grundlage für Personalisierung, Empfehlungen und Vorhersageprozesse bildet.¹²⁸ Diese Systeme lösen die Grenze zwischen digitaler Infrastruktur und sozialer Interaktion auf, um Verhalten messbar und schließlich steuerbar zu machen.

3.1 Datenerfassung und digitale Verhaltensanalyse

Die digitale Verhaltensanalyse beginnt mit einer umfassenden Architektur der Datenerfassung, die jeden Aspekt der Nutzerinteraktion in ein quantifizierbares Format transformiert. Dieser Prozess der Datafizierung bildet die notwendige Voraussetzung dafür, dass Monitoring-Systeme ein kontinuierliches Abbild der Realität erstellen und darauf basierend algorithmische Entscheidungen treffen können.

Digitale Plattformen wie soziale Netzwerke, Suchmaschinen und Videodienste operieren dabei nicht primär als bloße Kommunikationsmedien, sondern als digitale Informationssysteme mit integrierter Monitoring-Funktion.¹²⁹ Diese Systeme sind darauf ausgelegt, Nutzerinteraktionen in Echtzeit zu erfassen, systematisch zu speichern und mittels algorithmischer Verarbeitung in strukturierte Datenbestände zu überführen. Die erfassten Verhaltensdaten werden zu detaillierten Nutzerprofilen verdichtet, die als Grundlage für algorithmische Entscheidungen und personalisierte Informationsangebote dienen. Der operative Kern dieser digitalen Informationssysteme besteht in einem kontinuierlichen Rückkopplungszyklus: Erfasste Interaktionen werden analysiert, bewertet und als optimierte Informationsflüsse zurückgespielt, wodurch die Plattform zugleich Beobachtungsinstrument und gestaltende Infrastruktur der digitalen Informationsumgebung wird.¹³⁰

3.1.1 Social-Media-Plattformen

Als digitale Informationssysteme erfassen Social-Media-Plattformen kontinuierlich Verhaltensdaten und übersetzen menschliche Kommunikation sowie soziale Beziehungen in

¹²⁶Vgl. Srnicek(2017), S. 21.

¹²⁷Vgl. Zuboff(2019), S. 69.

¹²⁸Vgl. Lyon(2012), S. 1–2.

¹²⁹Vgl. Dijck(2014), S. 198 f..

¹³⁰Vgl. Yeung(2017), S. 122.

maschinenlesbare Datenströme.¹³¹ Jede Interaktion – sei es ein „Like“, ein Kommentar, das Teilen eines Beitrags oder die bloße Verweildauer auf einem Inhalt – wird als Eingabewert in algorithmische Verarbeitungsprozesse überführt.¹³² Plattformen wie Facebook, Instagram oder TikTok operieren dabei als persistente Monitoring-Infrastrukturen, die Nutzerverhalten nicht punktuell registrieren, sondern systematisch in Nutzerprofilen aggregieren, um daraus einen sogenannten Verhaltensüberschuss (Behavioral Surplus) zu extrahieren, der als Grundlage algorithmischer Entscheidungslogiken dient.¹³³

Als digitale Informationssysteme verarbeiten diese Plattformen kontinuierlich massive, oft unstrukturierte Verhaltensdaten, um mittels KI-gestützter Analyse Muster in Präferenzen und emotionalen Zuständen zu identifizieren.¹³⁴ Beispielsweise nutzt TikTok einen rein algorithmisch gesteuerten Feed, der auf der Echtzeit-Verarbeitung hochfrequenter Interaktionsdatensätze basiert, um Interaktionsprognosen zu optimieren.¹³⁵ Systeme wie FB Learner Flow von Facebook trainieren täglich tausende von Modellen an Billionen von Datenpunkten, um personalisierte Relevanzwerte zu berechnen.¹³⁶ Diese digitalen Informationssysteme fungieren somit als umfassende Erfassungsinfrastrukturen für gesellschaftliche Stimmungen und individuelles Verhalten, wobei die algorithmische Entscheidungslogik sicherstellt, dass Informationsflüsse präzise auf die errechneten Nutzerprofile zugeschnitten werden.¹³⁷

3.1.2 Plattformökosysteme

Die organisatorische und technologische Einbettung dieser Monitoring-Prozesse erfolgt innerhalb von Plattformökosystemen, die als komplexe digitale Informationssysteme mit spezifischer ökonomischer Logik operieren. Plattformen agieren als mehrseitige Märkte, die Interaktionen zwischen Nutzern, Werbetreibenden und Anbietern von Zusatzdiensten (Apps) koordinieren.¹³⁸¹³⁹ Ein entscheidendes Element ist hierbei das Auftreten von Netzwerkeffekten: Je mehr Nutzer eine Plattform verwenden, desto wertvoller wird sie für alle Beteiligten, was zu einer natürlichen Tendenz zur Monopolisierung und einer immer umfassenderen Datensammlung führt.¹⁴⁰

Innerhalb dieser digitalen Informationssysteme werden Verhaltensdaten zur strategischen Ressource, die den Kern der wirtschaftlichen Wertschöpfung bildet. Die Plattform-Governance legt dabei die Regeln fest, nach denen Daten erfasst, gespeichert, verarbeitet und genutzt

¹³¹ Vgl. Dijck(2014), S. 1.

¹³² Vgl. Narayanan(2023), S. 18–19.

¹³³ Vgl. Zuboff(2019), S. 69.

¹³⁴ Vgl. Metzler & Garcia(2023), S. 735–736.

¹³⁵ Vgl. Narayanan(2023), S. 11, 18–20, 23.

¹³⁶ Vgl. Zuboff(2019), S. 18.

¹³⁷ Vgl. Lyon(2012), S. 2, 5.

¹³⁸ Vgl. Cusumano, Gawer & Yoffie(2019), S. 15–16.

¹³⁹ Vgl. Tiwana(2014), S. 10.

¹⁴⁰ Vgl. Srnicek(2017), S. 27.

werden dürfen, wobei die Plattformbetreiber als zentrale Torwächter fungieren.^{141 142} Durch die systemische Integration verschiedener Dienste – wie Suche, soziale Netzwerke und Cloud-Infrastrukturen – können Unternehmen wie Amazon oder Google Verhaltensdaten aus unterschiedlichen Lebensbereichen konsolidieren und in einheitlichen Datenbanken aggregieren, was die Vorhersagekraft ihrer algorithmischen Entscheidungslogiken massiv erhöht.^{143 144} Diese digitalen Informationssysteme schaffen einen technologischen Rahmen, in dem die Erfassung von Verhaltensdaten nicht mehr als Nebenprodukt, sondern als primärer Zweck der Infrastruktur erscheint, um durch algorithmische Optimierung garantierte kommerzielle Ergebnisse zu erzielen.^{145 146}

3.1.3 Digitale Fußabdrücke und Nutzungsprofile

Das Resultat der kontinuierlichen Datenerfassung in digitalen Informationssystemen ist die systematische Transformation von digitalen Fußabdrücken (Digital Footprints) in detaillierte Nutzungsprofile. Jede Online-Aktivität hinterlässt „virtuelle Brotkrumen“, die ein präziseres Bild der Persönlichkeit und des Lebens eines Individuums zeichnen können, als dies durch bewusste Selbstauskünfte möglich wäre.¹⁴⁷ Monitoring-Systeme aggregieren diese Spuren zu umfassenden Datensätzen, wobei zwischen freiwillig bereitgestellten, beobachteten und erschlossenen Daten (Inferred Data) unterschieden werden muss.¹⁴⁸ Durch komplexe Daten-Mining-Verfahren und statistische Korrelationen können Systeme sensible Merkmale wie sexuelle Orientierung, politische Gesinnung oder die psychische Verfassung aus scheinbar banalen Interaktionen wie „Likes“ ableiten.^{149 150}

Diese datengetriebene Repräsentation von Individuen führt zur Erstellung von digitalen Dossiers oder algorithmischen Identitäten, die oft als „Schattenkörper“ (Shadow Bodies) bezeichnet werden, da sie nur jene Aspekte einer Person betonen, die für die algorithmische Entscheidungslogik lesbar und verarbeitbar sind.¹⁵¹ Die Aggregation von Verhaltensdaten über verschiedene digitale Informationssysteme hinweg ermöglicht es, Verhaltensmuster über lange Zeiträume zu modellieren und Individuen in immer feingranularere Segmente zu klassifizieren.^{152 153} Diese Profile dienen nicht nur der Analyse der Vergangenheit, sondern bilden das Fundament für die Vorhersage und gezielte Beeinflussung zukünftigen Verhaltens durch algorithmische Steuerungsmechanismen.¹⁵⁴

¹⁴¹ Vgl. Parker, Van Alstyne & Choudary(2016), S. 5.

¹⁴² Vgl. Tiwana(2014), S. 10.

¹⁴³ Vgl. Srnicek(2017), S. 48.

¹⁴⁴ Vgl. Cusumano, Gawer & Yoffie(2019), S. 94–95, 100–101.

¹⁴⁵ Vgl. Zuboff(2019), S. 69.

¹⁴⁶ Vgl. Parker, Van Alstyne & Choudary(2016), S. 5.

¹⁴⁷ Vgl. Zuboff(2019), S. 28.

¹⁴⁸ Vgl. OECD(2013), S. 10–11.

¹⁴⁹ Vgl. Dijck(2014), S. 1.

¹⁵⁰ Vgl. Acquisti, Brandimarte & Loewenstein(2016), S. 444.

¹⁵¹ Vgl. Gillespie(2014), S. 168.

¹⁵² Vgl. Kitchin(2014), S. 722.

¹⁵³ Vgl. Lyon(2012), S. 4–5.

¹⁵⁴ Vgl. OECD(2013), S. 13–15.

3.2 Algorithmische Steuerungs- und Bewertungsmechanismen

Die systematische Erfassung von Verhaltensdaten bildet die infrastrukturelle Grundlage für die operative Ebene KI-gestützter Monitoring-Systeme, die als digitale Informationssysteme durch spezifische algorithmische Entscheidungslogiken eine aktive Steuerung von Informationsflüssen und Nutzerhandlungen vollziehen. Diese Mechanismen fungieren als instrumentelle Verarbeitungslogik, die nicht nur Informationen filtert, sondern gezielt Relevanz konstruiert und so die digitalen Informationsumgebungen der Nutzer strukturiert.¹⁵⁵

3.2.1 Personalisierung

Die technische Realisierung einer individualisierten Informationsumgebung erfolgt primär durch Empfehlungssysteme (Recommender Systems), deren Kernaufgabe in der Schätzung des Nutzwerts (Utility) von bisher ungesehenen Objekten für einen spezifischen Nutzer besteht.¹⁵⁶ Der Prozess basiert auf der Extrapolation bekannter Präferenzen in einen multidimensionalen Raum, wobei zwei grundlegende Paradigmen dominieren: Das inhaltsbasierte Filtern (Content-based Filtering) empfiehlt Objekte, die Ähnlichkeiten zu früher präferierten Inhalten aufweisen, während das kollaborative Filtern (Collaborative Filtering) Übereinstimmungen zwischen den Bewertungsmustern verschiedener Nutzer identifiziert, um Vorhersagen auf Basis von „People-to-People“-Korrelationen zu treffen.¹⁵⁷¹⁵⁸ Hybride Systeme kombinieren diese Ansätze häufig mit wissensbasierten Methoden, um die Vorhersagegenauigkeit weiter zu steigern und technologische Hürden wie das Kaltstart-Problem zu überwinden.¹⁵⁹

Die Konsequenz dieser technologisch geschaffenen Umgebungen ist eine zunehmende Einengung des Informationshorizonts. Pariser (2011) beschreibt dieses Phänomen als Filterblase (Filter Bubble), in der die algorithmische Selektion dazu führt, dass Individuen primär mit dem vertrauten „Ghetto des Einen“ konfrontiert werden.¹⁶⁰ Da die Identität des Nutzers die Medieninhalte prägt und diese wiederum die Überzeugungen des Nutzers bestärken, entsteht eine Feedback-Schleife, die als „You Loop“ bezeichnet wird.¹⁶¹ In der Logik des Überwachungskapitalismus dient diese Personalisierung nicht mehr nur der Nutzerzufriedenheit, sondern der Gewinnung eines Verhaltensüberschusses, indem das Individuum in eine algorithmisch lesbare und damit vorhersagbare Identität gedrängt wird.¹⁶²

¹⁵⁵ Vgl. Gillespie(2014), S. 172.

¹⁵⁶ Vgl. Adomavicius & Tuzhilin(2005), S. 734.

¹⁵⁷ Vgl. Burke(2002), S. 2–3.

¹⁵⁸ Vgl. Adomavicius & Tuzhilin(2005), S. 734–735.

¹⁵⁹ Vgl. Burke(2002), S. 6–8.

¹⁶⁰ Vgl. Pariser(2011), S. 1.

¹⁶¹ Vgl. Pariser(2011), S. 1.

¹⁶² Vgl. Gillespie(2014), S. 175–176, 185.

3.2.2 Ranking-Algorithmen

Während die Personalisierung den individuellen Zuschnitt definiert, bestimmen Ranking-Algorithmen die hierarchische Ordnung und damit die Sichtbarkeit von Informationen innerhalb digitaler Plattformen.¹⁶³ Diese Algorithmen fungieren als neue Torwächter, die den Fluss von Wissen nach spezifischen, oft proprietären Relevanzkriterien steuern.¹⁶⁴¹⁶⁵ Ein zentraler Mechanismus moderner Plattformen ist hierbei die Interaktionsprognose, bei der Inhalte danach gewichtet werden, mit welcher Wahrscheinlichkeit ein Nutzer eine Interaktion (Likes, Kommentare, Shares) vollziehen wird.¹⁶⁶ Ein prominentes Beispiel ist das Meaningful Social Interaction (MSI)-Modell von Facebook, das durch maschinelles Lernen Wahrscheinlichkeiten für verschiedene Interaktionstypen berechnet und den News Feed entsprechend priorisiert.¹⁶⁷

Die daraus resultierende algorithmische Priorisierung transformiert soziale Interaktionen in eine ökonomische Logik, in der Aufmerksamkeit zur zentralen Währung wird. Da Ranking-Algorithmen bestimmen, was für die Öffentlichkeit wahrnehmbar ist, konstituieren sie sogenannte „berechnete Öffentlichkeiten“ (Calculated Publics), die politische Diskurse und gesellschaftliche Wahrnehmungen massiv beeinflussen können.¹⁶⁸ Die Konsequenz dieser Machtasymmetrie besteht darin, dass Plattformbetreiber durch die Manipulation der Sichtbarkeit – etwa durch die algorithmische Herabstufung (Demotion) von Inhalten – gezielte Verhaltenssteuerung betreiben können, ohne dass die zugrunde liegenden Bewertungskriterien für den Nutzer transparent sind.¹⁶⁹

3.2.3 Reputations- und Scoring-Systeme

Eine spezifische Form der algorithmischen Bewertung ist die Umwandlung von Verhaltensdaten in automatisierte Scores, die zur Klassifikation und Hierarchisierung von Individuen dienen.¹⁷⁰ Durch die Aggregation von digitalen Fußabdrücken, wie etwa Klickströmen, Standortdaten oder sozialen Kontakten, werden Profile erstellt, die beispielsweise die Kreditwürdigkeit oder Zuverlässigkeit bewerten.¹⁷¹ Solche e-Scores fungieren als Instrumente zur Reduktion von Unsicherheit für Unternehmen, indem sie Individuen in mathematische Wahrscheinlichkeitskategorien einteilen.¹⁷²¹⁷³

Diese Scoring-Verfahren haben tiefgreifende Konsequenzen für die soziale Teilhabe und Gerechtigkeit. O’Neil (2016) bezeichnet solche Modelle als „Weapons of Math Destructi-

¹⁶³ Vgl. Gillespie(2014), S. 2.

¹⁶⁴ Vgl. Gillespie(2014), S. 188–190.

¹⁶⁵ Vgl. Pasquale(2015), S. 19.

¹⁶⁶ Vgl. Narayanan(2023), S. 18–20.

¹⁶⁷ Vgl. Narayanan(2023), S. 30–31.

¹⁶⁸ Vgl. Gillespie(2014), S. 172, 176, 185.

¹⁶⁹ Vgl. Narayanan(2023), S. 16–18, 22.

¹⁷⁰ Vgl. Pasquale(2015), S. 19.

¹⁷¹ Vgl. O’Neil(2016), S. 145.

¹⁷² Vgl. OECD(2013), S. 10, 16.

¹⁷³ Vgl. O’Neil(2016), S. 145.

on“ (WMD), da sie oft auf undurchsichtigen Kriterien basieren, Vorurteile kodifizieren und für die Betroffenen lebensverändernde Folgen haben können – etwa den Ausschluss von Finanzprodukten oder Arbeitsplätzen –, ohne dass Einspruchsmöglichkeiten bestehen.¹⁷⁴ Die algorithmische Bewertung tarnt dabei diskriminierende Praktiken, wie das „Redlining“ auf Basis von Postleitzahlen, als objektive mathematische Evidenz und etabliert so eine Form der algorithmischen Governance, die das Leben des Einzelnen permanent überwacht und bewertet.¹⁷⁵¹⁷⁶

3.2.4 Interaktionsoptimierung und Verhaltensprognosen

Die Integration von Personalisierung, Ranking und Scoring mündet in der systematischen Optimierung der Interaktion, um Verhaltensprognosen zu kommerzialisieren und Handlungen gezielt zu lenken. Plattformen nutzen hierbei Mechanismen des Bestärkenden Lernens (Reinforcement Learning), bei dem Agenten kontinuierlich aus Nutzerreaktionen lernen, um jene Aktionen (Policies) zu identifizieren, die den erwarteten Reward – in Form von Aufmerksamkeit oder Klicks – maximieren.¹⁷⁷¹⁷⁸

Reinforcement Learning ermöglicht es Plattformen, Interaktionsmuster kontinuierlich zu analysieren und erfolgreiche Maßnahmen algorithmisch zu verstärken.¹⁷⁹ Um jedoch zu verstehen, warum bestimmte Maßnahmen überhaupt wirksam sind, müssen zusätzlich verhaltenswissenschaftliche Modelle betrachtet werden. Diese erklären, welche Faktoren menschliches Verhalten beeinflussen und wie digitale Systeme gezielt Anreize setzen können.¹⁸⁰

Das Fogg Behavior Model bietet hierfür einen konzeptionellen Rahmen: Verhalten entsteht demnach durch das gleichzeitige Zusammentreffen von Motivation, Fähigkeit (Ability) und einem Auslöser (Trigger). Digitale Monitoring-Systeme nutzen diese Erkenntnisse operativ, indem sie durch zeitlich und inhaltlich präzise platzierte Trigger – etwa Push-Benachrichtigungen oder personalisierte Inhaltsvorschläge – ein gewünschtes Zielverhalten automatisieren.¹⁸¹

Praktische Anwendungen demonstrieren die operative Funktionsweise dieser Verhaltensmodifikation. Die Facebook-Studie zur „Emotional Contagion“ bewies, dass die algorithmische Manipulation von emotionalen Inhalten im News Feed die Stimmungslage von Millionen Nutzern ohne deren Wissen verändern kann.¹⁸²¹⁸³

¹⁷⁴ Vgl. O’Neil(2016), S. 145.

¹⁷⁵ Vgl. Pasquale(2015), S. 19.

¹⁷⁶ Vgl. O’Neil(2016), S. 145.

¹⁷⁷ Vgl. Sutton & Barto(2018), S. 1.

¹⁷⁸ Vgl. Narayanan(2023), S. 18–20.

¹⁷⁹ Vgl. Narayanan(2023), S. 18, 38.

¹⁸⁰ Vgl. Yeung(2017), S. 118.

¹⁸¹ Vgl. Fogg(2009), S. 1, 3, 7.

¹⁸² Vgl. Zuboff(2019), S. 20.

¹⁸³ Vgl. Kramer, Guillory & Hancock(2014), S. 8788–8789.

Der Fall Cambridge Analytica illustriert exemplarisch den vollständigen operativen Zyklus KI-gestützter Monitoring-Systeme: Das Unternehmen erfasste systematisch Verhaltensdaten von Millionen Facebook-Nutzern durch eine scheinbar harmlose Persönlichkeits-App. Diese Rohdaten wurden mittels psychometrischer Verfahren analysiert, um detaillierte Persönlichkeitsprofile nach dem OCEAN-Modell (Openness, Conscientiousness, Extraversion, Agreeableness, Neuroticism) zu erstellen.¹⁸⁴¹⁸⁵ Auf Basis dieser Profile erfolgte eine präzise Segmentierung der Nutzer in Zielgruppen mit spezifischen psychologischen Vulnerabilitäten.¹⁸⁶ Die operative Intervention bestand in der Auslieferung maßgeschneiderter politischer Botschaften (Micro-Targeting), die exakt auf die identifizierten Persönlichkeitsmerkmale zugeschnitten waren, um Überzeugungen zu verstärken oder Zweifel zu säen.¹⁸⁷ Dieser Prozess – von der Datenerfassung über die Profilbildung und Segmentierung bis zur gezielten Verhaltensintervention – demonstriert die technische Funktionsweise digitaler Informationssysteme mit Monitoring-Funktion als geschlossene Rückkopplungsschleifen zur systematischen Beeinflussung menschlichen Verhaltens.¹⁸⁸

Schließlich führen diese Mechanismen zur Verstärkung von Echo-Kammern, in denen homophile Cluster und die algorithmische Belohnung von Emotionalität die soziale Polarisierung vorantreiben und die individuelle Autonomie zugunsten eines „Instrumentarismus“ untergraben.¹⁸⁹

Die hier analysierten Mechanismen – Personalisierung, Empfehlungssysteme, Ranking-Algorithmen, Scoring-Verfahren und Interaktionsoptimierung – stellen keine isolierten algorithmischen Einzelfunktionen dar, sondern bilden funktionale Module eines integrierten digitalen Monitoring-Informationssystems.¹⁹⁰ Ihre operative Logik folgt einem kontinuierlichen Verarbeitungszyklus: Verhaltensdaten werden erfasst, in strukturierten Nutzerprofilen aggregiert, mittels analytischer Verfahren ausgewertet, durch Scoring-Mechanismen bewertet und schließlich als Grundlage algorithmischer Interventionen genutzt, die wiederum neue Verhaltensdaten generieren.¹⁹¹ Diese systemische Rückkopplung transformiert KI-gestützte Monitoring-Systeme von passiven Beobachtungsinstrumenten zu aktiven Gestaltungsinfrastrukturen digitaler Informationsumgebungen. Sie strukturieren nicht nur die Verfügbarkeit und Sichtbarkeit von Informationen, sondern intervenieren gezielt in Entscheidungskontexte, indem sie durch personalisierte Informationsangebote, priorisierte Rankings und verhaltensbasierte Bewertungen die Handlungsoptionen der Nutzer präformieren.¹⁹²¹⁹³ Digitale Informationssysteme mit Monitoring-Funktion operieren

¹⁸⁴ Vgl. Isaak & Hanna(2018), S. 56-57.

¹⁸⁵ Vgl. Zuboff(2019), S. 278.

¹⁸⁶ Vgl. Susser, Roessler & Nissenbaum(2019), S. 38.

¹⁸⁷ Vgl. Zuboff(2019), S. 278.

¹⁸⁸ Vgl. Yeung(2017), S. 122.

¹⁸⁹ Vgl. Cinelli u. a.(2021), S. 1, 5–6.

¹⁹⁰ Vgl. Narayanan(2023), S. 4–6.

¹⁹¹ Vgl. Yeung(2017), S. 122.

¹⁹² Vgl. Yeung(2017), S. 118, 121.

¹⁹³ Vgl. Gillespie(2014), S. 183–184.

folglich nicht als neutrale Vermittler, sondern als soziotechnische Steuerungsarchitekturen, die durch algorithmische Entscheidungslogiken die digitale Informationsumgebung aktiv konstituieren und menschliches Verhalten systematisch beeinflussen.

3.3 Vergleich unterschiedlicher Systemlogiken

Die Funktionsweise KI-gestützter Monitoring-Systeme folgt je nach politischem und ökonomischem Rahmen unterschiedlichen Logiken, die jedoch auf einer gemeinsamen technologischen Basis der massenhaften Datenauswertung beruhen. Während westliche Systeme primär marktgesteuerten Akkumulationszielen folgen, zielen staatlich integrierte Systeme auf die Steuerung gesellschaftlicher Compliance ab.

3.3.1 Plattformzentrierte Systeme westlicher Plattformunternehmen

In westlich geprägten Wirtschaftsräumen operieren digitale Informationssysteme mit Monitoring-Funktion innerhalb einer Logik, die als Überwachungskapitalismus beschrieben wird und in der menschliche Erfahrung als kostenloses Rohmaterial für die systematische Extraktion von Verhaltensdaten dient.¹⁹⁴ Plattformunternehmen wie Google, Meta (Facebook), YouTube, TikTok und Amazon fungieren hierbei als zentrale Betreiber digitaler Informationssysteme, deren technische Infrastrukturen darauf ausgelegt sind, einen kontinuierlichen Fluss an Verhaltensüberschüssen zu erfassen und zu verarbeiten.¹⁹⁵¹⁹⁶ Diese Systeme nutzen Algorithmen zur Personalisierung, um Informationsumgebungen so zu gestalten, dass sie die individuelle Relevanz maximieren und dadurch die Verweildauer sowie die Interaktionsrate erhöhen.¹⁹⁷¹⁹⁸

Die zentralen Ziele dieser plattformzentrierten Monitoring-Logik sind Interaktion, Wachstum und Monetarisierung. Die Interaktionsprognose, also die Vorhersage der Interaktionswahrscheinlichkeit, bildet den Kern der algorithmischen Steuerung, da ein engagierter Nutzer häufiger zur Plattform zurückkehrt und somit mehr Werbeeinnahmen generiert.¹⁹⁹ Netzwerkeffekte verstärken diesen Prozess, da ein steigendes Nutzeraufkommen den Wert der Plattform erhöht und noch umfassendere Datensammlungen ermöglicht, was wiederum die Vorhersagekraft der Algorithmen für Werbetreibende verbessert.²⁰⁰²⁰¹ Diese ökonomische Dynamik führt zur Entstehung von „berechneten Öffentlichkeiten“, in denen Ranking-Algorithmen die Sichtbarkeit von Inhalten nach kommerziellen Kriterien priorisieren, was oft zu einer Verengung des Informationshorizonts in Form von Filterblasen führt.²⁰² Die Konsequenz dieser Logik ist eine instrumentelle Macht, die das Verhal-

¹⁹⁴ Vgl. Zuboff(2019), S. 69.

¹⁹⁵ Vgl. Srnicek(2017), S. 27.

¹⁹⁶ Vgl. Parker, Van Alstyne & Choudary(2016), S. 8.

¹⁹⁷ Vgl. Pariser(2011), S. 1.

¹⁹⁸ Vgl. Adomavicius & Tuzhilin(2005), S. 734.

¹⁹⁹ Vgl. Narayanan(2023), S. 8–9.

²⁰⁰ Vgl. Srnicek(2017), S. 27.

²⁰¹ Vgl. Parker, Van Alstyne & Choudary(2016), S. 17.

²⁰² Vgl. Gillespie(2014), S. 168.

ten der Nutzer nicht durch Zwang, sondern durch subtile algorithmische Anstöße und psychologische Trigger im Sinne der Plattformökonomie optimiert.²⁰³

3.3.2 Staatlich integrierte Monitoring-Systeme

Staatlich integrierte Monitoring-Systeme, wie sie insbesondere in China entwickelt werden, nutzen dieselben technologischen Werkzeuge wie westliche Plattformen, jedoch unter einer fundamental anderen Zwecksetzung: der Sicherung von Compliance und staatlicher Governance. Das Herzstück dieser Entwicklung ist das Social Credit System (SCS), das darauf abzielt, durch die Integration von Regierungsdaten und privaten Informationen ein umfassendes Maß an „Aufrichtigkeit“ in wirtschaftlichen, sozialen und politischen Belangen zu erzwingen.²⁰⁴ Dieses System fungiert als kybernetischer Regelkreis, der Verhalten durch ein System von Belohnungen und Bestrafungen (Joint Punishment System) steuert, wobei Regelverstöße in einem Bereich zu Einschränkungen in allen Lebensbereichen führen können.^{205 206}

Technologisch stützt sich dieser digitale Autoritarismus auf eine omnipräsente Überwachungsinfrastruktur, die Künstliche Intelligenz mit massiven Videonetzwerken wie dem „Skynet“- oder „Sharp Eyes“-Projekt kombiniert.^{207 208} Regierungsbehörden setzen Verfahren wie Gesichtserkennung, Biometrie und Big-Data-Analysen ein, um Individuen in Echtzeit zu identifizieren, zu klassifizieren und Profile zu erstellen, die eine prädiktive Überwachung ermöglichen.²⁰⁹ Im Bereich des Smart Policing erlaubt die „Integrated Joint Operations Platform“ (IJOP) die Aggregation verschiedenster Datenquellen, um verdächtige Verhaltensmuster automatisiert zu erkennen und präventive polizeiliche Maßnahmen einzuleiten.^{210 211} Diese Form der algorithmischen Governance zielt darauf ab, gesellschaftliche Risiken zu minimieren und die Stabilität des Regimes durch eine lückenlose Erfassung des Bürgerverhaltens sicherzustellen.²¹²

3.3.3 Vergleich westlicher Plattformlogiken und staatlicher Monitoring-Systeme

Sowohl kommerzielle Plattformen als auch staatlich integrierte Systeme operieren als digitale Informationssysteme mit Monitoring-Funktion, deren technologische Architektur auf denselben Grundprinzipien der Datenerfassung, Datenverarbeitung, algorithmischen Bewertung und systemischen Rückkopplung beruht.^{213 214} Der wesentliche Unterschied

²⁰³ Vgl. Zuboff(2019), S. 69.

²⁰⁴ Vgl. Creemers(2018), S. 2–3, 8.

²⁰⁵ Vgl. Creemers(2018), S. 3–4, 13–15.

²⁰⁶ Vgl. Qiang(2019), S. 5.

²⁰⁷ Vgl. Qiang(2019), S. 5.

²⁰⁸ Vgl. U.S.-China Economic and Security Review Commission(2020), S. 1.

²⁰⁹ Vgl. Qiang(2019), S. 5.

²¹⁰ Vgl. U.S.-China Economic and Security Review Commission(2020), S. 4.

²¹¹ Vgl. Qiang(2019), S. 5.

²¹² Vgl. Creemers(2018), S. 1–2, 26–28.

²¹³ Vgl. U.S.-China Economic and Security Review Commission(2020), S. 4.

²¹⁴ Vgl. Zuboff(2019), S. 389.

besteht nicht in der technischen Funktionsweise dieser Informationssysteme, sondern in deren primärer Zwecksetzung: Während kommerzielle Plattformen die erfassten Verhaltensdaten nutzen, um Interaktion, Aufmerksamkeit und letztlich Monetarisierung zu optimieren, zielen staatliche Monitoring-Systeme auf die Sicherstellung von Compliance, sozialer Kontrolle und administrativer Governance ab.²¹⁵²¹⁶ Beide Systemvarianten transformieren jedoch menschliches Verhalten in quantifizierbare Datenströme, verdichten diese zu Nutzerprofilen und nutzen algorithmische Entscheidungslogiken, um durch gezielte Interventionen – sei es in Form personalisierter Inhalte oder automatisierter Sanktionsmechanismen – Verhalten zu steuern. Die strukturelle Konvergenz digitaler Informationssysteme mit Monitoring-Funktion verdeutlicht, dass die Grenze zwischen ökonomischer und staatlicher Überwachung zunehmend verschwimmt und beide Formen letztlich auf einer gemeinsamen soziotechnischen Infrastruktur der Verhaltens Erfassung und -beeinflussung basieren.²¹⁷

Ein Vergleich westlicher plattformzentrierter Systeme mit staatlich integrierten Monitoring-Systemen offenbart eine technologische Konvergenz bei gleichzeitiger Divergenz der zugrunde liegenden Governance-Strukturen. Beide Systemtypen basieren auf der massenhaften Sammlung digitaler Fußabdrücke und deren Transformation in automatisierte Scoring- und Klassifikationssysteme, sei es zur Ermittlung der Kreditwürdigkeit (e-Scores) oder der sozialen Vertrauenswürdigkeit (Social Credit).²¹⁸²¹⁹ Ebenso nutzen beide Seiten Mechanismen der Verhaltensmodifikation; während westliche Plattformen Nutzer durch Anstöße zu Konsumhandlungen bewegen, setzen staatliche Systeme auf eine offene Paternalisierung zur Einübung staatsbürgerlicher Tugenden.²²⁰²²¹

Die wesentlichen Unterschiede liegen in den Zielsetzungen und den Adressaten der Systeme. Westliche Logiken sind auf Interaktion vs. Compliance ausgerichtet: Das Ziel ist die Maximierung der Nutzeraktivität zur Monetarisierung von Aufmerksamkeit in einer Werbeökonomie, während staatliche Systeme auf die Einhaltung von Normen und Gesetzen zielen.²²² Dies spiegelt sich im Gegensatz von Wachstum vs. Governance wider; Plattformen streben nach globaler Expansion durch Netzwerkeffekte, wohingegen staatliches Monitoring der administrativen Effizienz und Risikokontrolle dient.²²³²²⁴ Der Adressat wird entsprechend unterschiedlich konstruiert: als Nutzer (Konsument/Datenquelle) im Westen und als Bürger im staatlich integrierten Modell.²²⁵²²⁶

²¹⁵Vgl. Creemers(2018), S. 25–28.

²¹⁶Vgl. Zuboff(2019), S. 8.

²¹⁷Vgl. Lyon(2012), S. 3–5.

²¹⁸Vgl. Pasquale(2015), S. 19.

²¹⁹Vgl. Creemers(2018), S. 19–22, 27.

²²⁰Vgl. Zuboff(2019), S. 16.

²²¹Vgl. Creemers(2018), S. 26.

²²²Vgl. Narayanan(2023), S. 18–19, 35.

²²³Vgl. Srnicek(2017), S. 27.

²²⁴Vgl. U.S.-China Economic and Security Review Commission(2020), S. 1.

²²⁵Vgl. Zuboff(2019), S. 71.

²²⁶Vgl. U.S.-China Economic and Security Review Commission(2020), S. 1.

Ein weiterer markanter Unterschied besteht in der Form der Überwachung und Transparenz. Westliche Systeme operieren oft als Schwarze Kästen, deren proprietäre Algorithmen geheim gehalten werden, um Wettbewerbsvorteile zu sichern.²²⁷ Im Gegensatz dazu strebt das chinesische Modell eine Form der radikalen Transparenz an, bei der Informationen über die Vertrauenswürdigkeit von Individuen und Unternehmen teilweise öffentlich bekannt gemacht werden, um den sozialen Druck zur Konformität zu erhöhen.²²⁸ Dennoch verschwimmen die Grenzen zusehends, da westliche Sicherheitsbehörden verstärkt auf die Datenbestände privater Plattformen zugreifen, während staatliche Systeme zunehmend Daten aus dem Privatsektor integrieren, was zu einem hybriden Überwachungskontext führt, in dem ökonomische und staatliche Steuerungslogiken ineinandergreifen.²²⁹

²²⁷ Vgl. Pasquale(2015), S. 19.

²²⁸ Vgl. Creemers(2018), S. 13-15.

²²⁹ Vgl. Creemers(2018), S. 17ff..

4 Sozioökonomische und gesellschaftliche Implikationen

Die im vorangegangenen Kapitel dargelegten technologischen Funktionsweisen und Systemlogiken KI-gestützter Monitoring-Systeme bilden die Grundlage für eine weitreichende Transformation gesellschaftlicher und ökonomischer Strukturen. Während Kapitel 3 den Fokus auf die technische Realisierung der Datenerfassung und algorithmischen Verarbeitung legte, widmet sich das folgende Kapitel den daraus resultierenden Konsequenzen für das Individuum und die Gemeinschaft. In der modernen Informationsgesellschaft fungieren Monitoring-Systeme nicht mehr lediglich als passive Instrumente der Datenverarbeitung, sondern als aktive Gestalter digitaler Informationsumgebungen, die zunehmend Einfluss auf politische, soziale und wirtschaftliche Prozesse nehmen.²³⁰

Der Kern dieser Entwicklung liegt in der wachsenden Bedeutung von Verhaltensdaten, die im Kontext des sogenannten Überwachungskapitalismus als strategische Ressource für die Extraktion von Verhaltensüberschüssen dienen.²³¹²³² Durch den Prozess der Datafizierung werden ehemals private Aspekte des menschlichen Lebens in quantifizierbare Datenströme übersetzt, was eine kontinuierliche Überwachung und prädiktive Analyse ermöglicht.²³³ Diese Systeme streben dabei eine Neuausrichtung von reinem Wissen hin zur Ausübung von Macht an: Es genügt nicht mehr, Informationsflüsse über Individuen zu automatisieren; das Ziel besteht zunehmend darin, das Verhalten der Nutzer selbst in großem Maßstab zu formen und zu automatisieren.²³⁴ Diese Verschiebung markiert den Aufstieg einer instrumentellen Macht, die durch eine allgegenwärtige rechnergestützte Architektur das menschliche Handeln auf die Ziele dritter Akteure hin ausrichtet.²³⁵

Dabei erweisen sich KI-gestützte Systeme als „zweischneidige Schwerter“, die je nach Anwendung und Governance sowohl erhebliche Chancen als auch tiefgreifende Risiken bergen.²³⁶ Einerseits bieten sie das Potenzial, drängende gesellschaftliche Herausforderungen in Bereichen wie Gesundheit, Klimaschutz oder öffentlicher Verwaltung effizienter zu bewältigen und das menschliche Wohlergehen zu fördern.²³⁷ Andererseits führen dieselben Mechanismen der Personalisierung, des Rankings und Scorings zu kritischen Bedenken hinsichtlich der menschlichen Autonomie, der informationellen Selbstbestimmung und der Stabilität demokratischer Diskurse.²³⁸²³⁹²⁴⁰ Die algorithmische Autorität, die oft hinter

²³⁰ Vgl. Pasquale(2015), S. 19.

²³¹ Vgl. Zuboff(2019), S. 69.

²³² Vgl. OECD(2013), S. 4, 10, 14.

²³³ Vgl. Dijck(2014), S. 1.

²³⁴ Vgl. Zuboff(2019), S. 69 ff..

²³⁵ Vgl. Zuboff(2019), S. 59.

²³⁶ Vgl. Cusumano, Gawer & Yoffie(2019), S. 159.

²³⁷ Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 19.

²³⁸ Vgl. Zuboff(2019), S. 15.

²³⁹ Vgl. O’Neil(2016), S. 145.

²⁴⁰ Vgl. Pasquale(2015), S. 19.

undurchsichtigen „Schwarzen Kästen“ verborgen bleibt, schafft asymmetrische Machtverhältnisse zwischen Plattformbetreibern und Nutzern, die herkömmliche Regulierungs- und Kontrollmechanismen vor massive Herausforderungen stellt.^{241 242}

4.1 Auswirkungen auf digitale Informationsumgebungen

Die Integration von KI-gestützten Monitoring-, Empfehlungs- und Ranking-Systemen hat zu einer fundamentalen Transformation digitaler Informationsumgebungen geführt. Diese Umgebungen fungieren nicht länger als neutrale Infrastrukturen für den Datenaustausch, sondern haben sich zu aktiven, kuratierten Räumen entwickelt, in denen die Verfügbarkeit und Wahrnehmung von Informationen durch algorithmische Logiken präfiguriert werden.²⁴³ In der Wirtschaftsinformatik wird dieser Wandel als Übergang zu datengetriebenen Informationsökosystemen verstanden, in denen die Grenze zwischen technologischer Vermittlung und sozialer Realität zunehmend verschwimmt.²⁴⁴

Mechanismen der algorithmischen Transformation Der Prozess der Transformation beginnt mit der systematischen Datafizierung menschlicher Interaktionen. Plattformen übersetzen jede Online-Aktivität – von Klickmustern und Verweildauern bis hin zu sozialen Verknüpfungen – in quantifizierbare Metadaten.²⁴⁵ Diese Erfassung von „digitalen Fußabdrücken“ bildet das Rohmaterial für die Erstellung hochgradig detaillierter Nutzungsprofile.²⁴⁶ Gillespie (2014) beschreibt diesen Vorgang als Vorbereitung der Daten für den algorithmischen Zugriff, wobei komplexe Informationen in maschinenlesbare Kategorien formalisiert werden müssen. Solche Profile dienen als Grundlage für „Zyklen der Antizipation“, in denen Plattformbetreiber versuchen, die Bedürfnisse und das zukünftige Verhalten ihrer Nutzer präzise vorherzusagen.²⁴⁷

Auf Basis dieser Profile operieren algorithmische Selektions- und Empfehlungsmechanismen. Der technologische Kern moderner Plattformen wie TikTok, Facebook oder YouTube ist die Interaktionsprognose.²⁴⁸ Diese Systeme berechnen die Wahrscheinlichkeit, mit der ein Nutzer mit einem bestimmten Inhalt interagieren wird, um aus einer nahezu unendlichen Menge an Informationen eine personalisierte Auswahl zu treffen.²⁴⁹ Ziel dieser Mechanismen ist es primär, die Informationsüberlastung (Information Overload) zu bewältigen, indem Relevanz nicht mehr absolut, sondern als individuelle Korrelation definiert wird.²⁵⁰

²⁴¹ Vgl. Pasquale(2015), S. 19.

²⁴² Vgl. Acquisti, Brandimarte & Loewenstein(2016), S. 448.

²⁴³ Vgl. Gillespie(2014), S. 179–182.

²⁴⁴ Vgl. Dijck(2014), S. 1.

²⁴⁵ Vgl. Dijck(2014), S. 1.

²⁴⁶ Vgl. Kitchin(2014), S. 722.

²⁴⁷ Vgl. Gillespie(2014), S. 173–177.

²⁴⁸ Vgl. Narayanan(2023), S. 18–21.

²⁴⁹ Vgl. Areeb u. a.(2023), S. 1–2.

²⁵⁰ Vgl. Areeb u. a.(2023), S. 1.

Die strukturelle Ordnung dieser Auswahl wird durch Ranking- und Filterprozesse festgelegt. Algorithmen zur Priorisierung bestimmen die hierarchische Position von Informationen in Feeds oder Suchergebnissen und steuern damit maßgeblich die Sichtbarkeit von Inhalten. Diese „Public Relevance Algorithms“ besitzen die Macht, Wissen nach spezifischen, oft proprietären Kriterien zu zertifizieren und so die Regeln für die Teilnahme am öffentlichen Diskurs festzulegen. Der Zugriff auf Inhalte wird somit durch die Plattform mediiert, wobei algorithmische Torwächter die traditionelle redaktionelle Logik menschlicher Experten weitgehend ersetzen.²⁵¹

Konsequenzen für die Informationsumgebung Diese technologischen Mechanismen führen zu einer tiefgreifenden Individualisierung der Informationsumgebungen. Pariser (2011) prägte hierfür den Begriff der Filterblase (Filter Bubble), in der die algorithmische Selektion dazu führt, dass Individuen primär mit Inhalten konfrontiert werden, die ihren bestehenden Überzeugungen entsprechen.²⁵² Diese Form der algorithmischen Zugangskontrolle schafft eine ungleiche Sichtbarkeit von Informationen, da interaktionsstarke, oft emotionale oder polarisierende Inhalte algorithmisch bevorzugt werden, während dissonante oder komplexe Perspektiven aus dem Aufmerksamkeitsfokus verdrängt werden.²⁵³

In der wissenschaftlichen Debatte werden diese Phänomene häufig mit dem Konzept der Echokammern verknüpft. Während Filterblasen als Resultat algorithmischer Filterung verstanden werden, beschreiben Echokammern homophile Cluster in sozialen Netzwerken, in denen sich Nutzer mit Gleichgesinnten um eine geteilte Erzählung gruppieren.²⁵⁴ Dies kann zu einer Informationsfragmentierung führen, bei der die Grundlage für einen gemeinsamen öffentlichen Diskurs erodiert, da Nutzer unterschiedliche Versionen der Realität wahrnehmen.²⁵⁵ Pasquale (2015) betont in diesem Kontext die wachsende Informationsasymmetrie und Opazität: Die algorithmischen Entscheidungsprozesse operieren oft als „Schwarze Kästen“, deren Kriterien für den Nutzer und selbst für externe Experten undurchsichtig bleiben.²⁵⁶

Die empirische Forschung mahnt jedoch zur Differenzierung und warnt vor einer rein technologisch-deterministischen Sichtweise. Areeb et al. (2023) stellen fest, dass Filterblasen zwar experimentell nachweisbar sind, ihre Auswirkungen jedoch stark vom Design der Empfehlungssysteme abhängen.²⁵⁷ Cinelli et al. (2021) zeigen auf, dass die Entstehung von Echokammern maßgeblich von der Plattformarchitektur beeinflusst wird: Während Facebook und Twitter durch ihre Netzwerkstrukturen die Bildung homophiler Cluster begünstigen, weisen Plattformen wie Reddit eine höhere Integration unterschiedlicher

²⁵¹ Vgl. Gillespie(2014), S. 168, 175–177, 191–193.

²⁵² Vgl. Pariser(2011), S. 1.

²⁵³ Vgl. Narayanan(2023), S. 31–36.

²⁵⁴ Vgl. Cinelli u. a.(2021), S. 1, 3–5.

²⁵⁵ Vgl. Gillespie(2014), S. 188–189.

²⁵⁶ Vgl. Pasquale(2015), S. 4.

²⁵⁷ Vgl. Areeb u. a.(2023), S. 7–9, 17.

Meinungen innerhalb von Interessengemeinschaften auf. Dies deutet darauf hin, dass nicht der Algorithmus allein, sondern das Zusammenspiel aus technologischer Struktur und sozialer Dynamik entscheidend ist.²⁵⁸

Zudem belegen Studien von Kelm et al. (2023), dass die algorithmische Selektion politische Polarisierung zwar geringfügig beeinflussen kann, die Voreinstellungen der Nutzer und ihr aktives Selektionsverhalten jedoch oft eine deutlich stärkere Wirkung entfalten. In ihren Experimenten verstärkten algorithmisch ausgewählte Argumente die bestehenden Einstellungen nur minimal stärker als zufällig ausgewählte Argumente, was die Annahme einer automatischen Radikalisierung durch Algorithmen relativiert.²⁵⁹ Es muss daher präzise zwischen dem Einfluss der Algorithmen, den Strukturen der sozialen Netzwerke und der individuellen Wahlentscheidung differenziert werden, wobei alle drei Faktoren in komplexen Feedback-Schleifen interagieren.²⁶⁰

Zusammenfassend lässt sich festhalten, dass KI-gestützte Monitoring-Systeme die digitale Informationswelt von einem explorativen zu einem prädiktiv strukturierten Raum transformieren. Die strukturelle Veränderung der Informationsumgebung bildet den Rahmen, innerhalb dessen sich individuelle Wahrnehmungs- und Entscheidungsprozesse vollziehen. Die daraus resultierende Verschiebung der Informationsasymmetrien zugunsten der Plattformbetreiber erschwert es Individuen, die Verzerrungen ihrer eigenen Informationsumgebung zu erkennen.²⁶¹

4.2 Verhaltensdynamiken und Personalisierungseffekte

Die Transformation digitaler Informationsumgebungen durch KI-gestützte Monitoring-Systeme findet ihre Fortsetzung in der gezielten Beeinflussung individueller Verhaltensdynamiken. In der Wirtschaftsinformatik und Psychologie wird dieser Prozess als Übergang von einer rein informativen Unterstützung hin zu einer aktiven Verhaltenssteuerung verstanden, die menschliche Entscheidungsprozesse proaktiv gestaltet.²⁶² Während die strukturelle Ebene den Rahmen setzt, operieren auf der psychologischen Ebene Mechanismen, die darauf ausgerichtet sind, Nutzer durch datenbasierte Adaptation, Empfehlungen und Feedback-Schleifen in ihren Handlungen zu lenken.²⁶³

Mechanismen der personalisierten Verhaltenssteuerung Der grundlegende Mechanismus dieser Steuerung beruht auf der kontinuierlichen Erfassung und Analyse von Verhaltensdaten, die in hochpräzise Nutzungsprofile überführt werden.²⁶⁴ Diese Profile ermöglichen es Systemen, die individuelle Empfänglichkeit eines Nutzers gegenüber

²⁵⁸ Vgl. Cinelli u. a. (2021), S. 1–3, 5–7.

²⁵⁹ Vgl. Kelm, Dohle & Bernhard (2023), S. 3, 6–7.

²⁶⁰ Vgl. Metzler & Garcia (2023), S. 735–736.

²⁶¹ Vgl. Pasquale (2015), S. 19.

²⁶² Vgl. Susser, Roessler & Nissenbaum (2019), S. 1.

²⁶³ Vgl. Zuboff (2019), S. 69.

²⁶⁴ Vgl. Susser, Roessler & Nissenbaum (2019), S. 1.

verschiedenen Überzeugungsstrategien einzuschätzen, ein Konzept, das als „Überzeugungsprofilerstellung“ bezeichnet wird.²⁶⁵ Persuasion Profiles sind Sammlungen von Schätzungen über die erwarteten Effekte verschiedener Einflussprinzipien für ein spezifisches Individuum.²⁶⁶ Diese Profile werden durch automatisierte Prozesse laufend aktualisiert, wobei jede Nutzerreaktion auf einen digitalen Stimulus als Feedback-Signal dient, um die Vorhersagegenauigkeit des Systems zu optimieren.²⁶⁷

Die technologische Basis für diese iterative Optimierung bilden oft Verfahren des bestärkenden Lernens (Reinforcement Learning), bei denen ein System lernt, jene Aktionen zu wählen, die eine maximale Belohnung – in diesem Kontext meist Nutzer-Interaktion – versprechen.²⁶⁸ Dabei werden Belohnungssignale genutzt, um die interne Strategie (Policy) des Systems so anzupassen, dass zukünftige Reize exakter auf die psychologischen Trigger des Nutzers abgestimmt sind.²⁶⁹ Dieser Prozess schafft geschlossene Rückkopplungsschleifen, in denen das System nicht nur das Verhalten misst, sondern durch die Auswahl der präsentierten Inhalte aktiv die Wahrscheinlichkeit zukünftiger Handlungen erhöht.²⁷⁰

Ein wesentliches Element der gestalterischen Umsetzung ist das „Verhaltensdesign“, welches psychologische Modelle wie das Fogg Behavior Model (FBM) operationalisiert. Nach diesem Modell ist ein Verhalten das Produkt aus drei gleichzeitig auftretenden Faktoren: Motivation, Fähigkeit (Ability) und einem Auslöser (Trigger). Digitale Systeme nutzen diese Erkenntnisse, um durch zeitlich und inhaltlich präzise platzierte Trigger Handlungen zu automatisieren.²⁷¹ Wenn diese Trigger durch Big-Data-Analysen und Echtzeit-Monitoring gesteuert werden, entsteht eine Form der dynamischen Regulierung, die als „Hyper-Anstöße“ bezeichnet wird.²⁷² Im Gegensatz zu statischen Anstößen passen sich Hyper-Anstöße adaptiv an den aktuellen Kontext und die spezifischen Schwachstellen des Nutzers an, was ihre Effektivität massiv erhöht.²⁷³

Konsequenzen und Auswirkungen auf das Nutzerverhalten Die Anwendung dieser Mechanismen führt zu Veränderungen in der Aufmerksamkeit und im Informationskonsum der Nutzer. Durch die algorithmische Priorisierung von Inhalten, die eine hohe Interaktionswahrscheinlichkeit versprechen, werden bestehende Gewohnheiten und Präferenzen systematisch verstärkt. Nutzer geraten dabei in Feedback-Schleifen, in denen das vergangene Verhalten die zukünftigen Möglichkeiten determiniert.²⁷⁴ Diese Form der Habitualisierung kann dazu führen, dass die Erkundung neuer Informationen abnimmt und

²⁶⁵ Vgl. Kaptein, Markopoulos, Ruyter & Aarts(2015), S. 41.

²⁶⁶ Vgl. Kaptein, Markopoulos, Ruyter & Aarts(2015), S. 41.

²⁶⁷ Vgl. Kaptein, Markopoulos, Ruyter & Aarts(2015), S. 41, 45.

²⁶⁸ Vgl. Sutton & Barto(2018), S. 1.

²⁶⁹ Vgl. Sutton & Barto(2018), S. 46.

²⁷⁰ Vgl. Metzler & Garcia(2023), S. 735–736.

²⁷¹ Vgl. Fogg(2009), S. 1, 3, 4, 7.

²⁷² Vgl. Yeung(2017), S. 118.

²⁷³ Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

²⁷⁴ Vgl. Narayanan(2023), S. 7–10, 20–23, 35–36.

eine passive Konsumhaltung begünstigt wird.²⁷⁵

Darüber hinaus belegen Studien die Möglichkeit einer emotionalen Beeinflussung durch digital kuratierte Umgebungen. Das Experiment zur emotionalen Ansteckung (Emotional Contagion) auf Facebook demonstrierte, dass bereits geringfügige Änderungen in der emotionalen Gewichtung des News Feeds ausreichen, um die Stimmungslage und das eigene Posting-Verhalten von Millionen von Nutzern messbar zu verändern.²⁷⁶ Solche subliminalen Reize können die individuelle Autonomie beeinträchtigen, da sie jenseits der Schwelle bewusster Wahrnehmung operieren und die Fähigkeit zur selbstbestimmten emotionalen Regulation stören.²⁷⁷

In diesem Zusammenhang ist eine klare Differenzierung zwischen Persuasion, Einfluss und Manipulation notwendig.²⁷⁸ Während Persuasion als offener Appell an die rationale Entscheidungsfähigkeit verstanden wird, kennzeichnet Manipulation einen verdeckten Einfluss, der die Entscheidungsgewalt des Individuums untergräbt.²⁷⁹ Manipulative Praktiken zeichnen sich dadurch aus, dass sie kognitive oder emotionale Schwachstellen gezielt ausbeuten, um den Nutzer zu Handlungen zu bewegen, die primär den Zielen des Systembetreibers dienen.²⁸⁰ Die Verdecktheit des Einflusses ist hierbei das entscheidende Kriterium: Der Nutzer fühlt sich zwar als Autor seiner Handlungen, folgt jedoch einer technologisch präfigurierten Wahlarchitektur.²⁸¹

Die Auswirkungen dieser Dynamiken variieren jedoch zwischen verschiedenen Nutzergruppen, wobei insbesondere Jugendliche oft als vulnerable Zielgruppe thematisiert werden. Specification Curve Analysen von Orben und Przybylski zeigen jedoch, dass der Zusammenhang zwischen Technologienutzung und psychischem Wohlbefinden bei Jugendlichen insgesamt sehr gering ist und höchstens 0,4 % der Varianz erklärt. Diese Effekte sind im Vergleich zu anderen Faktoren wie Schlafmangel oder Mobbing als klein einzustufen.²⁸² Dennoch bleibt die Anfälligkeit für sozialen Vergleich und die Suche nach Bestätigung ein Faktor, der durch algorithmische Feedback-Signale verstärkt werden kann.²⁸³

Zusammenfassend lässt sich festhalten, dass Personalisierung weit über die bloße Anpassung an Nutzerpräferenzen hinausgeht. Durch die Kombination von kontinuierlichem Monitoring, psychologischem Profiling und adaptiven Trigger-Mechanismen werden Architekturen geschaffen, die Verhaltensmuster aktiv formen.²⁸⁴ Diese Verhaltensdynamiken bilden den Kern einer neuen Form der Machtausübung, deren Effektivität direkt mit der

²⁷⁵ Vgl. Zuboff(2019), S. 298.

²⁷⁶ Vgl. Kramer, Guillory & Hancock(2014), S. 8788–8790.

²⁷⁷ Vgl. Susser, Roessler & Nissenbaum(2019), S. 16.

²⁷⁸ Vgl. Susser, Roessler & Nissenbaum(2019), S. 2.

²⁷⁹ Vgl. Susser, Roessler & Nissenbaum(2019), S. 3.

²⁸⁰ Vgl. Susser, Roessler & Nissenbaum(2019), S. 26.

²⁸¹ Vgl. Susser, Roessler & Nissenbaum(2019), S. 28.

²⁸² Vgl. Orben & Przybylski(2019), S. 2–3, 16.

²⁸³ Vgl. Metzler & Garcia(2023), S. 736, 738.

²⁸⁴ Vgl. Zuboff(2019), S. 283.

Undurchsichtigkeit der zugrunde liegenden Logiken korreliert.²⁸⁵

4.3 Ökonomische Interessen und Plattformlogiken

Die ökonomische Dimension KI-gestützter Monitoring-Systeme verdeutlicht, dass diese nicht lediglich technologische Infrastrukturen darstellen, sondern das Fundament neuartiger Geschäftsmodelle bilden, die Verhaltensdaten, Nutzeraufmerksamkeit und Vorhersagewissen systematisch in ökonomischen Wert transformieren.²⁸⁶²⁸⁷ In der modernen Plattformökonomie fungieren digitale Informationssysteme als extraktive Apparate, deren primärer Zweck in der Erfassung und Verwertung von Daten als strategische Ressource liegt.²⁸⁸ Dieser Abschnitt erläutert die ökonomischen Mechanismen dieser Transformation sowie die daraus resultierenden strukturellen Konsequenzen für Märkte und Individuen.

Ökonomische Mechanismen der Datenverwertung Der Kern dieser ökonomischen Logik liegt in der Transformation menschlicher Erfahrung in Verhaltensdaten, ein Prozess, den Zuboff (2019) als Grundlage des Überwachungskapitalismus beschreibt.²⁸⁹ Dabei wird ein „Verhaltensüberschuss“ (Behavioral Surplus) generiert, der über die für die bloße Serviceverbesserung notwendigen Daten hinausgeht und als Rohmaterial für die Herstellung von Vorhersageprodukten dient.²⁹⁰ Diese Daten fungieren im 21. Jahrhundert ähnlich wie das Öl im Industriezeitalter: Sie müssen extrahiert, raffiniert und in verschiedenen wertschöpfenden Prozessen eingesetzt werden.²⁹¹ Die Datafizierung ermöglicht es dabei, ehemals wertlose Nebenprodukte digitaler Dienste in wertvolle Ressourcen zu verwandeln, die Aufschluss über Präferenzen, Stimmungen und zukünftige Absichten der Nutzer geben.²⁹²

Die ökonomische Überlegenheit moderner Plattformen basiert maßgeblich auf dem Masterplan von Analytik und Vorhersagefähigkeiten. Unternehmen, die „auf Basis von Analysen konkurrieren“ (Competing on Analytics), nutzen komplexe statistische Modelle und maschinelles Lernen, um jeden Aspekt ihrer Geschäftsprozesse zu optimieren und individuelle Kundenbedürfnisse mit mathematischer Präzision vorherzusagen.²⁹³ Datengetriebene Wettbewerbsvorteile entstehen hierbei durch geschlossene Feedback-Schleifen: Je mehr Daten eine Plattform sammelt, desto besser werden ihre Algorithmen, was wiederum mehr Nutzer anzieht und den Wert der Vorhersageprodukte für Werbetreibende erhöht.²⁹⁴²⁹⁵

²⁸⁵ Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

²⁸⁶ Vgl. Srnicek(2017), S. 18.

²⁸⁷ Vgl. Zuboff(2019), S. 69.

²⁸⁸ Vgl. Srnicek(2017), S. 21.

²⁸⁹ Vgl. Zuboff(2019), S. 69.

²⁹⁰ Vgl. Zuboff(2019), S. 69.

²⁹¹ Vgl. Srnicek(2017), S. 18.

²⁹² Vgl. Dijck(2014), S. 1.

²⁹³ Vgl. Davenport(2006), S. 2–4.

²⁹⁴ Vgl. Parker, Van Alstyne & Choudary(2016), S. 5.

²⁹⁵ Vgl. Cusumano, Gawer & Yoffie(2019), S. 50–51.

Die strukturelle Basis hierfür bilden Plattformökosysteme, die als mehrseitige Märkte (Multi-sided Markets) fungieren und Interaktionen zwischen verschiedenen Gruppen wie Nutzern, Werbetreibenden und Drittanbietern koordinieren.²⁹⁶²⁹⁷ Ein entscheidendes Merkmal sind Netzwerkeffekte, bei denen der Nutzen der Plattform für einen Teilnehmer mit der Anzahl der Nutzer auf der anderen Seite des Marktes steigt.²⁹⁸ Um diese Effekte zu maximieren, setzen Plattformen häufig auf Strategien der Quersubventionierung, bei denen Dienste für Nutzer kostenlos angeboten werden, um eine kritische Masse zu erreichen, während die Monetarisierung über die Werbeindustrie oder den Verkauf von Daten erfolgt.²⁹⁹³⁰⁰ In dieser Logik werden Metadaten zur „Währung“, mit der Bürger für Kommunikationsdienste und Bequemlichkeit bezahlen.³⁰¹

Konsequenzen der Plattformdominanz Die beschriebenen Mechanismen führen zu einer massiven Konzentration von Marktmacht. Netzwerkeffekte und geringe Grenzkosten begünstigen „Winner-take-all“- oder „Winner-take-most“-Dynamiken, in denen wenige dominante Akteure wie Alphabet, Amazon oder Meta den Markt kontrollieren.³⁰²³⁰³ Dies schafft eine tiefe Abhängigkeit von Nutzern und Komplementoren (z. B. App-Entwicklern), da die Plattformbesitzer als zentrale Torwächter fungieren, welche die Regeln des Ökosystems und die Verteilung der Wertschöpfung einseitig festlegen.³⁰⁴³⁰⁵

Ein kritisches Resultat dieser Dominanz sind tiefgreifende Informationsasymmetrien zwischen Plattformen und Individuen. Während die Betreiber durch die Aggregation massiver Datensätze über ein nahezu „perfektes Gedächtnis“ verfügen, bleibt die Funktionsweise ihrer Entscheidungslogiken für den Einzelnen undurchsichtig.³⁰⁶³⁰⁷ Diese Opazität der „Gesellschaft des Schwarzen Kastens“ führt dazu, dass algorithmische Bewertungen – etwa Kredit-Scores oder Reputationswerte – lebensverändernde Konsequenzen haben können, ohne dass die Betroffenen die zugrunde liegenden Kriterien verstehen oder anfechten können.³⁰⁸ Die Plattformbetreiber nutzen diesen Wissensvorsprung gezielt aus, um das Nutzerverhalten durch subtile „Anstöße“ in eine für das Unternehmen profitable Richtung zu lenken.³⁰⁹³¹⁰

Schließlich entsteht ein permanentes Spannungsfeld zwischen Personalisierung, Profitabi-

²⁹⁶Vgl. D. S. Evans & Schmalensee(2016), S. 5.

²⁹⁷Vgl. Tiwana(2014), S. 10.

²⁹⁸Vgl. Parker, Van Alstyne & Choudary(2016), S. 17.

²⁹⁹Vgl. Srnicek(2017), S. 27.

³⁰⁰Vgl. Dijck(2014), S. 1.

³⁰¹Vgl. Dijck(2014), S. 1.

³⁰²Vgl. Cusumano, Gawer & Yoffie(2019), S. 31–32, 49–50.

³⁰³Vgl. Srnicek(2017), S. 27.

³⁰⁴Vgl. Tiwana(2014), S. 10.

³⁰⁵Vgl. Parker, Van Alstyne & Choudary(2016), S. 5.

³⁰⁶Vgl. Pasquale(2015), S. 5.

³⁰⁷Vgl. Acquisti, Brandimarte & Loewenstein(2016), S. 477–478.

³⁰⁸Vgl. Pasquale(2015), S. 19.

³⁰⁹Vgl. Acquisti, Brandimarte & Loewenstein(2016), S. 449.

³¹⁰Vgl. Zuboff(2019), S. 69.

lität und Privatsphäre. Während personalisierte Dienste einen hohen Nutzwert versprechen, erfordern sie gleichzeitig eine lückenlose Überwachung, die herkömmliche Konzepte der informationellen Selbstbestimmung untergräbt.³¹¹³¹² Die ökonomischen Imperative des Plattformkapitalismus verlangen nach immer tieferen Einblicken in die Privatsphäre, um die Genauigkeit der Vorhersagemodelle zu steigern, was dazu führt, dass ehemals private Handlungen zunehmend quantifiziert und kommerzialisiert werden.³¹³³¹⁴

Zusammenfassend lässt sich festhalten, dass KI-gestützte Monitoring-Systeme die infrastrukturelle Voraussetzung für eine Form des Kapitalismus geschaffen haben, die auf der systematischen Ausbeutung von Verhaltensüberschüssen beruht.³¹⁵ Die ökonomische Logik der Plattformen zielt nicht mehr nur auf die Vermittlung von Informationen ab, sondern auf die Erlangung einer instrumentellen Macht, die durch algorithmische Steuerung garantierte kommerzielle Ergebnisse sicherstellt.³¹⁶

4.4 Politische und gesellschaftliche Einflussmechanismen

Die Einbettung KI-gestützter Monitoring-Systeme in politische Prozesse markiert einen Übergang von der rein funktionalen Informationsvermittlung hin zu einer proaktiven Steuerung des öffentlichen Diskurses und des sozialen Verhaltens. In der modernen Informationsgesellschaft fungieren diese Systeme nicht mehr lediglich als passive Beobachter, sondern als aktive Architekten der politischen Realität, indem sie die Sichtbarkeit von Themen, die Kommunikation zwischen Akteuren und die emotionalen Reaktionen der Bürger gezielt beeinflussen.³¹⁷ Die politische Dimension dieser technologischen Infrastrukturen manifestiert sich dabei sowohl in demokratischen als auch in autoritären Kontexten, wobei die Mechanismen der algorithmischen Selektion und der automatisierten Kommunikation als Instrumente der Machtausübung dienen.³¹⁸³¹⁹

Mechanismen der politischen Einflussnahme Ein zentraler Mechanismus der politischen Steuerung ist die algorithmische Verstärkung und Sichtbarkeitssteuerung. Empfehlungssysteme und Ranking-Algorithmen determinieren maßgeblich, wer im digitalen Raum gehört wird und welche Themen die öffentliche Aufmerksamkeit dominieren. Gillespie (2014) beschreibt diese Systeme als „Public Relevance Algorithms“, die Wissen nicht nur organisieren, sondern durch spezifische Kriterien erst zertifizieren. Diese Macht zur Priorisierung ermöglicht es, politische Symbole über expansive Netzwerke zu verbreiten und durch Verfahren wie das „Downranking“ unliebsame Stimmen faktisch unsichtbar zu

³¹¹ Vgl. OECD(2013), S. 9, 14, 17.

³¹² Vgl. Acquisti, Brandimarte & Loewenstein(2016), S. 479–481.

³¹³ Vgl. Srnicek(2017), S. 18.

³¹⁴ Vgl. Dijck(2014), S. 1.

³¹⁵ Vgl. Zuboff(2019), S. 69.

³¹⁶ Vgl. Zuboff(2019), S. 62.

³¹⁷ Vgl. Bradshaw & Howard(2018), S. 4, 11–13.

³¹⁸ Vgl. Feldstein(2019), S. 5.

³¹⁹ Vgl. Woolley & Howard(2017), S. 1.

machen.³²⁰

Darauf aufbauend ermöglicht die systematische Datenerfassung eine personalisierte politische Kommunikation, die oft als Micro-Targeting bezeichnet wird. Durch die Analyse digitaler Fußabdrücke können politische Botschaften exakt auf die psychologischen Profile und Schwachstellen individueller Wähler zugeschnitten werden.³²¹

Der Fall Cambridge Analytica verdeutlicht die demokratischen Risiken dieser Praktiken aus gesellschaftlicher Perspektive: Die verdeckte Nutzung von Monitoring-Systemen zur politischen Beeinflussung (vgl. Kapitel 3.2.4) führte zu massiven Bedenken hinsichtlich der Informationsasymmetrie zwischen Plattformen, Datenhändlern und Bürgern.³²² Während die technische Funktionsweise des operativen Zyklus – von der Datenerfassung über Profilbildung bis zur gezielten Intervention – bereits erläutert wurde, stehen aus gesellschaftlicher Sicht die Governance-Implikationen im Vordergrund: Die fehlende Transparenz über den Einsatz psychometrischer Methoden untergräbt das Prinzip informierter Zustimmung und schafft ein strukturelles Machtgefälle, bei dem politische Akteure „innere Dämonen“ der Wähler adressieren können, ohne dass diese die Manipulation erkennen.³²³ Diese Form der verdeckten Beeinflussung stellt demokratische Institutionen vor die Herausforderung, wie individuelle Autonomie und faire Wahlprozesse gegen algorithmisch optimierte Manipulationstechniken geschützt werden können.³²⁴³²⁵³²⁶ Die Yeung (2017) als Hyper-Anstöße charakterisierte Dynamik – eine adaptive, datengesteuerte Regulierung durch subtile Wahlarchitekturen – verdeutlicht, dass traditionelle Regulierungsansätze, die auf offener Kommunikation und rationaler Deliberation basieren, nicht mehr ausreichen.³²⁷

Zusätzlich werden Bots und koordinierte Manipulationskampagnen eingesetzt, um den öffentlichen Diskurs künstlich zu verzerren. Sogenannte „Cyber Troops“ – staatliche oder parteinahe Akteure – nutzen automatisierte Konten, um die Illusion eines breiten Konsenses zu erzeugen (Astroturfing) oder Oppositionelle durch konzertierte Angriffe zu diffamieren.³²⁸³²⁹ Diese Form der Computational Propaganda nutzt die Algorithmen der Plattformen gezielt aus, indem sie durch massenhafte Interaktionen bestimmte Keywords in die Trends befördert und so die Agenda der traditionellen Medien beeinflusst.³³⁰

Die Wirksamkeit dieser Kampagnen wird durch die algorithmische Bevorzugung emotionaler und polarisierender Inhalte verstärkt. Plattformen optimieren primär auf Interaktion, was dazu führt, dass sensationelle oder empörende Informationen eine höhere Reichweite

³²⁰ Vgl. Gillespie(2014), S. 169–173.

³²¹ Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

³²² Vgl. Isaak & Hanna(2018), S. 56, 58.

³²³ Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

³²⁴ Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

³²⁵ Vgl. Yeung(2017), S. 118.

³²⁶ Vgl. Bradshaw & Howard(2018), S. 5, 21–22.

³²⁷ Vgl. Yeung(2017), S. 118.

³²⁸ Vgl. Bradshaw & Howard(2018), S. 11.

³²⁹ Vgl. Woolley & Howard(2017), S. 1.

³³⁰ Vgl. Bradshaw & Howard(2018), S. 6.

erzielen als sachliche Diskurse.³³¹ Experimentelle Studien zur emotionalen Ansteckung (Emotional Contagion) belegen zudem, dass die gezielte Manipulation des News Feeds die Stimmungslage von Millionen von Nutzern messbar verändern kann.³³² In autoritären Staaten wie China wird diese technologische Kapazität zur staatlichen Überwachung und Zensur perfektioniert. Die Integration von KI in Systeme wie das SCS oder die „Great Firewall“ erlaubt eine lückenlose Kontrolle des Informationsflusses und die Identifikation potenzieller Dissidenten durch Mustererkennung in Echtzeit.³³³³³⁴

Gesellschaftliche und politische Konsequenzen Die Anwendung dieser Mechanismen hat tiefgreifende Konsequenzen für die Stabilität demokratischer Institutionen. Eine wesentliche Folge ist die Manipulation des öffentlichen Diskurses durch die systematische Verbreitung von Desinformation. Da soziale Medien sensationelle Inhalte bevorzugen, verbreiten sich „Junk News“ oft schneller und weiter als professioneller Journalismus.³³⁵ Dies untergräbt das Vertrauen in Medien, Wissenschaft und öffentliche Institutionen, was die Grundlage für eine faktenbasierte demokratische Meinungsbildung erodiert.³³⁶

Ein weiteres viel diskutiertes Phänomen ist die Polarisierung und Fragmentierung der Gesellschaft. Während Filterblasen als Resultat algorithmischer Personalisierung Individuen in homogenen Informationsräumen isolieren, beschreiben Echokammern soziale Strukturen, in denen sich Gleichgesinnte gegenseitig in ihren Weltbildern bestärken.³³⁷ Metzler und Garcia (2023) betonen jedoch, dass Algorithmen hierbei oft bestehende soziale Treiber lediglich verstärken.³³⁸ Empirische Befunde zeigen, dass die Plattformarchitektur entscheidend ist: Während Facebook homophile Cluster begünstigt, fördern andere Strukturen eher den Kontakt mit dissonanten Meinungen.³³⁹ Dennoch kann die ständige Konfrontation mit extremen Positionen die wahrgenommene Polarisierung erhöhen und gemäßigte Mehrheiten unsichtbar machen.³⁴⁰

Diese Dynamiken beeinflussen auch die politische Partizipation und Mobilisierung. Einerseits bieten soziale Netzwerke neue Wege für bürgerschaftliche Beteiligung und die Koordination von Protestbewegungen, wie sie während des Arabischen Frühlings beobachtet wurden. Andererseits führt die omnipräsente Überwachung zu einem Chilling Effect, bei dem Bürger aus Angst vor Repressionen oder sozialer Ausgrenzung auf die freie Meinungsäußerung verzichten.³⁴¹ In autoritären Regimen wird KI-gestütztes Monitoring

³³¹ Vgl. Woolley & Howard(2017), S. 1.

³³² Vgl. Kramer, Guillory & Hancock(2014), S. 8788–8790.

³³³ Vgl. Creemers(2018), S. 26, 28.

³³⁴ Vgl. Qiang(2019), S. 5.

³³⁵ Vgl. Woolley & Howard(2017), S. 1.

³³⁶ Vgl. Bradshaw & Howard(2018), S. 3–4.

³³⁷ Vgl. Cinelli u. a.(2021), S. 1.

³³⁸ Vgl. Metzler & Garcia(2023), S. 736, 738.

³³⁹ Vgl. Cinelli u. a.(2021), S. 3, 5–6.

³⁴⁰ Vgl. Metzler & Garcia(2023), S. 738–739.

³⁴¹ Vgl. Bradshaw & Howard(2018), S. 21.

genutzt, um Proteste bereits im Keim zu ersticken, indem Bewegungen prädiktiv analysiert und deren Anführer gezielt neutralisiert werden.³⁴²

Schließlich führt die flächendeckende Implementierung dieser Systeme zu einer Normalisierung von Überwachung und sozialer Kontrolle. In China wird das Streben nach einer „perfekten Erinnerung“ des Staates an seine Bürger durch das SCS institutionalisiert, wobei algorithmische Bewertungen über den Zugang zu grundlegenden Dienstleistungen entscheiden.³⁴³³⁴⁴ Diese Entwicklung markiert den Aufstieg eines digitalen Autoritarismus, der nicht mehr auf physischen Zwang allein, sondern auf die algorithmische Disziplinierung durch Belohnung und Bestrafung setzt.³⁴⁵³⁴⁶

Zusammenfassend lässt sich festhalten, dass KI-gestützte Monitoring-Systeme Politik und Gesellschaft fundamental transformieren, indem sie die Bedingungen der Kommunikation und des sozialen Austauschs neu definieren. Die daraus resultierenden Risiken für die individuelle Autonomie und die demokratische Ordnung fordern bestehende regulatorische Rahmenbedingungen heraus. Die Frage, wie diese mächtigen technologischen Infrastrukturen rechtlich und ethisch eingehegt werden können, um eine vertrauenswürdige KI sicherzustellen, ist Gegenstand des abschließenden Kapitels über Governance- und Kontrollstrukturen.

4.5 Governance- und Kontrollstrukturen

Die umfassenden sozioökonomischen und politischen Auswirkungen KI-gestützter Monitoring-Systeme verdeutlichen die Notwendigkeit robuster Governance-Strukturen, um algorithmische Macht einzuhegen und Verantwortlichkeiten zu klären. Effektive Governance erfordert dabei ein integratives Zusammenspiel aus rechtlichen Normen, ethischen Prinzipien, organisatorischen Risikomanagement-Prozessen und technischen Kontrollmechanismen.³⁴⁷³⁴⁸ Der folgende Abschnitt analysiert zunächst die zentralen Herausforderungen der Regulierung und stellt darauf aufbauend die wichtigsten Governance-Ansätze dar.

Herausforderungen der algorithmischen Governance Die primäre Hürde für eine wirksame Kontrolle liegt in der konstitutiven Opazität algorithmischer Entscheidungsprozesse. Pasquale (2015) beschreibt moderne Informations- und Finanzsysteme als „Schwarze Kästen“, deren interne Logiken durch eine Kombination aus technischer Komplexität, echtem Geheimwissen und rechtlichem Schutz von Geschäftsgeheimnissen der öffentlichen Einsicht entzogen werden.³⁴⁹ Diese Undurchsichtigkeit führt zu massiven Informationsa-

³⁴² Vgl. Feldstein(2019), S. 14–15, 20–21.

³⁴³ Vgl. Creemers(2018), S. 3–4, 25–28.

³⁴⁴ Vgl. Qiang(2019), S. 5.

³⁴⁵ Vgl. Qiang(2019), S. 5.

³⁴⁶ Vgl. U.S.-China Economic and Security Review Commission(2020), S. 1.

³⁴⁷ Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 2.

³⁴⁸ Vgl. National Institute of Standards and Technology(2023), S. 21–24.

³⁴⁹ Vgl. Pasquale(2015), S. 19.

symmetrien, da Plattformbetreiber zwar über ein nahezu perfektes Wissen über die Nutzer verfügen, deren eigene Bewertungskriterien jedoch im Verborgenen bleiben.³⁵⁰³⁵¹

In diesem Kontext entstehen erhebliche Risiken für automatisierte Klassifikationen und Diskriminierung. O’Neil (2016) charakterisiert problematische Modelle als „Weapons of Math Destruction“, die oft auf fehlerhaften Daten oder voreingenommenen Annahmen basieren und bestehende soziale Ungleichheiten mathematisch zementieren, ohne dass für die Betroffenen Einspruchsmöglichkeiten bestehen.³⁵² Die lückenlose Erfassung von Verhaltensdaten untergräbt zudem die menschliche Autonomie und die informationelle Selbstbestimmung, da Individuen oft die Kontrolle darüber verlieren, wie ihre digitalen Fußabdrücke aggregiert und zur Verhaltensbeeinflussung genutzt werden.³⁵³ Eine unklare Zuweisung von Verantwortung erschwert zudem die Rechenschaftspflicht (Accountability), wenn algorithmische Entscheidungen zu materiellen oder immateriellen Schäden führen.³⁵⁴³⁵⁵

Rechtliche Regulierungsansätze im EU-Kontext Zur Bewältigung dieser Herausforderungen hat die Europäische Union einen multidimensionalen Rechtsrahmen etabliert, der auf verschiedenen Ebenen ansetzt. Die Datenschutz-Grundverordnung (DSGVO) bildet das fundamentale Fundament für den Schutz personenbezogener Daten und adressiert spezifisch die Risiken von Profiling und automatisierter Entscheidungsfindung. Gemäß Artikel 22 der DSGVO haben betroffene Personen grundsätzlich das Recht, nicht einer ausschließlich auf einer automatisierten Verarbeitung beruhenden Entscheidung unterworfen zu werden, die ihnen gegenüber rechtliche Wirkung entfaltet oder sie in ähnlicher Weise erheblich beeinträchtigt.³⁵⁶ Die DSGVO fordert zudem die Einhaltung zentraler Prinzipien wie Datenminimierung, Zweckbindung und Transparenz, was die extraktiven Praktiken des Überwachungskapitalismus rechtlich begrenzt.³⁵⁷³⁵⁸

Ergänzend dazu führt das Gesetz über Künstliche Intelligenz (Artificial Intelligence (AI) Act) einen risikobasierten Ansatz ein, der KI-Systeme nach ihrem Gefährdungspotenzial klassifiziert. Bestimmte Praktiken, wie etwa der Einsatz manipulativer Techniken zur Beeinflussung des Nutzerverhaltens oder KI-basiertes Citizen Scoring durch staatliche Stellen, werden explizit untersagt.³⁵⁹ Hochrisiko-KI-Systeme, zu denen insbesondere Monitoring-Systeme in den Bereichen Beschäftigung, Bildung und Strafverfolgung zählen, unterliegen strengen Anforderungen an das Risikomanagement, die Datenqualität und

³⁵⁰ Vgl. Pasquale(2015), S. 19.

³⁵¹ Vgl. Zuboff(2019), S. 69.

³⁵² Vgl. O’Neil(2016), S. 145.

³⁵³ Vgl. Lyon(2012), S. 3.

³⁵⁴ Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 6.

³⁵⁵ Vgl. Pasquale(2015), S. 19.

³⁵⁶ Vgl. Europäisches Parlament und Rat(2016).

³⁵⁷ Vgl. Europäisches Parlament und Rat(2016).

³⁵⁸ Vgl. Zuboff(2019), S. 471.

³⁵⁹ Vgl. Europäisches Parlament und Rat(2024), S. 51.

die technische Dokumentation.³⁶⁰ Ein zentrales Element des AI Act ist die Forderung nach menschlicher Aufsicht (Human Oversight), um sicherzustellen, dass KI-Systeme die menschliche Autonomie nicht untergraben und Entscheidungen jederzeit durch natürliche Personen korrigiert werden können.³⁶¹

Für digitale Plattformen schafft das Gesetz über digitale Dienste (Digital Services Act – DSA) zusätzliche Verantwortlichkeiten. Sehr große Online-Plattformen werden verpflichtet, systemische Risiken zu bewerten, die von ihren Diensten ausgehen – insbesondere im Hinblick auf die Verbreitung von Desinformation oder negative Auswirkungen auf Grundrechte.³⁶² Der DSA fordert zudem eine erhöhte Transparenz für Empfehlungssysteme; Plattformbetreiber müssen die wichtigsten Parameter ihrer Algorithmen offenlegen und den Nutzern Optionen zur Verfügung stellen, die Reihenfolge der Inhalte zu beeinflussen.³⁶³ Diese regulatorischen Maßnahmen zielen darauf ab, die algorithmische Kuratierung kontrollierbar zu machen und Informationsasymmetrien abzubauen.³⁶⁴

Ethische Leitlinien und organisatorisches Risikomanagement Über die rein gesetzlichen Verpflichtungen hinaus bilden ethische Leitlinien einen Orientierungsrahmen für eine vertrauenswürdige KI. Die Ethik-Leitlinien der High-Level Expert Group on AI definieren Vertrauenswürdigkeit durch drei Komponenten: KI sollte rechtmäßig, ethisch und robust sein.³⁶⁵ Zu den sieben Kernanforderungen zählen unter anderem Vorrang menschlichen Handelns, technische Robustheit, Transparenz sowie Vielfalt und Nichtdiskriminierung.³⁶⁶ Diese Prinzipien dienen als Grundlage für die Entwicklung einer ethischen Kultur innerhalb von Organisationen und sollen sicherstellen, dass KI-Systeme zum menschlichen Wohlergehen beitragen.³⁶⁷

Die praktische Operationalisierung dieser Werte erfolgt durch Rahmenwerke wie das NIST AI Risk Management Framework. Dieses Framework schlägt einen iterativen Prozess vor, der die Funktionen Regieren (Govern), Abbilden (Map), Messen (Measure) und Verwalten (Manage) umfasst.³⁶⁸ Governance wird hierbei als querschnittliche Funktion verstanden, die eine Risikokultur im gesamten Unternehmen verankert und klare Linien der Rechenschaftspflicht zwischen Management und technischen Teams etabliert.³⁶⁹ Organisationen werden dazu angehalten, regelmäßige Audits, Folgenabschätzungen und ein kontinuierliches Monitoring durchzuführen, um unvorhergesehene negative Auswirkungen frühzeitig

³⁶⁰ Vgl. Europäisches Parlament und Rat(2024), S. 52.

³⁶¹ Vgl. Europäisches Parlament und Rat(2024), S. 58.

³⁶² Vgl. Europäisches Parlament und Rat(2022), S. 22–23, 64.

³⁶³ Vgl. Europäisches Parlament und Rat(2022), S. 59.

³⁶⁴ Vgl. Europäisches Parlament und Rat(2022), S. 26–27, 70–72.

³⁶⁵ Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 2.

³⁶⁶ Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 14.

³⁶⁷ Vgl. National Institute of Standards and Technology(2023), S. 1–2.

³⁶⁸ Vgl. National Institute of Standards and Technology(2023), S. 20–21.

³⁶⁹ Vgl. National Institute of Standards and Technology(2023), S. 20–23.

zu erkennen und abzumildern.³⁷⁰³⁷¹

Zusammenfassend lässt sich festhalten, dass eine effektive Governance KI-gestützter Monitoring-Systeme nicht durch ein einzelnes Instrument erreicht werden kann. Vielmehr ist eine Kombination aus verbindlicher Gesetzgebung, ethischer Selbstverpflichtung und technischer Kontrolle erforderlich. Dennoch kann Regulierung allein keine vollständige Lösung bieten, da technologische Innovationen die regulatorische Kapazität oft überholen.³⁷² Die ständige Spannung zwischen technologischer Dynamik, ökonomischen Interessen und dem Schutz fundamentaler Rechte erfordert daher eine kontinuierliche gesellschaftliche Debatte über die Grenzen algorithmischer Steuerung. Diese abschließende Betrachtung leitet über zum Fazit der Arbeit, in dem die Ergebnisse zusammengeführt und ein Ausblick auf die zukünftige Gestaltung digitaler Informationsumgebungen gegeben wird.

³⁷⁰Vgl. National Institute of Standards and Technology(2023), S. 28–31, 35–36.

³⁷¹Vgl. O’Neil(2016), S. 145.

³⁷²Vgl. Pasquale(2015), S. 19.

5 Kritische Betrachtung

Die vorangegangenen Kapitel dieser Arbeit haben die technologische Funktionsweise, die Systemlogiken sowie die sozioökonomischen Implikationen KI-gestützter Monitoring-Systeme durch einen literaturbasierten und konzeptionellen Ansatz systematisch analysiert. Um die eingangs formulierte Forschungsfrage jedoch verantwortungsvoll zu beantworten, ist eine kritische Reflexion der zugrunde liegenden Annahmen, der synthetisierten Befunde und der methodischen Entscheidungen unerlässlich.³⁷³ Die in dieser Untersuchung dargelegten Erkenntnisse müssen innerhalb spezifischer Limitationen interpretiert werden, die sich aus der Opazität proprietärer Systeme, der Heterogenität der Literaturlbasis, dem Fehlen eigener Primärdaten sowie der rasanten technologischen Entwicklung ergeben.³⁷⁴ Besondere Aufmerksamkeit verdient zudem die Diskrepanz zwischen theoretischen Modellen und empirischen Befunden, da die tatsächliche Wirkstärke algorithmischer Interventionen oft geringer ausfällt als konzeptionell angenommen und stark kontextabhängig ist.³⁷⁵³⁷⁶

5.1 Grenzen der technologischen Analyse

Die technologische Analyse der vorliegenden Arbeit konzentriert sich auf die Funktionsweise von KI-gestützten Monitoring-Systemen als integrierte Bestandteile digitaler Informationsumgebungen. Der Untersuchung liegt ein idealtypischer Monitoring-Zyklus zugrunde, der die komplexen Wirkmechanismen theoretisch handhabbar macht. In der technologischen Realität sind die Grenzen zwischen diesen Phasen jedoch fließend, und die zugrunde liegende Infrastruktur ist weitaus heterogener, als es das generalisierte Modell vermuten lässt.³⁷⁷

Die Arbeit fokussiert sich auf die Ebenen der Analyse, Prognose und Verhaltensbeeinflussung, während tieferliegende technologische Schichten – wie Sensortechnologien, Datenübertragungsprotokolle oder Hardwarearchitekturen – weitgehend abstrahiert werden.³⁷⁸ Ohne diese basale Infrastrukturebene bleibt die technologische Durchdringung auf einer funktionalen Ebene stehen. Zudem führt die Vereinfachung heterogener Technologien in ein allgemeines Prozessmodell zu einer Vernachlässigung sektoraler und geografischer Unterschiede.

Eine zentrale Limitation bildet die konstitutive Opazität proprietärer Systeme. Da Plattformen wie Meta, Google oder TikTok ihre exakten Trainingsdaten, Modellparameter und

³⁷³ Vgl. Brocke u. a.(2009), S. 1.

³⁷⁴ Vgl. National Institute of Standards and Technology(2023), S. 6, 38–39.

³⁷⁵ Vgl. Areeb u. a.(2023), S. 7–9, 17.

³⁷⁶ Vgl. Kelm, Dohle & Bernhard(2023), S. 6–7.

³⁷⁷ Vgl. Russell & Norvig(2010), S. 34.

³⁷⁸ Vgl. K. C. Laudon & J. P. Laudon(2018), S. 254–255, 259.

algorithmischen Gewichtungungen nicht offenlegen, kann die Funktionsweise realer Systeme lediglich konzeptionell auf Basis veröffentlichter Literatur, technischer Whitepaper und Leaks rekonstruiert werden.³⁷⁹ Diese Arbeit bietet daher eine theoriegeleitete Synthese der systemischen Zusammenhänge, kann jedoch kein technisches Audit realer Plattformen leisten. Die rasante technologische Entwicklungsgeschwindigkeit im Bereich des Deep Learning limitiert zudem die langfristige Validität spezifischer technischer Beschreibungen.³⁸⁰

Schließlich ist kritisch zu reflektieren, dass Nutzerreaktionen und Verhaltensdynamiken nicht monokausal auf algorithmische Interventionen zurückgeführt werden können, da Algorithmen permanent mit sozialen, organisatorischen und individuellen Faktoren interagieren.³⁸¹ Während die zentralen funktionalen Zusammenhänge und Systemlogiken präzise herausgearbeitet wurden, stößt die Untersuchung bei der detaillierten technischen Rekonstruktion interner Plattformprozesse an systemimmanente Grenzen.

5.2 Grenzen der Literaturbasis

Die vorliegende Arbeit stützt sich auf eine breite Auswahl wissenschaftlicher Quellen, um die komplexen Wirkmechanismen KI-gestützter Monitoring-Systeme theoretisch zu erfassen. Die herangezogene Literaturbasis weist jedoch inhärente Limitationen auf, die die Generalisierbarkeit der Ergebnisse einschränken. Da die Untersuchung an der Schnittstelle von Wirtschaftsinformatik, Soziologie, Rechtswissenschaft und Psychologie angesiedelt ist, unterliegen die Quellen sehr unterschiedlichen konzeptionellen und methodischen Ansätzen, was die Integration in ein einheitliches Gesamtbild erschwert.³⁸²³⁸³

Ein zentraler kritischer Aspekt ist die Heterogenität der wissenschaftlichen Evidenz zu den untersuchten Phänomenen. Befunde zu Filterblasen, Echokammern und algorithmischer Polarisierung erweisen sich als widersprüchlich oder stark kontextabhängig.³⁸⁴³⁸⁵ Während konzeptionelle Arbeiten vor informationaler Isolation warnen, zeigen systematische Reviews uneinheitliche empirische Belege, die stark vom spezifischen Algorithmus-Design und der Plattformarchitektur abhängen. Diese Unsicherheit illustriert exemplarisch die Schwierigkeit, allgemeingültige Schlussfolgerungen über die Wirkung von Monitoring-Systemen zu treffen.

Des Weiteren basieren viele empirische Untersuchungen auf spezifischen Nutzergruppen oder geografischen Räumen. Orben und Przybylski (2019) zeigen etwa, dass Studien zum digitalen Wohlbefinden oft auf Sekundäranalysen mit hoher „analytischer Flexibilität“ basieren, was zu statistisch signifikanten, aber praktisch vernachlässigbaren Effekten füh-

³⁷⁹ Vgl. National Institute of Standards and Technology(2023), S. 15–16, 38.

³⁸⁰ Vgl. Goodfellow, Bengio & Courville(2016), S. 19–26.

³⁸¹ Vgl. Lyon(2012), S. 2, 8.

³⁸² Vgl. Pasquale(2015), S. 19.

³⁸³ Vgl. Brocke u. a.(2009), S. 1.

³⁸⁴ Vgl. Areeb u. a.(2023), S. 7–9.

³⁸⁵ Vgl. Cinelli u. a.(2021), S. 1–2, 5–6.

ren kann.³⁸⁶ Die Synthese umfasst zudem Quellen mit unterschiedlichen Evidenzgraden – von peer-reviewten Fachartikeln über juristische Gesetzestexte bis hin zu Berichten internationaler Organisationen –, was eine differenzierte Gewichtung der jeweiligen Argumentationsstränge erfordert.³⁸⁷

Zusammenfassend lässt sich festhalten, dass die Literaturbasis eine fundierte Grundlage für eine konzeptionelle Analyse bietet, jedoch keine allgemeingültigen Schlussfolgerungen für sämtliche Monitoring-Systeme zulässt.

5.3 Aussagekraft und methodische Limitationen

Die Aussagekraft der vorliegenden Untersuchung ist untrennbar mit ihrem qualitativen, literaturbasierten und konzeptionellen Forschungsansatz verknüpft. Da im Rahmen dieser Arbeit keine eigenen Primärdaten erhoben wurden, zielt die Argumentation auf die systematische Rekonstruktion und Synthese des vorhandenen wissenschaftlichen Wissens ab.³⁸⁸ Dieser Ansatz ermöglicht eine fundierte theoretische Durchdringung, stößt jedoch an Grenzen, sobald es um den Nachweis konkreter kausaler Effekte geht. Die gewonnenen Erkenntnisse stellen eine Integration bestehender Theorien und Befunde dar, können jedoch keine empirische Beweiskraft für die unmittelbare Wirkung einzelner Algorithmen auf das Nutzerverhalten beanspruchen.³⁸⁹

Ein wesentlicher limitierender Faktor ist die Abhängigkeit von der Qualität und Interpretation der herangezogenen Sekundärquellen. Da die wissenschaftliche Evidenz zu zentralen Phänomenen oft uneinheitlich ist, hängen die Ergebnisse maßgeblich davon ab, welche Studien als Referenz gewählt wurden.³⁹⁰ Die Resultate können nicht gleichermaßen auf alle Plattformen, Länder oder Nutzergruppen verallgemeinert werden. Monitoring-Systeme operieren in hochgradig unterschiedlichen soziotechnischen Kontexten, wobei die spezifische Architektur die Generalisierbarkeit der beschriebenen Mechanismen massiv einschränkt.³⁹¹

Die Isolation kausaler Beziehungen zwischen Algorithmen und menschlichem Verhalten erweist sich als methodisch äußerst komplex. Die beobachteten Verhaltensdynamiken sind stets das Resultat eines Zusammenspiels vielfältiger Faktoren, bei dem soziale Einflüsse, individuelle psychologische Dispositionen sowie ökonomische und politische Rahmenbedingungen die rein technologische Wirkung überlagern.³⁹² Empirische Analysen zeigen, dass technologische Effekte auf das Wohlbefinden im Vergleich zu basalen Faktoren wie Schlaf oder Ernährung oft nur einen minimalen Anteil der Varianz erklären.³⁹³ Die vorlie-

³⁸⁶ Vgl. Orben & Przybylski(2019), S. 2, 4–5.

³⁸⁷ Vgl. Brocke u. a.(2009), S. 1.

³⁸⁸ Vgl. Brocke u. a.(2009), S. 1.

³⁸⁹ Vgl. Kelm, Dohle & Bernhard(2023), S. 1, 3, 7.

³⁹⁰ Vgl. Areeb u. a.(2023), S. 2, 7–10.

³⁹¹ Vgl. Cinelli u. a.(2021), S. 1–2, 5–6.

³⁹² Vgl. National Institute of Standards and Technology(2023), S. 1.

³⁹³ Vgl. Orben & Przybylski(2019), S. 16.

gende Arbeit kann daher zwar plausible Zusammenhänge identifizieren, ist jedoch nicht in der Lage, die exakte Wirkstärke dieser Interventionen quantitativ zu messen.

Zusammenfassend lässt sich festhalten, dass diese Arbeit einen hohen konzeptionellen Erklärungswert besitzt, indem sie die strukturellen Logiken und Mechanismen der algorithmischen Governance transparent macht, während ihre empirische und kausale Validität durch die dargelegten methodischen Rahmenbedingungen notwendigerweise limitiert bleibt.

5.4 Normative und empirische Perspektiven

Die vorliegende Arbeit hat verdeutlicht, dass die Bewertung KI-gestützter Monitoring-Systeme in einem Spannungsfeld zwischen normativen Zielsetzungen und lückenhafter empirischer Evidenz steht. Der Abschluss der kritischen Betrachtung erfordert eine präzise Differenzierung zwischen dem, was technologisch und gesellschaftlich wünschenswert ist (normative Perspektive), und dem, was wissenschaftlich gesichert über die tatsächliche Wirkung dieser Systeme gesagt werden kann (empirische Perspektive).

Die normative Perspektive definiert Prinzipien wie Human Oversight, Transparenz, Rechenschaftspflicht, Fairness und Datenschutz, die das Design und den Einsatz von Monitoring-Systemen leiten sollten.³⁹⁴³⁹⁵ Rechtliche Rahmenwerke wie die DSGVO oder der AI Act markieren einen gesellschaftlichen Konsens über Standards der „Vertrauenswürdigen KI“. ³⁹⁶³⁹⁷ Es muss jedoch kritisch reflektiert werden, dass die Existenz regulatorischer Vorgaben noch keinen Beweis für das tatsächliche Verhalten der Systeme in der Praxis darstellt. Normative Forderungen beschreiben einen Soll-Zustand, dessen faktische Umsetzung aufgrund der dargelegten Opazität und ökonomischen Interessenlagen oft im Verborgenen bleibt.³⁹⁸³⁹⁹

Die empirische Perspektive offenbart, dass viele zentrale Fragen zur tatsächlichen Wirkstärke und den Langzeitfolgen von Monitoring-Systemen weiterhin offen sind. Während konzeptionelle Modelle vor manipulativer Verhaltenssteuerung warnen, zeigen empirische Studien oft nur geringfügige Effekte, die stark von der individuellen Suszeptibilität und dem sozialen Kontext abhängen.⁴⁰⁰⁴⁰¹ Ebenso bleibt unklar, wie sich Personalisierung über lange Zeiträume auf kognitive Prozesse und politische Meinungsbildung auswirkt, da kausale Zusammenhänge methodisch schwer zu isolieren sind.⁴⁰² O’Neil (2016) betont zudem das Problem der Feedback-Schleifen, bei denen automatisierte Bewertungen soziale

³⁹⁴ Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 16.

³⁹⁵ Vgl. Europäisches Parlament und Rat(2024), S. 4.

³⁹⁶ Vgl. Europäisches Parlament und Rat(2016).

³⁹⁷ Vgl. National Institute of Standards and Technology(2023), S. 12.

³⁹⁸ Vgl. Pasquale(2015), S. 19.

³⁹⁹ Vgl. Zuboff(2019), S. 69.

⁴⁰⁰ Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

⁴⁰¹ Vgl. Orben & Przybylski(2019), S. 6.

⁴⁰² Vgl. Areeb u. a.(2023), S. 7–9, 17.

Ungleichheiten unbemerkt verstärken können, ohne dass ausreichende unabhängige Audits vorliegen.⁴⁰³

Zukünftige Forschung muss die Lücke zwischen normativen Ansprüchen und empirischen Befunden schließen. Hierzu ist ein erweiterter Zugang zu internen Plattformdaten und proprietären Algorithmen erforderlich, wie ihn der Digital Services Act für zugelassene Forscher prinzipiell vorsieht.⁴⁰⁴ Eine verantwortungsvolle Beantwortung der Forschungsfrage setzt voraus, dass konzeptionelle Analysen durch plattformübergreifende Längsschnittstudien, kontrollierte Online-Experimente, qualitative Interviews und vergleichende Fallstudien ergänzt werden.⁴⁰⁵ Nur durch methodische Triangulation kann die Effektivität bestehender Governance-Mechanismen überprüft und die Grenze zwischen legitimer Personalisierung und unzulässiger Manipulation präzise bestimmt werden.⁴⁰⁶

Zusammenfassend lässt sich festhalten, dass die wissenschaftliche Auseinandersetzung mit KI-gestütztem Monitoring eine kontinuierliche Reflexion der normativen Grundlagen und eine Ausweitung der empirischen Prüfverfahren erfordert. Die in dieser Arbeit identifizierten Mechanismen bilden das theoretische Fundament, auf dem zukünftige Untersuchungen die tatsächlichen Machtverhältnisse in digitalen Informationsumgebungen weiter entschlüsseln müssen.

⁴⁰³ Vgl. O’Neil(2016), S. 145.

⁴⁰⁴ Vgl. Europäisches Parlament und Rat(2022), S. 70–71.

⁴⁰⁵ Vgl. National Institute of Standards and Technology(2023), S. 28.

⁴⁰⁶ Vgl. Susser, Roessler & Nissenbaum(2019), S. 28.

6 Fazit und Ausblick

Die vorliegende Arbeit verfolgte das Ziel, KI-gestützte Monitoring-Systeme in ihrer Funktion als digitale Informationssysteme systematisch zu untersuchen und zu analysieren, inwiefern diese Technologien eine datenbasierte Analyse und gezielte Beeinflussung menschlichen Verhaltens ermöglichen. Im Zentrum der Untersuchung stand die Forschungsfrage, welche Mechanismen der algorithmischen Steuerung zugrunde liegen und welche sozio-ökonomischen sowie gesellschaftlichen Konsequenzen sich aus deren Anwendung ergeben. Die Beantwortung dieser Frage erforderte eine interdisziplinäre Betrachtung technologischer Architekturen, ökonomischer Verwertungslogiken und staatlicher Governance-Strukturen.

Die wesentlichen Ergebnisse der Arbeit verdeutlichen, dass modernes Monitoring weit über die bloße Beobachtung hinausgeht und als geschlossener kybernetischer Regelkreis operiert. Dieser zentrale Monitoring-Zyklus umfasst die Phasen Datenerfassung → Profilbildung → Analyse → Prognose und Bewertung → algorithmische Intervention → erneute Datenerfassung. Durch die kontinuierliche Übersetzung menschlicher Erfahrung in quantifizierbare Verhaltensdaten werden Individuen in maschinenlesbaren Nutzungsprofilen formalisiert. Auf dieser Basis transformieren Teilsysteme wie Empfehlungsalgorithmen, Ranking-Verfahren, Scoring-Modelle und Personalisierungsmechanismen den sogenannten Verhaltensüberschuss in präzise Vorhersagen und automatisierte Entscheidungen. Die algorithmische Intervention greift aktiv in die Informationsumgebung ein, um das künftige Verhalten der Nutzer im Sinne spezifischer Zielvorgaben zu optimieren.

Dabei wurde zwischen zwei grundlegenden Systemlogiken differenziert, die zwar auf ähnlichen technologischen Verfahren beruhen, jedoch divergierende Ziele verfolgen. Kommerzielle Plattformen wie Meta, TikTok oder Google operieren nach der Logik des Überwachungskapitalismus, wobei das Monitoring primär der Interaktionsoptimierung, dem Wachstum und der Monetarisierung von Aufmerksamkeit dient.⁴⁰⁷ Im Gegensatz dazu nutzen staatlich integrierte Systeme, wie das chinesische Social Credit System, Monitoring-Infrastrukturen zur Sicherung von Compliance, Governance und umfassender sozialer Kontrolle.⁴⁰⁸ Während die westliche Logik Nutzer durch subtile ökonomische Anstöße lenkt, setzt das chinesische Modell auf eine offene algorithmische Disziplinierung zur Einübung staatsbürgerlicher Tugenden.

In der abschließenden Bewertung ist festzustellen, dass KI-gestützte Monitoring-Systeme eine signifikante Bedrohung für die demokratische Willensbildung, das freie Denken und die individuelle Autonomie darstellen können, wenn sie ohne hinreichende Transparenz und wirksame Kontrollinstanzen operieren. Das Risiko einer schleichenden Entmach-

⁴⁰⁷ Vgl. Zuboff(2019), S. 69.

⁴⁰⁸ Vgl. Creemers(2018), S. 19–22, 25–28.

tung des Individuums resultiert aus dem synergetischen Zusammenspiel von lückenloser Überwachung, psychologischem Profiling, personalisierten Informationsräumen und der algorithmischen Verstärkung emotionaler oder polarisierender Inhalte. Die Fälle Cambridge Analytica, die US-Wahlkämpfe sowie die Brexit-Kampagne haben exemplarisch verdeutlicht, wie datengetriebene politische Kommunikation gezielt psychologische Schwachstellen ausbeuten kann, um öffentliche Diskurse zu manipulieren.⁴⁰⁹ Das chinesische Sozialkreditsystem markiert hierbei die bisher weitestgehende Ausprägung einer algorithmischen Governance, die das Leben des Bürgers bis in private Bereiche hinein bewertet und sanktioniert.⁴¹⁰

Dennoch muss betont werden, dass Algorithmen den freien Willen nicht automatisch eliminieren oder als monokausale Ursache für Radikalisierung betrachtet werden dürfen. Die tatsächliche Wirkung dieser Systeme ist stets von einem komplexen Gefüge aus sozialen, psychologischen und politischen Faktoren sowie dem individuellen Selektionsverhalten der Nutzer abhängig. Die Aussagekraft dieser Arbeit unterliegt zudem spezifischen Limitationen, die sich aus dem literaturbasierten Ansatz und dem fehlenden Zugriff auf proprietäre Systemdaten ergeben. Die synthetisierten Befunde basieren auf einer heterogenen Evidenzlage und lassen aufgrund geografischer und plattformspezifischer Unterschiede keine uneingeschränkte Generalisierung zu.

Der Ausblick auf künftige Entwicklungen macht deutlich, dass die technologische Gestaltung digitaler Räume eine permanente gesellschaftliche und regulatorische Begleitung erfordert. Zukünftige Forschung sollte verstärkt auf unabhängige Audits von Empfehlungs- und Scoring-Systemen setzen und den durch den Digital Services Act geschaffenen Datenzugang für die Wissenschaft nutzen.⁴¹¹ Um die Langzeitfolgen von Interaktionsoptimierung und Personalisierung besser zu verstehen, sind plattformübergreifende Längsschnittstudien und kontrollierte Experimente unerlässlich. Schließlich wird die Wirksamkeit aktueller Regulierungsrahmen wie der DSGVO, des Digital Services Act und des AI Act einer kontinuierlichen Evaluierung unterzogen werden müssen, um sicherzustellen, dass technologische Innovationen nicht zu Lasten fundamentaler Menschenrechte und der menschlichen Autonomie gehen.

⁴⁰⁹Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

⁴¹⁰Vgl. Qiang(2019), S. 5.

⁴¹¹Vgl. Europäisches Parlament und Rat(2022), S. 70–71.

Literaturverzeichnis

- Acquisti, Alessandro, Brandimarte, Laura & Loewenstein, George (2016). „Privacy and Human Behavior in the Age of Information“. In: *Science* 347.6221, S. 509–514. DOI: 10.1126/science.aaa1465.
- Adomavicius, Gediminas & Tuzhilin, Alexander (2005). „Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions“. In: *IEEE Transactions on Knowledge and Data Engineering* 17.6, S. 734–749. DOI: 10.1109/TKDE.2005.99.
- Areeb, Qazi Mudassar u. a. (2023). „Filter Bubbles in Recommender Systems: Fact or Fallacy – A Systematic Review“. In: *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* 13.6, e1512. DOI: 10.1002/widm.1512.
- Bradshaw, Samantha & Howard, Philip N. (2018). *Challenging Truth and Trust: A Global Inventory of Organized Social Media Manipulation*. Computational Propaganda Project Working Paper 2018.1. Oxford: Oxford Internet Institute.
- Brocke, Jan vom u. a. (2009). „Reconstructing the Giant: On the Importance of Rigour in Documenting the Literature Search Process“. In: *Proceedings of the 17th European Conference on Information Systems (ECIS)*, S. 2206–2217.
- Burke, Robin (2002). „Hybrid Recommender Systems: Survey and Experiments“. In: *User Modeling and User-Adapted Interaction* 12.4, S. 331–370. DOI: 10.1023/A:1021240730564.
- Chandola, Varun, Banerjee, Arindam & Kumar, Vipin (2009). „Anomaly Detection: A Survey“. In: *ACM Computing Surveys* 41.3, S. 1–58. DOI: 10.1145/1541880.1541882.
- Cinelli, Matteo u. a. (2021). „The Echo Chamber Effect on Social Media“. In: *Proceedings of the National Academy of Sciences* 118.9, e2023301118. DOI: 10.1073/pnas.2023301118.
- Creemers, Rogier (2018). „China’s Social Credit System: An Evolving Practice of Control“. In: *SSRN Electronic Journal*. DOI: 10.2139/ssrn.3175792.
- Cusumano, Michael A., Gawer, Annabelle & Yoffie, David B. (2019). „The Business of Platforms: Strategy in the Age of Digital Competition, Innovation, and Power“. In: *Academy of Management Perspectives* 33.4, S. 664–713. DOI: 10.5465/amp.2018.0177.
- Davenport, Thomas H. (2006). „Competing on Analytics“. In: *Harvard Business Review* 84.1, S. 98–107.
- Dijk, José van (2014). „Datafication, Dataism and Dataveillance: Big Data Between Scientific Paradigm and Ideology“. In: *Surveillance & Society* 12.2, S. 197–208. DOI: 10.24908/ss.v12i2.4776.

- Europäisches Parlament und Rat (2016). *Verordnung (EU) 2016/679 – Datenschutz-Grundverordnung (DSGVO)*. URL: https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=LEGISSUM:310401_2 (besucht am 14.06.2026).
- Europäisches Parlament und Rat (2022). *Verordnung (EU) 2022/2065 – Gesetz über digitale Dienste (Digital Services Act)*. URL: <https://eur-lex.europa.eu/eli/reg/2022/2065/oj> (besucht am 14.06.2026).
- Europäisches Parlament und Rat (2024). *Verordnung (EU) 2024/1689 – Gesetz über Künstliche Intelligenz (AI Act)*. URL: <https://eur-lex.europa.eu/eli/reg/2024/1689/oj> (besucht am 14.06.2026).
- Evans, David S. & Schmalensee, Richard (2016). *Matchmakers: The New Economics of Multisided Platforms*. Boston: Harvard Business Review Press.
- Evans, Michael A., Gawer, Annabelle & Yoffie, David B. (2019). *The Business of Platforms: Strategy in the Age of Digital Competition, Innovation, and Power*. New York: Harper Business.
- Feldstein, Steven (2019). „The Global Expansion of AI Surveillance“. In: *Carnegie Endowment for International Peace*, S. 1–47.
- Fogg, B. J. (2009). „A Behavior Model for Persuasive Design“. In: *Proceedings of the 4th International Conference on Persuasive Technology*, S. 1–7. DOI: 10.1145/1541948.1541999.
- Gillespie, Tarleton (2014). „The Relevance of Algorithms“. In: *Media Technologies: Essays on Communication, Materiality, and Society*, S. 167–194.
- Goodfellow, Ian, Bengio, Yoshua & Courville, Aaron (2016). *Deep Learning*. Cambridge, MA: MIT Press.
- High-Level Expert Group on Artificial Intelligence (2019). *Ethics Guidelines for Trustworthy AI*. Brussels: European Commission. URL: <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>.
- Isaak, Jim & Hanna, Mina J. (2018). „User Data Privacy: Facebook, Cambridge Analytica, and Privacy Protection“. In: *Computer* 51.8, S. 56–59. DOI: 10.1109/MC.2018.3191268.
- Jordan, Michael I. & Mitchell, Tom M. (2015). „Machine Learning: Trends, Perspectives, and Prospects“. In: *Science* 349.6245, S. 255–260. DOI: 10.1126/science.aaa8415.
- Kaptein, Maurits u. a. (2015). „Personalizing Persuasive Technologies: Explicit and Implicit Personalization Using Persuasion Profiles“. In: *International Journal of Human-Computer Studies* 77, S. 38–51. DOI: 10.1016/j.ijhcs.2015.01.004.
- Kelm, Ole, Dohle, Marco & Bernhard, Uli (2023). „How Algorithmically Curated Online Environments Influence Political Polarization: Evidence From Two Experimental Studies“. In: *New Media & Society*. DOI: 10.1177/14614448231180584.
- Kitchin, Rob (2014). *The Data Revolution: Big Data, Open Data, Data Infrastructures and Their Consequences*. London: SAGE Publications.

- Kramer, Adam D. I., Guillory, Jamie E. & Hancock, Jeffrey T. (2014). „Experimental Evidence of Massive-Scale Emotional Contagion Through Social Networks“. In: *Proceedings of the National Academy of Sciences* 111.24, S. 8788–8790. DOI: 10.1073/pnas.1320040111.
- Laudon, Kenneth C. & Laudon, Jane P. (2018). *Management Information Systems: Managing the Digital Firm, Global Edition*. 15. Aufl. Harlow: Pearson Education Limited.
- Lyon, David (2012). *Surveillance Studies: An Overview*. Cambridge: Polity Press.
- Metzler, Hannah & Garcia, David (2023). „Social Drivers and Algorithmic Mechanisms on Digital Media“. In: *Perspectives on Psychological Science* 18.3, S. 728–750. DOI: 10.1177/17456916221109892.
- Mitchell, Tom M. (1997). *Machine Learning*. New York: McGraw-Hill.
- Narayanan, Arvind (2023). *Understanding Social Media Recommendation Algorithms*. New York: Knight First Amendment Institute.
- National Institute of Standards and Technology (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. NIST AI 100-1. Gaithersburg, MD: U.S. Department of Commerce. DOI: 10.6028/NIST.AI.100-1.
- O’Neil, Cathy (2016). *Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy*. New York: Crown.
- OECD (2013). *Exploring the Economics of Personal Data: A Survey of Methodologies for Measuring Monetary Value*. OECD Digital Economy Papers 220. Paris: Organisation for Economic Co-operation und Development. DOI: 10.1787/5k486qtxldmq-en.
- Orben, Amy & Przybylski, Andrew K. (2019). „The Association Between Adolescent Well-Being and Digital Technology Use“. In: *Nature Human Behaviour* 3.2, S. 173–182. DOI: 10.1038/s41562-018-0506-1.
- Pariser, Eli (2011). *The Filter Bubble: What the Internet Is Hiding from You*. New York: Penguin Press.
- Parker, Geoffrey G., Van Alstyne, Marshall W. & Choudary, Sangeet Paul (2016). *Platform Revolution: How Networked Markets Are Transforming the Economy and How to Make Them Work for You*. New York: W. W. Norton.
- Pasquale, Frank (2015). *The Black Box Society: The Secret Algorithms That Control Money and Information*. Cambridge, MA: Harvard University Press.
- Qiang, Xiao (2019). „The Road to Digital Unfreedom: President Xi’s Surveillance State“. In: *Journal of Democracy* 30.1, S. 53–67. DOI: 10.1353/jod.2019.0004.
- Rashidi, Maria u. a. (2018). „Decision Support Systems“. In: *Management of Information Systems*. 1. Aufl. London: IntechOpen.
- Russell, Stuart & Norvig, Peter (2010). *Artificial Intelligence: A Modern Approach*. 3. Aufl. Upper Saddle River, NJ: Pearson.
- Shipsey, R. (2010). *Information Systems Foundations of E-business*. London: University of London.
- Srnicek, Nick (2017). *Platform Capitalism*. Cambridge: Polity Press.

- Stair, Ralph M. & Reynolds, George W. (2010). *Principles of Information Systems: A Managerial Approach*. 9. Aufl. Australia: Course Technology Cengage Learning.
- Susser, Daniel, Roessler, Beate & Nissenbaum, Helen (2019). „Online Manipulation: Hidden Influences in a Digital World“. In: *Georgetown Law Technology Review* 4.1, S. 1–45.
- Sutton, Richard S. & Barto, Andrew G. (2018). *Reinforcement Learning: An Introduction*. 2. Aufl. Cambridge, MA: MIT Press.
- Tiwana, Amrit (2014). *Platform Ecosystems: Aligning Architecture, Governance, and Strategy*. Waltham, MA: Morgan Kaufmann.
- U.S.-China Economic and Security Review Commission (2020). *China's Social Credit System: Speculation vs. Reality*. Staff Research Report. Washington, DC: Senate Foreign Relations Committee.
- Woolley, Samuel C. & Howard, Philip N. (2017). „Computational Propaganda Worldwide: Executive Summary“. In: *Working Paper Series on Computational Propaganda*. Oxford: Oxford Internet Institute.
- Yeung, Karen (2017). „Hypermudge: Big Data as a Mode of Regulation by Design“. In: *Information, Communication & Society* 20.1, S. 118–136. DOI: 10.1080/1369118X.2016.1186713.
- Zuboff, Shoshana (2019). *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*. New York: PublicAffairs.

Ehrenwörtliche Erklärung

Hiermit versichere ich, dass die vorliegende Arbeit von mir selbstständig und ohne unerlaubte Hilfe angefertigt worden ist, insbesondere, dass ich alle Stellen, die wörtlich oder annähernd wörtlich aus Veröffentlichungen entnommen sind, durch Zitate als solche gekennzeichnet habe. Ich versichere auch, dass die von mir eingereichte schriftliche Version mit der digitalen Version übereinstimmt. Weiterhin erkläre ich, dass die Arbeit in gleicher oder ähnlicher Form noch keiner Prüfungsbehörde/Prüfungsstelle vorgelegen hat. Ich erkläre mich damit einverstanden, dass die Arbeit der Öffentlichkeit zugänglich gemacht wird. Ich erkläre mich damit einverstanden, dass die Digitalversion dieser Arbeit zwecks Plagiatsprüfung auf die Server externer Anbieter hochgeladen werden darf. Die Plagiatsprüfung stellt keine Zurverfügungstellung für die Öffentlichkeit dar.

(Ort, Datum)

(Eigenhändige Unterschrift)