



FOM Hochschule für Oekonomie & Management

Hochschulzentrum Frankfurt a. M.

Bachelor-Thesis

im Studiengang Wirtschaftsinformatik

zur Erlangung des Grades eines
Bachelor of Science (B.Sc.)

über das Thema

Wie funktionieren KI-gestützte Monitoring-Systeme als digitale Informationssysteme und inwiefern ermöglichen sie datenbasierte Analyse und Beeinflussung von Verhalten?

von

Meshan Fernando

Erstgutachter/in

Dr. phil. Patrick Hedfeld

Matrikelnummer

617993

Abgabedatum

22.06.2026

Inhaltsverzeichnis

I.	Abbildungsverzeichnis	IV
II.	Abkürzungsverzeichnis	V
III.	Formelverzeichnis	VI
IV.	Tabellenverzeichnis	VII
1.	Einleitung	1
1.1	Problemstellung	1
1.2	Zielsetzung und Forschungsfrage	2
1.3	Methodisches Vorgehen	3
1.4	Aufbau der Arbeit	4
2.	Theoretische und technologische Grundlagen	5
2.1	Künstliche Intelligenz und Machine Learning	5
2.1.1	Grundbegriffe	5
2.1.2	Überwachungs- und Analyseverfahren	5
2.1.3	Empfehlungssysteme, Predictive Analytics und Verhaltenssteuerung	7
2.2	Digitale Informationssysteme	8
2.2.1	Funktionale Architektur KI-gestützter Monitoring-Systeme	9
2.2.2	Datenflüsse und Entscheidungslogiken	10
2.2.3	Plattformökosysteme	12
2.3	Monitoring- und Bewertungssysteme	14
2.3.1	Begriffliche und soziotechnische Einordnung	14
2.3.2	Datenerfassung	15
2.3.3	Analyse und Modellbildung	16
2.3.4	Algorithmische Bewertung und Klassifikation	17
2.4	Methodisches Vorgehen	18
2.4.1	Forschungsansatz	19
2.4.2	Literaturrecherche	19
2.4.3	Auswahlkriterien der Quellen	19
2.4.4	Methodische Grenzen	20
3.	KI-gestützte Monitoring-Systeme in digitalen Informationsumgebungen	21
3.1	Datenerfassung und digitale Verhaltensanalyse	21
3.1.1	Social-Media-Plattformen	21
3.1.2	Plattformökosysteme	22
3.1.3	Digitale Fußabdrücke und Nutzungsprofile	23
3.2	Algorithmische Steuerungs- und Bewertungsmechanismen	23
3.2.1	Personalisierung	24
3.2.2	Ranking-Algorithmen	24

III

3.2.3	Reputations- und Scoring-Systeme	25
3.2.4	Interaktionsoptimierung und Verhaltensprognosen	26
3.3	Vergleich unterschiedlicher Systemlogiken	26
3.3.1	Plattformzentrierte Systeme westlicher Plattformunternehmen .	27
3.3.2	Staatlich integrierte Monitoring-Systeme	28
3.3.3	Vergleich westlicher Plattformlogiken und staatlicher Monitoring- Systeme	28
4.	Sozioökonomische und gesellschaftliche Implikationen	30
4.1	Auswirkungen auf digitale Informationsumgebungen	31
4.2	Verhaltensdynamiken und Personalisierungseffekte	34
4.3	Ökonomische Interessen und Plattformlogiken	36
4.4	Politische und gesellschaftliche Einflussmechanismen	39
4.5	Governance- und Kontrollstrukturen	42
5.	Kritische Betrachtung	45
5.1	Grenzen der technologischen Analyse	46
5.2	Grenzen der Literaturbasis	47
5.3	Aussagekraft und methodische Limitationen	49
5.4	Normative und empirische Perspektiven	50
6.	Fazit und Ausblick	53
	Literaturverzeichnis	55

I Abbildungsverzeichnis

II Abkürzungsverzeichnis

AI	Artificial Intelligence
AIS	Association for Information Systems
DSGVO	Datenschutz-Grundverordnung
HMM	Hidden-Markov-Modell
KI	Künstliche Intelligenz
ML	Machine Learning
NLP	Natural Language Processing
SCS	Social Credit System

III Formelverzeichnis

IV Tabellenverzeichnis

1 Einleitung

Die fortschreitende Digitalisierung hat in den vergangenen Jahren zur Entstehung komplexer, datengetriebener Plattformökosysteme geführt, die nahezu alle Bereiche des gesellschaftlichen, wirtschaftlichen und politischen Lebens durchdringen. Soziale Netzwerke, Suchmaschinen und digitale Plattformen wie Google, TikTok, Meta oder X setzen zunehmend Künstliche Intelligenz (KI)-gestützte Systeme ein, um Nutzerverhalten zu erfassen, zu analysieren und gezielt zu beeinflussen. Durch algorithmische Steuerungsmechanismen und Interaktionsoptimierung werden Inhalte personalisiert, Aufmerksamkeit kanalisiert und Interaktionsmuster systematisch gelenkt.¹

Moderne KI-gestützte Personalisierungssysteme erzeugen individualisierte Informationsumgebungen, die Wahrnehmung, Meinungsbildung und Entscheidungsprozesse der Nutzer nachhaltig prägen können.² Die daraus resultierende Verhaltensbeeinflussung wirft Fragen hinsichtlich individueller Autonomie, informationeller Selbstbestimmung und demokratischer Willensbildung auf.³

Gleichzeitig zeigen wissenschaftliche Untersuchungen, dass algorithmisch gesteuerte Plattformen zur Verbreitung von Desinformation sowie zur Fragmentierung öffentlicher Diskurse beitragen können.⁴ Im Kontext des von Zuboff beschriebenen Überwachungs-kapitalismus werden diese Mechanismen für ökonomische Verwertungslogiken instrumentalisiert, während staatliche Akteure vergleichbare Technologien zur sozialen Kontrolle und politischen Steuerung einsetzen.⁵

Zudem ist festzustellen, dass viele dieser Systeme bislang nur unzureichend reguliert sind. Trotz weitreichender gesellschaftlicher Auswirkungen operieren algorithmische Monitoring- und Bewertungssysteme häufig in regulatorischen Grauzonen, in denen weder ausreichende Transparenzpflichten noch wirksame Kontrollmechanismen existieren.⁶

Vor diesem Hintergrund untersucht die vorliegende Arbeit, wie KI-gestützte Monitoring-Systeme als digitale Informationssysteme funktionieren und inwiefern sie datenbasierte Analyse und Beeinflussung menschlichen Verhaltens ermöglichen.

1.1 Problemstellung

Die zunehmende Durchdringung digitaler Lebenswelten durch algorithmische Systeme hat dazu geführt, dass Verhaltensbeeinflussung als strukturelles Merkmal moderner Platt-

¹Vgl. Srnicek(2017), S. 4.

²Vgl. Srnicek(2017), S. 4.

³Vgl. Zuboff(2019), S. 4.

⁴Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 17.

⁵Vgl. Pasquale(2015), S. 1.

⁶Vgl. Kitchin(2014), S. 1.

formökonomien betrachtet werden kann.⁷ Digitale Informationssysteme und KI-gestützte Plattformen erfassen kontinuierlich nutzerbezogene Daten und setzen diese mittels Machine Learning (ML)-basierter Analyseverfahren ein, um personalisierte Inhalte zu generieren, Nutzerverhalten zu prognostizieren und Interaktionen gezielt zu steuern.⁸

Die dabei eingesetzten Mechanismen der Interaktionsoptimierung zielen primär auf die Maximierung von Verweildauer, Interaktionsraten und datenbasierter Monetarisierung ab. Empfehlungssysteme, Ranking-Algorithmen und personalisierte Werbesysteme bilden die technologische Grundlage einer umfassenden algorithmischen Steuerung, die über neutrale Informationsvermittlung hinausgeht.⁹

Parallel dazu gewinnen staatlich geprägte Überwachungs- und Bewertungssysteme an Bedeutung. Im Kontext des chinesischen Social Credit System (SCS) wird deutlich, wie datenbasierte Monitoring-Infrastrukturen mit Mechanismen sozialer Bewertung und Verhaltensregulierung verknüpft werden können.¹⁰ Die Konvergenz kommerzieller und staatlicher Überwachungslogiken verdeutlicht die gesellschaftspolitische Tragweite algorithmischer Monitoring-Systeme.¹¹

Aus wissenschaftlicher Perspektive ergeben sich hieraus mehrere zentrale Problemfelder: Erstens erschwert die Intransparenz proprietärer Algorithmen eine unabhängige Bewertung ihrer Wirkungsmechanismen.¹² Zweitens werden Desinformationsdynamiken und soziale Fragmentierung durch algorithmische Verstärkungseffekte begünstigt.¹³ Drittens erweisen sich bestehende regulatorische Rahmen als unzureichend, um den Herausforderungen algorithmischer Verhaltensbeeinflussung angemessen zu begegnen.¹⁴

Die vorliegende Arbeit adressiert diese Problemstellung durch eine systematische Untersuchung der Funktionsweise, Wirkungsmechanismen und gesellschaftlichen Implikationen KI-gestützter Monitoring-Systeme.

1.2 Zielsetzung und Forschungsfrage

Ziel der vorliegenden Arbeit ist die systematische Untersuchung KI-gestützter Monitoring-Systeme als digitale Informationssysteme sowie die Analyse ihrer Möglichkeiten zur datenbasierten Erfassung, Bewertung und Beeinflussung menschlichen Verhaltens.

Im Mittelpunkt stehen dabei folgende Untersuchungsschwerpunkte: die technologischen Grundlagen algorithmischer Steuerung und Interaktionsoptimierung, die Mechanismen der Verhaltensbeeinflussung durch KI-gestützte Personalisierungssysteme, die Rolle von

⁷Vgl. Zuboff(2019), S. 4.

⁸Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 20.

⁹Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 27.

¹⁰Vgl. Zuboff(2019), S. 4.

¹¹Vgl. Woolley & Howard(2017), S. 1.

¹²Vgl. Srnicek(2017), S. 19.

¹³Vgl. Pasquale(2015), S. 4.

¹⁴Vgl. O’Neil(2016), S. 2.

Desinformation und sozialer Fragmentierung im Kontext algorithmischer Plattformlogiken, die ökonomischen Verwertungsstrukturen des Überwachungskapitalismus sowie die Möglichkeiten politischer Einflussnahme durch datenbasierte Monitoring-Systeme.¹⁵

Darüber hinaus werden auf Grundlage der Literaturanalyse Hypothesen zur Wirkungsweise algorithmischer Monitoring-Systeme formuliert, die als Ausgangspunkt für weiterführende empirische Forschung dienen können.

Die zentrale Forschungsfrage der Arbeit lautet:

„Wie funktionieren KI-gestützte Monitoring-Systeme als digitale Informationssysteme und inwiefern ermöglichen sie datenbasierte Analyse und Beeinflussung menschlichen Verhaltens?“

Zur Beantwortung dieser Forschungsfrage wird ein literaturbasierter, konzeptionell-analytischer Forschungsansatz verfolgt. Die Untersuchung stützt sich auf eine systematische Literaturrecherche und theoriegeleitete Analyse wissenschaftlicher Fachliteratur aus den Bereichen KI, digitale Informationssysteme, Plattformökonomie, algorithmische Überwachung sowie Verhaltens- und Kommunikationsforschung.

1.3 Methodisches Vorgehen

Die vorliegende Arbeit folgt einem literaturbasierten, konzeptionell-analytischen Forschungsansatz. Es wird keine empirische Datenerhebung durchgeführt. Stattdessen werden wissenschaftliche Publikationen systematisch ausgewertet, um die Funktionsweise KI-gestützter Monitoring-Systeme sowie deren sozioökonomische Implikationen zu analysieren.

Die Wahl dieses methodischen Vorgehens begründet sich durch den soziotechnischen Charakter des Untersuchungsgegenstandes: KI-gestützte Monitoring-Systeme operieren als proprietäre Systeme, deren interne Algorithmen und Datenstrukturen für externe Forschung nicht unmittelbar zugänglich sind.¹⁶ Eine literaturbasierte Analyse ermöglicht es, bestehende wissenschaftliche Erkenntnisse systematisch zusammenzuführen und in einen kohärenten analytischen Rahmen zu überführen.

Die Literaturrecherche orientiert sich an den Grundsätzen systematischer Literaturanalysen. Zur Identifikation relevanter Quellen werden wissenschaftliche Datenbanken wie Google Scholar, SpringerLink, IEEE Xplore, ACM Digital Library sowie Web of Science herangezogen. Die Auswahl der Literatur erfolgt anhand definierter Kriterien hinsichtlich wissenschaftlicher Qualität, thematischer Relevanz, Aktualität und methodischer Transparenz.

Die Analyse der identifizierten Literatur erfolgt durch thematische Kategorisierung und systematische Synthese. Dabei werden technologische Systemstrukturen, Datenverarbei-

¹⁵Vgl. Bradshaw & Howard(2018), S. 1.

¹⁶Vgl. Pasquale(2015), S. 1.

tungsmechanismen und sozioökonomische Wirkungszusammenhänge herausgearbeitet und in Bezug zur Forschungsfrage gesetzt.

1.4 Aufbau der Arbeit

Die vorliegende Bachelorarbeit gliedert sich in sechs Kapitel, die aufeinander aufbauend die Forschungsfrage systematisch bearbeiten.

Kapitel 2 behandelt die theoretischen und technologischen Grundlagen. Zunächst werden zentrale Begriffe und Konzepte aus den Bereichen KI, ML und digitale Informationssysteme erläutert. Anschließend werden Monitoring- und Bewertungssysteme sowie relevante Verfahren der Datenerfassung, algorithmischen Analyse und Klassifikation dargestellt.

Kapitel 3 untersucht KI-gestützte Monitoring-Systeme in digitalen Informationsumgebungen. Der Schwerpunkt liegt auf der Datenerfassung und digitalen Verhaltensanalyse innerhalb moderner Plattformökosysteme. Zudem werden algorithmische Steuerungs- und Bewertungsmechanismen wie Personalisierung, Ranking-Algorithmen, Reputations- und Scoring-Systeme sowie Interaktionsoptimierung analysiert. Abschließend erfolgt ein Vergleich unterschiedlicher Systemlogiken zwischen plattformzentrierten und staatlich integrierten Monitoring-Systemen.

Kapitel 4 widmet sich den sozioökonomischen und gesellschaftlichen Implikationen algorithmischer Monitoring-Systeme. Dabei werden Auswirkungen auf digitale Informationsumgebungen, Verhaltensdynamiken, ökonomische Plattformlogiken sowie politische und gesellschaftliche Einflussmechanismen betrachtet. Darüber hinaus werden Governance- und Kontrollstrukturen diskutiert.

Kapitel 5 bietet eine kritische Betrachtung der Arbeit, einschließlich der Grenzen der technologischen Analyse, der Literaturbasis sowie methodischer Limitationen.

Kapitel 6 fasst die zentralen Erkenntnisse zusammen, beantwortet die Forschungsfrage und gibt einen Ausblick auf zukünftige Entwicklungen im Bereich KI-gestützter Monitoring-Systeme und digitaler Informationssysteme.

2 Theoretische und technologische Grundlagen

2.1 Künstliche Intelligenz und Machine Learning

Dieses Kapitel vermittelt die technologischen Grundlagen, die für das Verständnis von KI-gestütztem Monitoring und algorithmischer Governance notwendig sind.

2.1.1 Grundbegriffe

Künstliche Intelligenz (KI) befasst sich im Kern mit der Frage, wie Maschinen eine Welt, die weit größer und komplizierter ist als sie selbst, wahrnehmen, verstehen, vorhersagen und manipulieren können.¹⁷ Ein zentrales Konzept ist hierbei der rationale Agent, der seine Umwelt durch Sensoren wahrnimmt und über Aktuatoren darauf einwirkt. Ein solcher Agent gilt als rational, wenn er für jede mögliche Wahrnehmungssequenz eine Aktion wählt, die unter Berücksichtigung seines Wissens das erwartete Leistungsmaß maximiert.¹⁸

Machine Learning (ML) ist ein Teilbereich der KI, der es Systemen ermöglicht, sich an neue Umstände anzupassen sowie Muster in Daten zu erkennen und zu extrapolieren.¹⁹ Die Quellen unterscheiden dabei drei wesentliche Lernparadigmen:

- **Überwachtes Lernen (Supervised Learning):** Das System lernt Funktionen auf Basis von markierten Beispieldaten (Inputs und Zielvorgaben).²⁰
- **Unüberwachtes Lernen (Unsupervised Learning):** Hierbei werden Kategorien oder Strukturen in Sammlungen nicht etikettierter Daten erkannt, beispielsweise durch Clustering.²¹
- **Bestärkendes Lernen (Reinforcement Learning):** Ein Agent lernt durch Interaktion mit einer Umgebung, indem er für seine Aktionen Belohnungen oder Bestrafungen erhält, um eine optimale Strategie zu entwickeln.²²

2.1.2 Überwachungs- und Analyseverfahren

Der funktionale Kern KI-gestützter Monitoring-Systeme liegt in der Fähigkeit, massive Mengen an Rohdaten systematisch in analysierbare Ergebnisse zu transformieren. Als konzeptionelle Synthese dieser Arbeit wird hierfür eine Prozesskette definiert, die von der Erfassung heterogener Datenquellen über die Aufbereitung und Merkmalsextraktion bis hin zur Anwendung mathematischer Modelle reicht. Die daraus resultierenden Analyseergebnisse dienen als notwendige Informationsgrundlage für algorithmische Bewertungen

¹⁷Vgl. Russell & Norvig(2010), S. 2.

¹⁸Vgl. Russell & Norvig(2010), S. 24.

¹⁹Vgl. Goodfellow, Bengio & Courville(2016), S. 95.

²⁰Vgl. Goodfellow, Bengio & Courville(2016), S. 95.

²¹Vgl. Goodfellow, Bengio & Courville(2016), S. 95.

²²Vgl. Sutton & Barto(2018), S. 1 ff..

oder automatisierte Entscheidungen, wobei nicht jedes Analyseergebnis zwingend in eine unmittelbare Systemreaktion münden muss.

Monitoring-Systeme verarbeiten hierbei unterschiedliche Datentypen, die eine differenzierte Vorbehandlung erfordern. Es wird zwischen strukturierten Transaktions- und Profildaten, unstrukturierten Text-, Bild- und Audiodaten sowie zeitbezogenen Sensor- und Interaktionsdaten unterschieden. Während strukturierte Daten in fest definierten Formaten vorliegen, müssen unstrukturierte Informationen zunächst durch spezialisierte Verfahren erschlossen werden.²³ In der Praxis sind diese Daten häufig mit Fehlern behaftet, enthalten Inkonsistenzen oder fehlende Attributwerte, was eine systematische Datenbereinigung und Datenaufbereitung notwendig macht.²⁴ Ein wesentlicher Bestandteil dieser Vorbereitungsphase ist zudem die Zusammenführung fragmentierter digitaler Fußabdrücke zu umfassenden Nutzungsprofilen, die eine ganzheitliche Analyse ermöglichen.²⁵

Die Transformation der aufbereiteten Daten in ein für Algorithmen nutzbares Format erfolgt durch das Feature Engineering. Hierbei werden Merkmale ausgewählt, transformiert oder neu konstruiert, die für das jeweilige Analyseverfahren geeignet sind. Moderne Deep-Learning-Verfahren erlauben es dabei zunehmend, relevante Repräsentationen direkt aus den Rohdaten zu erlernen, anstatt diese manuell definieren zu müssen.²⁶ Wissenschaftlich ist zudem präzise zwischen dem Modelltraining und der Anwendung des trainierten Modells zu trennen. In der Trainingsphase lernt das System auf Basis historischer Datenbestände eine mathematische Funktion, welche Eingabewerte auf gewünschte Ausgabewerte abbildet. In der anschließenden Anwendungsphase nutzt das System dieses gespeicherte Wissen, um neue, bisher unbekannte Datenpunkte automatisiert zu bewerten.²⁷

Innerhalb des Monitorings kommen je nach Erkenntnisziel verschiedene analytische Kernverfahren zum Einsatz. Die Klassifikation ordnet Datenpunkte vordefinierten Kategorien zu, beispielsweise zur Identifikation von Betrugsmustern.²⁸ Im Gegensatz dazu schätzen Regression und Wahrscheinlichkeitsprognosen kontinuierliche Werte, um etwa die Klickwahrscheinlichkeit eines Nutzers für einen bestimmten Inhalt zu berechnen.²⁹ Zur Identifikation natürlicher Gruppierungen oder zur Nutzersegmentierung werden Clustering-Verfahren eingesetzt, die Muster in Datenbeständen erkennen, ohne dass vorab definierte Kategorien existieren müssen.³⁰ Ergänzt werden diese Verfahren durch das Natural Language Processing (NLP), das mittels Sentiment Analysis emotionale Zustände oder Einstellungen aus Textdaten statistisch erfassbar macht.³¹ Für die Analyse von Prozes-

²³Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 1.

²⁴Vgl. Mitchell(1997), S. 4.

²⁵Vgl. Kitchin(2014), S. 1.

²⁶Vgl. Goodfellow, Bengio & Courville(2016), S. 5.

²⁷Vgl. Mitchell(1997), S. 5.

²⁸Vgl. Jordan & Mitchell(2015), S. 1.

²⁹Vgl. Russell & Norvig(2010), S. 698.

³⁰Vgl. Goodfellow, Bengio & Courville(2016), S. 95.

³¹Vgl. Russell & Norvig(2010), S. 855.

sen, die sich über die Zeit entwickeln, eignen sich zudem zeitbezogene Modelle wie Hidden-Markov-Modells (HMMs).³²

Ein zentraler Aspekt der algorithmischen Analyse ist die Erzeugung von Scores, die zunächst als numerische Werte oder Wahrscheinlichkeiten vorliegen. Eine endgültige Klassifikation oder die Ableitung einer Intervention erfolgt erst durch die Anwendung spezifischer Schwellenwerte oder Entscheidungsregeln auf diese Scores.³³ Die Zuverlässigkeit dieser Ergebnisse wird durch Metriken der Modellqualität gemessen, wobei insbesondere das Verhältnis von Fehlklassifikationen, wie False Positives und False Negatives, eine entscheidende Rolle für die Genauigkeit des Systems spielt.³⁴

Aus technischer Perspektive stellt die Datenqualität eine dauerhafte Herausforderung dar. Wenn die zugrunde liegenden Trainingsdaten nicht repräsentativ sind oder systematische Verzerrungen enthalten, werden diese durch den algorithmischen Prozess verstärkt und führen zu fehlerhaften Modellen.³⁵ Ein unzureichendes Monitoring der Modellleistung kann zudem dazu führen, dass die Übertragbarkeit des Modells auf neue Kontexte abnimmt.³⁶ Zusammenfassend folgt die Analyse der Logik: Rohdaten → Aufbereitung → Merkmale → Modell → Klassifikation, Prognose oder Score. Diese Ergebnisse bilden die Grundlage für Empfehlungssysteme, Rankings und automatisierte Entscheidungen, deren Auswirkungen auf die Verhaltensbeeinflussung im folgenden Abschnitt untersucht werden.

2.1.3 Empfehlungssysteme, Predictive Analytics und Verhaltenssteuerung

Predictive Analytics nutzt maschinelle Intelligenz, um Vorhersagen über menschliches Verhalten zu erstellen, wobei diese Vorhersagen umso wertvoller werden, je näher sie der Gewissheit kommen.³⁷ Diese Systeme basieren oft auf Wahrscheinlichkeitsmodellen wie Bayesschen Netzen, die Abhängigkeiten zwischen Variablen darstellen, um auch unter Unsicherheit fundierte Schlüsse ziehen zu können.³⁸

Die Grundlage moderner Predictive-Analytics-Systeme besteht häufig in der kontinuierlichen Auswertung großer Mengen historischer und aktueller Verhaltensdaten. Ziel ist die Identifikation von Mustern, Zusammenhängen und Wahrscheinlichkeiten zukünftiger Handlungen. Die Qualität solcher Vorhersagen steigt dabei in der Regel mit der Menge und Aktualität der verfügbaren Daten.³⁹

Empfehlungssysteme sind eine spezifische Anwendung, bei der Algorithmen die Präferenzen eines Nutzers mit denen anderer abgleichen, um relevante Informationen oder

³²Vgl. Russell & Norvig(2010), S. 556.

³³Vgl. Pasquale(2015), S. 1.

³⁴Vgl. Goodfellow, Bengio & Courville(2016), S. 412.

³⁵Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 18.

³⁶Vgl. National Institute of Standards and Technology(2023), S. 19.

³⁷Vgl. Zuboff(2019), S. 4.

³⁸Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 1.

³⁹Vgl. National Institute of Standards and Technology(2023), S. 19.

kulturelle Inhalte vorzuschlagen.⁴⁰

Empfehlungssysteme basieren häufig auf Verfahren des kollaborativen Filterns, der Inhaltsanalyse oder hybriden Ansätzen. Dabei werden Nutzerpräferenzen analysiert, um relevante Inhalte, Produkte oder Informationen vorzuschlagen. Solche Systeme finden Anwendung in sozialen Netzwerken, Streaming-Plattformen, Suchmaschinen und E-Commerce-Systemen.⁴¹

Zwischen Nutzer und Plattform entstehen dabei kontinuierliche Rückkopplungsschleifen. Jede Interaktion eines Nutzers erzeugt neue Daten, welche zur Verbesserung zukünftiger Vorhersagen und Empfehlungen genutzt werden. Dieser Prozess ermöglicht eine fortlaufende Optimierung algorithmischer Modelle und eine zunehmend präzisere Analyse individuellen Verhaltens.⁴²

In der Logik des sogenannten Überwachungskapitalismus werden solche Systeme genutzt, um aus „Verhaltensüberschüssen“ Vorhersageprodukte zu fertigen, die in speziellen Märkten für zukünftiges Verhalten gehandelt werden.⁴³ Das Ziel ist hierbei oft nicht nur die Vorhersage, sondern die Verhaltensmodifikation, um garantierte kommerzielle Ergebnisse zu erzielen.⁴⁴

Aus Sicht digitaler Plattformen beschränkt sich die Nutzung solcher Systeme nicht ausschließlich auf die Vorhersage zukünftigen Verhaltens. Vielmehr können algorithmische Empfehlungen, Rankings und Personalisierungsmechanismen genutzt werden, um Aufmerksamkeit zu lenken, Interaktionen zu fördern und bestimmte Verhaltensweisen wahrscheinlicher zu machen. Die Übergänge zwischen Verhaltensprognose und Verhaltensbeeinflussung bilden dabei einen zentralen Untersuchungsgegenstand dieser Arbeit.⁴⁵

2.2 Digitale Informationssysteme

Das Verständnis KI-gestützter Monitoring-Systeme setzt eine fundierte Auseinandersetzung mit der theoretischen Basis digitaler Informationssysteme voraus. In der Wirtschaftsinformatik werden diese Systeme nicht als rein technologische Artefakte begriffen, sondern als soziotechnische Gefüge, in denen technologische und organisatorische Komponenten zur Erreichung spezifischer Ziele zusammenwirken.⁴⁶

Im Zentrum steht das funktionale Zusammenspiel von Datenerfassung, Verarbeitung, Analyse und Entscheidungslogik. Dabei ist weniger die konkrete technische Implementierung entscheidend als die Frage, wie Daten, Infrastrukturen, organisatorische Ziele und mensch-

⁴⁰Vgl. Adomavicius & Tuzhilin(2005), S. 1.

⁴¹Vgl. Adomavicius & Tuzhilin(2005), S. 1.

⁴²Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 1.

⁴³Vgl. Zuboff(2019), S. 4.

⁴⁴Vgl. National Institute of Standards and Technology(2023), S. 19.

⁴⁵Vgl. Adomavicius & Tuzhilin(2005), S. 1.

⁴⁶Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 20.

liche Akteure miteinander verknüpft sind.⁴⁷ Plattformökosysteme bilden dabei einen organisatorischen und technologischen Rahmen, in dem Datenerfassung, Analyse und algorithmische Entscheidungen zusammengeführt werden. Diese Einordnung schafft die Grundlage für die anschließende Betrachtung von Monitoring- und Bewertungssystemen als spezifische Ausprägung digitaler Informationssysteme.

2.2.1 Funktionale Architektur KI-gestützter Monitoring-Systeme

Die funktionale Architektur KI-gestützter Monitoring-Systeme kann als eine idealtypische Struktur miteinander verknüpfter Komponenten verstanden werden, die innerhalb eines soziotechnischen Rahmens operieren. In der Wirtschaftsinformatik wird ein Informationssystem nicht allein als technisches Artefakt betrachtet, sondern als ein Gefüge aus Technologie, organisatorischen Strukturen und menschlichen Akteuren, die zur Erreichung spezifischer Ziele zusammenwirken.⁴⁸ Die funktionale Organisation beschreibt dabei, wie Daten erfasst, bereitgestellt, analysiert und gegebenenfalls für Bewertungen oder Entscheidungen genutzt werden.

Den Ausgangspunkt bildet die Datenerfassung als Schnittstelle zur überwachten Umwelt. Dabei können strukturierte Transaktions- und Profildaten, unstrukturierte Text- und Bilddaten sowie zeitbezogene Interaktions- oder Sensordaten aufgenommen werden.⁴⁹ Die Daten können beispielsweise aus Nutzerinteraktionen, digitalen Plattformen, mobilen Endgeräten, Transaktionen oder technischen Sensoren stammen. Innerhalb des funktionalen Modells bilden diese Beobachtungen die Eingabebasis für die nachfolgenden Verarbeitungsschritte.⁵⁰

An die Erfassung schließt sich die Datenintegration und Bereitstellung an. Da Monitoring-Daten häufig aus unterschiedlichen Quellen und in verschiedenen Formaten vorliegen, müssen sie zusammengeführt, bereinigt und für die weitere Verarbeitung verfügbar gemacht werden. Ziel ist die Schaffung einer konsistenten Datenbasis, auf die Analyseverfahren und Modelle zugreifen können. Die konkrete technische Umsetzung kann dabei zentral, verteilt oder cloudbasiert erfolgen. Für die funktionale Betrachtung ist jedoch nicht die verwendete Speichertechnologie entscheidend, sondern die zuverlässige Bereitstellung der benötigten Daten.⁵¹

Den analytischen Kern der Architektur bildet die Analyse- und Modellkomponente. Verfahren des maschinellen Lernens und der statistischen Analyse werden eingesetzt, um Merkmale, Regelmäßigkeiten und Zusammenhänge in den bereitgestellten Daten zu identifizieren.⁵² Die daraus erzeugten Modelle stellen ausgewählte Aspekte der überwachten

⁴⁷Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 27.

⁴⁸Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 20.

⁴⁹Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 1.

⁵⁰Vgl. Russell & Norvig(2010), S. 24.

⁵¹Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 1.

⁵²Vgl. Goodfellow, Bengio & Courville(2016), S. 95.

Umwelt, von Prozessen oder des Nutzerverhaltens in einer maschinenlesbaren Form dar. Sie können als Grundlage für Prognosen, Zustandsbewertungen oder die Erkennung auffälliger Muster dienen.

Auf Grundlage dieser Analyseergebnisse kann eine Bewertungs- oder Entscheidungskomponente eingesetzt werden. Dabei werden Ergebnisse beispielsweise anhand festgelegter Regeln, Kategorien oder Schwellenwerte weiterverarbeitet. Mögliche Ausgaben sind Wahrscheinlichkeiten, Scores, Klassifikationen, Rankings oder Entscheidungsvorschläge. Diese können sich auf Personen, Inhalte, Transaktionen, Ereignisse oder technische Systemzustände beziehen.⁵³ Nicht jedes Analyseergebnis führt jedoch automatisch zu einer Entscheidung oder einer unmittelbaren Systemreaktion.

Eine mögliche Interventions- oder Ausgabekomponente überführt ausgewählte Ergebnisse in eine sichtbare Handlung des Systems. Dazu können Warnmeldungen, Berichte, Empfehlungen, personalisierte Inhalte, Rankings oder automatisierte Reaktionen gehören. Ob eine solche Intervention erfolgt, hängt von der konkreten Ausgestaltung und Zielsetzung des Systems ab. Rein deskriptive Monitoring-Systeme können Ergebnisse lediglich darstellen, während adaptive Systeme aktiv auf die überwachte Umgebung einwirken.

Reaktionen von Nutzern oder Veränderungen innerhalb der überwachten Umgebung können wiederum neue Daten erzeugen. Dadurch entsteht eine mögliche Rückkopplung, durch die Profile, Zustände oder Bewertungen aktualisiert werden. Diese Aktualisierung ist jedoch vom erneuten Training eines Modells zu unterscheiden. Neue Beobachtungen führen nicht zwangsläufig zu einer Veränderung der zugrunde liegenden Modellparameter oder zu einem kontinuierlich selbstständig lernenden System. Die Modellleistung und ihre Übertragbarkeit auf neue Daten müssen vielmehr regelmäßig überprüft werden.⁵⁴

Die funktionalen Komponenten sind in organisatorische Zielsetzungen, Regeln und Verantwortlichkeiten eingebettet, die von menschlichen Akteuren gestaltet und kontrolliert werden.⁵⁵ Welche Daten erhoben, welche Modelle eingesetzt und welche Systemreaktionen zugelassen werden, ist daher nicht allein eine technische Entscheidung. Entscheidend für das Zusammenwirken der Komponenten ist, wie Daten zwischen ihnen übertragen und nach welchen Regeln Analyseergebnisse in Bewertungen, Entscheidungen oder mögliche Handlungen überführt werden.

2.2.2 Datenflüsse und Entscheidungslogiken

Die Funktionsweise KI-gestützter Monitoring-Systeme beruht auf der Steuerung von Datenflüssen und deren Überführung in spezifische Entscheidungslogiken. Innerhalb dieser Informationssysteme durchlaufen Daten eine Transformationskette, die über die bloße Weiterleitung von Signalen hinausgeht. Der Prozess beginnt mit der Bereitstellung von

⁵³Vgl. Pasquale(2015), S. 1.

⁵⁴Vgl. National Institute of Standards and Technology(2023), S. 19.

⁵⁵Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 27.

Rohdaten, die entweder strukturiert, etwa als Transaktionsprotokolle, oder unstrukturiert, beispielsweise als Text- oder Bilddaten, vorliegen können.⁵⁶ Durch die anschließende Modellanwendung entstehen Analyseergebnisse, die beispielsweise als Wahrscheinlichkeiten, Prognosen oder Scores ausgegeben werden können. Zwischen diesem technischen Output und seiner anschließenden Bewertung ist begrifflich zu unterscheiden.

Eine Bewertung entsteht erst, wenn der Modelloutput durch spezifische Regeln, Schwellenwerte oder Kategorisierungen interpretiert wird. Hierbei wird den identifizierten Mustern eine Bedeutung im Kontext der organisatorischen Ziele zugeordnet.⁵⁷ So stellt beispielsweise ein berechneter Score zunächst nur einen numerischen Wert dar. Erst durch den Vergleich mit einem festgelegten Schwellenwert kann daraus etwa die Einstufung einer Transaktion als risikoreich oder eines Inhalts als relevant entstehen. Die auf diese Weise bewerteten Informationen können anschließend als Grundlage für Entscheidungen dienen.

Die Entscheidungslogik kann unterschiedliche Automatisierungsgrade aufweisen. Standardisierte und zeitkritische Entscheidungen können automatisiert erfolgen, während komplexe oder folgenreiche Entscheidungen eine menschliche Prüfung oder Freigabe erfordern können.⁵⁸ Dabei sind Kontrollinstanzen erforderlich, um die Grenzen algorithmischer Ergebnisse zu berücksichtigen und sicherzustellen, dass automatisierte Bewertungen die menschliche Autonomie nicht unangemessen einschränken.⁵⁹ Eine Entscheidung kann schließlich in eine Intervention münden, die als sichtbare Handlung des Systems in die Informationsumgebung eingreift. Beispiele hierfür sind die Bereitstellung personalisierter Empfehlungen, die Ausgabe einer Warnmeldung oder die Sperrung einer als risikoreich bewerteten Transaktion.

Die Ausgestaltung dieser Logiken wird maßgeblich durch organisatorische Ziele, Verantwortlichkeiten und Governance-Strukturen geprägt. Das soziotechnische Design bestimmt, welche Daten als relevant gelten, welche Kriterien bei ihrer Bewertung angewendet werden und welche Optimierungsziele die Systemlogik verfolgt.⁶⁰ Entscheidungen entstehen somit nicht allein aus technischen Modellen, sondern aus der Verknüpfung von Analyseergebnissen mit organisatorisch festgelegten Regeln und Zielsetzungen.

Ein weiteres mögliches Element ist die Rückkopplung durch neue Daten. Nutzerreaktionen oder Veränderungen innerhalb der überwachten Umgebung können zusätzliche Beobachtungen erzeugen, die jedoch nicht in jedem Fall unmittelbar verarbeitet werden. Neue Informationen können zur Aktualisierung eines Profils oder eines internen Systemzustands genutzt werden.⁶¹ Diese Aktualisierung ist von einem erneuten Training des Modells abzugrenzen. Beim erneuten Training werden die Modellparameter anhand neuer Daten

⁵⁶Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 1.

⁵⁷Vgl. Pasquale(2015), S. 1.

⁵⁸Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 1.

⁵⁹Vgl. National Institute of Standards and Technology(2023), S. 16.

⁶⁰Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 27.

⁶¹Vgl. Russell & Norvig(2010), S. 117.

angepasst. Eine Überwachung der Modellleistung kann Hinweise darauf liefern, ob eine solche Anpassung erforderlich ist.⁶²

In der Praxis sind Datenflüsse und Entscheidungslogiken selten auf eine einzelne geschlossene Anwendung beschränkt. Vielmehr verteilen sie sich häufig über komplexe Infrastrukturen, in denen unterschiedliche Dienste, technische Komponenten, Organisationen und Akteure zusammenwirken. Diese vernetzte Struktur der Datenverarbeitung bildet einen wesentlichen Bestandteil moderner Plattformökosysteme.

2.2.3 Plattformökosysteme

Die moderne Informationsökonomie wird maßgeblich durch digitale Plattformen geprägt, die in der Wirtschaftsinformatik als spezifische Geschäftsmodelle und technologische Architekturen begriffen werden. Eine digitale Plattform stellt eine erweiterbare Codebasis bereit, welche die Kernfunktionalität eines Systems definiert und über Schnittstellen mit ergänzenden Software-Subsystemen interagiert.⁶³ Das daraus resultierende Plattformökosystem umfasst die Gesamtheit der Akteure – den Plattformbetreiber, die Komplementoren sowie die Nutzer –, die auf Basis dieser technologischen Infrastruktur miteinander interagieren.⁶⁴ Im Gegensatz zu traditionellen Pipeline-Geschäftsmodellen, die Werte linear entlang einer Kette vom Hersteller zum Kunden schaffen, fungiert eine Plattform als modularer Rahmen, der wertschöpfende Interaktionen zwischen verschiedenen externen Gruppen ermöglicht.⁶⁵

Zentral für die Funktionsweise eines Plattformökosystems ist die Koordination von Interaktionen in mehrseitigen Märkten. Plattformen bringen dabei unterschiedliche Gruppen zusammen, die über die bereitgestellte Infrastruktur Transaktionen durchführen oder Informationen austauschen.⁶⁶ In der Literatur wird häufig zwischen Transaktionsplattformen, die als Vermittler auf Marktplätzen agieren, und Innovationsplattformen differenziert, die technologische Bausteine für die Entwicklung komplementärer Produkte und Dienste bereitstellen.⁶⁷ Die Rolle des Plattformbetreibers besteht darin, den technologischen und organisatorischen Rahmen zu schaffen, während Komplementoren die Funktionalität und den Nutzwert des Gesamtsystems durch spezialisierte Beiträge erweitern können.⁶⁸

Ein wesentlicher ökonomischer Treiber dieser Ökosysteme sind Netzwerkeffekte. Diese treten auf, wenn der Nutzen eines Systems für einen Teilnehmer von der Anzahl oder Aktivität anderer Nutzer abhängt.⁶⁹ Dabei wird zwischen direkten Netzwerkeffekten innerhalb einer Gruppe und indirekten beziehungsweise kreuzseitigen Effekten unterschieden, bei

⁶²Vgl. National Institute of Standards and Technology(2023), S. 19.

⁶³Vgl. Tiwana(2014), S. 1.

⁶⁴Vgl. Tiwana(2014), S. 1.

⁶⁵Vgl. Parker, Van Alstyne & Choudary(2016), S. 20.

⁶⁶Vgl. Tiwana(2014), S. 1.

⁶⁷Vgl. **Cusumano2019**, S. 18.

⁶⁸Vgl. Tiwana(2014), S. 1.

⁶⁹Vgl. Parker, Van Alstyne & Choudary(2016), S. 17.

denen die Zunahme einer Gruppe die Attraktivität der Plattform für eine andere Marktseite erhöht.⁷⁰ Solche positiven Rückkopplungen können zu einer Konzentration von Marktmacht beitragen. Eine Monopolisierung ist jedoch nicht zwingend, da differenzierte Wettbewerber oder spezialisierte Nischenanbieter die Dominanz etablierter Plattformen begrenzen können.⁷¹

Die Steuerung dieser komplexen Gefüge erfolgt über die Plattform-Governance. Diese legt Regeln, Zugänge und Verantwortlichkeiten innerhalb des Ökosystems fest. Der Plattformbetreiber definiert dabei nicht nur die technischen Schnittstellen, sondern regelt auch, welche Akteure teilnehmen dürfen und nach welchen Kriterien Interaktionen oder ergänzende Angebote zugelassen werden.⁷² Eine effektive Governance muss das Spannungsfeld zwischen technologischer Offenheit zur Förderung von Innovationen und der notwendigen Kontrolle zur Sicherstellung von Qualität und Vertrauen ausbalancieren.⁷³ Plattformen sind daher keine neutralen Räume, sondern technisch und organisatorisch gestaltete Umgebungen, deren Regeln die möglichen Interaktionen zwischen den beteiligten Akteuren strukturieren.

In diesem Kontext bilden Plattformökosysteme eine wichtige Einsatzumgebung für KI-gestützte Monitoring-Infrastrukturen. Da der Plattformbetreiber die technische Infrastruktur bereitstellt, über die ein erheblicher Teil der vermittelten Interaktionen erfolgt, nimmt er eine zentrale Position bei der Zusammenführung von Daten aus unterschiedlichen Diensten und Akteursgruppen ein.⁷⁴ Diese Daten können als strategische Ressource genutzt werden, um digitale Dienste anzupassen, Abläufe zu optimieren oder algorithmische Analyseverfahren zu unterstützen.⁷⁵ Plattformen schaffen damit eine Infrastruktur, innerhalb derer digitale Interaktionsdaten dienst- und akteursübergreifend zusammengeführt und für weiterführende Analysen bereitgestellt werden können.⁷⁶ Die konkrete Profilbildung und Verhaltensanalyse werden in den folgenden Abschnitten vertieft.

Zusammenfassend lässt sich festhalten, dass Plattformökosysteme einen infrastrukturellen und organisatorischen Rahmen schaffen, innerhalb dessen zahlreiche digitale Informationssysteme und datenbasierte Dienste operieren. Die Fähigkeit, Interaktionen zwischen heterogenen Gruppen zu koordinieren und Datenflüsse über verschiedene technische Komponenten hinweg zusammenzuführen, macht sie zu einer wichtigen Einsatzumgebung für Monitoring-, Analyse- und Bewertungssysteme. Wie solche Systeme Daten erfassen, analysieren und in Bewertungen überführen, ist Gegenstand des folgenden Abschnitts zu Monitoring- und Bewertungssystemen.

⁷⁰Vgl. Parker, Van Alstyne & Choudary(2016), S. 17.

⁷¹Vgl. **Cusumano2019**, S. 25.

⁷²Vgl. Parker, Van Alstyne & Choudary(2016), S. 3.

⁷³Vgl. Tiwana(2014), S. 1.

⁷⁴Vgl. Srnicek(2017), S. 19.

⁷⁵Vgl. Srnicek(2017), S. 20.

⁷⁶Vgl. Srnicek(2017), S. 19.

2.3 Monitoring- und Bewertungssysteme

Das Verständnis von KI-gestützten Monitoring-Systemen erfordert eine detaillierte Betrachtung der Prozesse, durch die Daten in verwertbare Informationen und schließlich in algorithmische Entscheidungen transformiert werden. Bevor die einzelnen Phasen dieses Prozesses im Detail analysiert werden, ist zunächst eine begriffliche und konzeptionelle Einordnung erforderlich, die das Monitoring-System als spezifische Ausprägung eines digitalen Informationssystems verortet.

2.3.1 Begriffliche und soziotechnische Einordnung

Ein Monitoring-System lässt sich als spezialisierte Ausprägung eines digitalen Informationssystems verstehen, dessen funktionaler Schwerpunkt auf der kontinuierlichen oder regelmäßigen Beobachtung und systematischen Auswertung von Zuständen, Prozessen oder Verhalten liegt.⁷⁷ Während die allgemeine soziotechnische und funktionale Architektur KI-gestützter Monitoring-Systeme bereits in Abschnitt 2.2.1 erläutert wurde, steht im Folgenden ihre begriffliche Einordnung im Mittelpunkt.

Für die Zwecke dieser Arbeit werden drei idealtypische Formen des Monitorings unterschieden. Deskriptives Monitoring beschränkt sich auf die Erfassung, Aufbereitung und Darstellung beobachteter Zustände. Analytisches und prädiktives Monitoring setzt zusätzlich Verfahren der Mustererkennung, Klassifikation oder Prognose ein, um weiterführende Informationen aus den erfassten Daten abzuleiten. Adaptives beziehungsweise interventionistisches Monitoring verknüpft die Analyseergebnisse schließlich mit möglichen Anpassungen der digitalen Umgebung. Diese Differenzierung ist idealtypisch, da reale Systeme mehrere Formen miteinander verbinden können. Monitoring impliziert zudem nicht zwangsläufig eine aktive Verhaltensbeeinflussung. Eine gezielte Steuerung entsteht erst dann, wenn Analyse- oder Bewertungsergebnisse mit Systementscheidungen und Interventionen verknüpft werden.⁷⁸

Von KI-gestütztem Monitoring wird in dieser Arbeit gesprochen, wenn lernende Modelle für mindestens eine zentrale Analysefunktion eingesetzt werden. Dazu können insbesondere die Erkennung von Mustern, die Klassifikation von Objekten oder Verhaltensweisen und die Prognose zukünftiger Ereignisse gehören.⁷⁹ Regelbasierte Komponenten können diese Modelle ergänzen, ohne dass dadurch die Einordnung des Gesamtsystems als KI-gestütztes Monitoring ausgeschlossen wird. Entscheidend ist, dass mindestens ein wesentlicher Analyseschritt auf einem aus Daten abgeleiteten Modell beruht.

Das Monitoring-Gesamtsystem ist dabei von seinen operativen Teilsystemen abzugrenzen. Empfehlungssysteme, Ranking-Verfahren, Scoring-Modelle und Predictive-Analytics-Module übernehmen jeweils spezifische Funktionen, stellen jedoch nicht das gesamte

⁷⁷Vgl. Lyon(2012), S. 2.

⁷⁸Vgl. Pasquale(2015), S. 1.

⁷⁹Vgl. Goodfellow, Bengio & Courville(2016), S. 95.

Monitoring-System dar.⁸⁰⁸¹ Sie können vielmehr als Komponenten in eine umfassendere Infrastruktur aus Datenerfassung, Datenbereitstellung, Analyse, Bewertung und möglichen Systemreaktionen eingebettet sein.

Als zentrale konzeptionelle Synthese dieser Arbeit wird ein idealtypischer Monitoring-Zyklus verwendet. Dieser umfasst die Phasen Datenerfassung → Datenaufbereitung und Profilbildung → Analyse → Prognose und Bewertung → mögliche algorithmische Intervention → erneute Datenerfassung. Das Modell dient der Strukturierung der nachfolgenden Untersuchung und bildet keine für alle realen Systeme verbindliche Abfolge ab. Einzelne Phasen können je nach Systemdesign fehlen oder unterschiedlich ausgeprägt sein. Insbesondere ist die algorithmische Intervention als optionale Komponente zu verstehen.

Die erneute Datenerfassung kann eine Rückkopplung ermöglichen und beispielsweise zur Aktualisierung eines Profils oder eines internen Systemzustands genutzt werden. Sie bedeutet jedoch nicht automatisch, dass die Parameter des zugrunde liegenden Modells kontinuierlich angepasst oder neu trainiert werden.⁸² Die folgenden Abschnitte vertiefen mit der Datenerfassung, der Analyse und Modellbildung sowie der algorithmischen Bewertung die zentralen Phasen dieses idealtypischen Zyklus.

2.3.2 Datenerfassung

Die Datenerfassung bildet die Schnittstelle eines Monitoring-Systems zur überwachten Umwelt und stellt den ersten Schritt innerhalb des idealtypischen Monitoring-Zyklus dar. In diesem Zusammenhang bezeichnet Datafizierung die Übersetzung ausgewählter Aspekte menschlichen Handelns und sozialer Prozesse in quantifizierbare und maschinenlesbare Daten.⁸³ In der Theorie des Überwachungskapitalismus beschreibt Zuboff eine spezifische kommerzielle Form dieser Transformation als „Rendition“, durch die menschliche Erfahrungen für datenbasierte Auswertungen verfügbar gemacht werden.⁸⁴ Diese Perspektive ist jedoch nicht auf jede Form der Datenerfassung übertragbar.

Die technologische Grundlage der Erfassung bilden unterschiedliche digitale Infrastrukturen. Daten können durch Interaktionen auf Plattformen, die Nutzung von Browsern und mobilen Anwendungen sowie durch Transaktionen entstehen. Darüber hinaus ermöglichen mobile Endgeräte, Wearables und eingebettete Sensoren die Erfassung physischer, räumlicher oder zeitbezogener Parameter.⁸⁵ Innerhalb eines funktionalen Agentenmodells bilden die auf diese Weise aufgenommenen Signale die Wahrnehmungen des Systems und damit die Eingabebasis für nachgelagerte Verarbeitungsschritte.⁸⁶

⁸⁰Vgl. Adomavicius & Tuzhilin(2005), S. 1.

⁸¹Vgl. Gillespie(2014), S. 1.

⁸²Vgl. Russell & Norvig(2010), S. 24.

⁸³Vgl. Dijck(2014), S. 1.

⁸⁴Vgl. Zuboff(2019), S. 223.

⁸⁵Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 1.

⁸⁶Vgl. Russell & Norvig(2010), S. 24.

Monitoring-Systeme können unterschiedliche Datenarten verarbeiten, die jeweils spezifische Anforderungen an Speicherung, Aufbereitung und Analyse stellen. Dazu zählen strukturierte Transaktions- und Profildaten, unstrukturierte Text-, Bild- und Audiodaten sowie zeitbezogene Sensor- und Interaktionsdaten. Eine weitere Unterscheidung betrifft die Entstehungsweise personenbezogener Informationen. Dabei kann zwischen freiwillig bereitgestellten Daten, beobachteten Daten und aus vorhandenen Informationen abgeleiteten Daten differenziert werden.⁸⁷ Freiwillig bereitgestellte Daten entstehen beispielsweise durch Profileingaben, während beobachtete Daten aus der tatsächlichen Nutzung eines Dienstes hervorgehen. Abgeleitete Daten entstehen dagegen erst durch analytische Schlussfolgerungen aus bereits vorhandenen Datenbeständen.

Erfassungsfrequenz, Granularität und Umfang der Datenbasis können je nach Systemarchitektur, Anwendungszweck, technischen Möglichkeiten, organisatorischen Regeln und rechtlichen Rahmenbedingungen erheblich variieren. Datenerfassung erfolgt daher weder zwangsläufig lückenlos noch immer in Echtzeit. Die entstehende Datenbasis bildet vielmehr eine selektive und kontextabhängige Repräsentation der überwachten Umwelt.

Nach der Erfassung können fragmentierte digitale Spuren aus unterschiedlichen Quellen zusammengeführt und für weitere Verarbeitungsschritte bereitgestellt werden.⁸⁸ Dabei entstehen jedoch noch keine vollständigen Nutzungsprofile oder belastbaren Aussagen über Verhalten. Erst die anschließende Analyse und Modellbildung verknüpft die erfassten Daten zu Profilen, Zustandsmodellen, Mustern oder Prognosen.

2.3.3 Analyse und Modellbildung

Nachdem die Daten erfasst und für die Analyse bereitgestellt wurden (vgl. Abschnitt 2.3.2), folgt die Phase der Modellbildung. In diesem Prozessschritt werden fragmentierte Datenpunkte systematisch zu Profilen, Zustandsmodellen und Mustern verknüpft, um eine datenbasierte Repräsentation der überwachten Umwelt oder der Nutzer zu erstellen.

Ein zentrales Element ist die Profilbildung aus historischen und aktuellen Datenbeständen. Durch die Aggregation zeitlich und räumlich verteilter digitaler Spuren entstehen umfassende Datensätze, die als digitale Dossiers charakterisiert werden.⁸⁹ Wissenschaftlich ist dabei zu betonen, dass solche Profile zweckgebundene, vereinfachte Repräsentationen sind und keine vollständige oder objektive Identität einer Person abbilden.⁹⁰ Sie dienen dazu, komplexe Informationen in maschinenlesbare Kategorien zu formalisieren, die für den jeweiligen Systemzweck relevant sind.

In komplexen Monitoring-Umgebungen ist das System häufig damit konfrontiert, dass entscheidende Merkmale nicht direkt beobachtbar sind. Zur Lösung dieser Herausforderung

⁸⁷Vgl. OECD(2013), S. 1.

⁸⁸Vgl. Kitchin(2014), S. 1.

⁸⁹Vgl. Kitchin(2014), S. 1.

⁹⁰Vgl. Gillespie(2014), S. 1.

wird die Methode der Zustandschätzung eingesetzt. Das System nutzt dabei eine Sequenz beobachtbarer Variablen, um Wahrscheinlichkeiten für nicht direkt beobachtbare, latente Zustände abzuleiten.⁹¹ Hierbei handelt es sich um probabilistische Schlussfolgerungen, nicht um gesicherte Tatsachen. So können beispielsweise eine vermutete Kaufabsicht oder spezifische Präferenzen lediglich als Wahrscheinlichkeitswerte innerhalb eines Modells existieren. Der hierbei aufrechterhaltene interne Zustand des Systems über seine Umwelt wird als Belief State bezeichnet. Dieser repräsentiert eine Wahrscheinlichkeitsverteilung über die Zustände, die auf Grundlage der bisherigen Beobachtungen als möglich gelten.⁹²

Die Identifikation von Regelmäßigkeiten erfolgt durch Mustererkennung und Segmentierung. Unter Einsatz statistischer Verfahren werden Ähnlichkeiten im Verhalten erkannt, die eine neutrale analytische Gruppierung von Objekten oder Nutzern ermöglichen.⁹³ Davon abzugrenzen ist die Anomalieerkennung, die darauf abzielt, Datenmuster zu identifizieren, die deutlich von einem erwarteten Muster oder einem etablierten Normalverhalten abweichen.⁹⁴

Innerhalb der Modellanwendung muss methodisch präzise zwischen der Aktualisierung eines Profils oder Systemzustands durch neue Beobachtungen und dem erneuten Training der Modellparameter unterschieden werden. Während die Aktualisierung den Belief State oder das Profil anhand neuer Beobachtungen an die aktuelle Evidenzlage anpasst⁹⁵, umfasst ein erneutes Training die Anpassung der Modellparameter anhand neuer oder aktualisierter Trainingsdaten. Es ist festzuhalten, dass nicht jedes Monitoring-System kontinuierlich lernt; vielmehr muss die Modellleistung regelmäßig überwacht werden, um die Übertragbarkeit auf neue Kontexte sicherzustellen.⁹⁶

Zusammenfassend lassen sich die erzeugten Analyseergebnisse als Informationsgrundlagen verstehen, die deskriptive Muster, Cluster, Wahrscheinlichkeiten, Prognosen oder Anomaliehinweise umfassen können. Diese Analyseergebnisse können als Eingaben für die nachfolgende algorithmische Bewertung und Klassifikation dienen (vgl. Abschnitt 2.3.4), in der sie anhand definierter Regeln, Kategorien oder Schwellenwerte interpretiert und gegebenenfalls in Systemsentscheidungen überführt werden können.

2.3.4 Algorithmische Bewertung und Klassifikation

Die algorithmische Bewertung bildet eine mögliche abschließende Verarbeitungsphase innerhalb des Monitoring-Zyklus, in der technische Analyseergebnisse in eine handlungsrelevante Form überführt werden können. Dabei ist zwischen dem technischen Modelloutput und seiner anschließenden Bewertung zu unterscheiden. Ein Modelloutput – etwa ei-

⁹¹Vgl. Russell & Norvig(2010), S. 556.

⁹²Vgl. Russell & Norvig(2010), S. 117.

⁹³Vgl. Goodfellow, Bengio & Courville(2016), S. 95.

⁹⁴Vgl. Chandola, Banerjee & Kumar(2009), S. 1.

⁹⁵Vgl. Russell & Norvig(2010), S. 562.

⁹⁶Vgl. National Institute of Standards and Technology(2023), S. 19.

ne berechnete Wahrscheinlichkeit, ein statistischer Score, ein Ähnlichkeitswert oder ein Anomaliehinweis – stellt zunächst ein technisches Analyseergebnis dar. Erst durch die Anwendung spezifischer Regeln, Kategorien, Gewichtungen oder Schwellenwerte wird dieses Ergebnis im Kontext organisatorischer Ziele interpretiert und erhält eine entscheidungsbezogene Bedeutung.⁹⁷

Innerhalb dieses Prozesses lassen sich insbesondere Klassifikation und Scoring unterscheiden. Die Klassifikation ordnet einzelne Fälle oder Datenpunkte diskreten, vordefinierten Kategorien zu. Das Scoring bildet dagegen Merkmale, Wahrscheinlichkeiten oder potenzielle Risiken in numerischen Werten ab. Ein Score stellt für sich genommen noch keine Entscheidung dar, sondern dient zunächst als quantifizierte Bewertungsgrundlage, die anschließend durch Regeln oder Schwellenwerte interpretiert werden kann.⁹⁸

Das Ranking ordnet Informationen, Personen oder Objekte anhand eines oder mehrerer Relevanz-, Risiko- oder Prioritätskriterien in eine hierarchische Reihenfolge.⁹⁹ Ein Ranking kann auf Scores oder anderen Modelloutputs beruhen, stellt jedoch eine eigenständige Form der algorithmischen Ordnung dar.

Hinsichtlich der Entscheidungslogik sind unterschiedliche Automatisierungsgrade zu unterscheiden. Monitoring-Systeme können Bewertungen lediglich als Unterstützung für menschliche Entscheidungen bereitstellen, eine verpflichtende menschliche Prüfung vorsehen oder bei klar definierten und standardisierten Aufgaben automatisierte Entscheidungen und Systemreaktionen ausführen.¹⁰⁰ Dabei sollten Zuständigkeiten, Kontrollmöglichkeiten und Grenzen des Systems dokumentiert und regelmäßig überprüft werden.¹⁰¹

Algorithmische Bewertung und Klassifikation führen nicht zwangsläufig zu einer Verhaltensbeeinflussung. Ein steuernder Einfluss kann erst entstehen, wenn die Ergebnisse mit einer konkreten Auswahl, Empfehlung, Priorisierung oder Intervention verbunden werden. Personalisierung, Interaktionsoptimierung und Anstöße stellen mögliche Anwendungsformen dar, die in Kapitel 3 vertieft werden. Nachdem damit die theoretischen und technologischen Grundlagen des Monitoring-Zyklus dargestellt wurden, erläutert Abschnitt 2.4 das methodische Vorgehen der Untersuchung.

2.4 Methodisches Vorgehen

Die vorliegende Arbeit folgt einem systematischen, literaturbasierten Forschungsansatz, um die Funktionsweise und Auswirkungen von KI-gestützten Monitoring-Systemen theoretisch zu durchdringen. Das methodische Vorgehen orientiert sich an etablierten Standards der Wirtschaftsinformatik, um Transparenz und wissenschaftliche Strenge zu gewährleisten.

⁹⁷Vgl. Pasquale(2015), S. 1.

⁹⁸Vgl. Pasquale(2015), S. 1.

⁹⁹Vgl. Gillespie(2014), S. 1.

¹⁰⁰Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 1.

¹⁰¹Vgl. National Institute of Standards and Technology(2023), S. 16.

2.4.1 Forschungsansatz

Der Forschungsansatz dieser Arbeit ist als qualitative, theoriegeleitete Literaturanalyse konzipiert. Ziel ist es, den aktuellen Erkenntnisstand zu KI-gestützten Systemen systematisch zu rekonstruieren und zu synthetisieren. Dabei wird explizit auf eine eigene Primärdatenerhebung verzichtet, da die Forschungsfrage auf der theoretischen Durchdringung und Integration bestehender Konzepte der Wirtschaftsinformatik und Informatik basiert. In Anlehnung an Hevner et al. (2004) bildet die fundierte Nutzung der vorhandenen Wissensbasis die notwendige Grundlage für die wissenschaftliche Rigorosität dieser Untersuchung.¹⁰² Wissenschaft wird hierbei als kumulatives Unterfangen verstanden, bei dem neue Erkenntnisse durch die Interpretation und Kombination bestehenden Wissens gewonnen werden, getreu dem Gleichnis vom Stehen auf den Schultern von Riesen.¹⁰³

2.4.2 Literaturrecherche

Die Literaturrecherche wurde als mehrstufiger Prozess gestaltet, der die Suche in wissenschaftlichen Datenbanken, Keyword-Recherchen sowie Vorwärts- und Rückwärtssuchen umfasst.¹⁰⁴ Zunächst wurden zentrale Fachbegriffe definiert und in Suchphrasen überführt, um relevante Quellen in Datenbanken wie EBSCOhost oder ScienceDirect zu identifizieren. Die Rückwärtssuche beinhaltete die Analyse der Referenzen der gefundenen Kernartikel, um ältere, fundamentale Arbeiten zu erschließen, während die Vorwärtssuche dazu diente, aktuellere Quellen zu finden, die die identifizierten Artikel zitieren. Dieses Vorgehen stellt sicher, dass die Recherche über eine rein stichwortbasierte Suche hinausgeht und die Vernetzung innerhalb des wissenschaftlichen Diskurses abbildet.

2.4.3 Auswahlkriterien der Quellen

Um die Qualität der Literaturreview sicherzustellen, wurden die Quellen nach expliziten Kriterien ausgewählt, wobei primär Beiträge aus hochrangigen, begutachteten (peer-reviewed) Fachzeitschriften und Konferenzbänden berücksichtigt wurden.¹⁰⁵ Die Bewertung der Zeitschriftenqualität orientierte sich an etablierten Rankings, wie der konsolidierten Liste der Association for Information Systems (Association for Information Systems (AIS)). Ein wesentliches Auswahlkriterium war die Relevanz der Inhalte bezüglich der technologischen Grundlagen von KI und ML sowie der soziotechnischen Architektur von Informationssystemen. Quellen, die lediglich oberflächliche Beschreibungen lieferten oder keine klare theoretische Fundierung aufwiesen, wurden im Rahmen des Evaluierungsprozesses ausgeschlossen.

¹⁰²Vgl. Brocke u. a.(2009), S. 1.

¹⁰³Vgl. Brocke u. a.(2009), S. 1.

¹⁰⁴Vgl. Brocke u. a.(2009), S. 1.

¹⁰⁵Vgl. Brocke u. a.(2009), S. 1.

2.4.4 Methodische Grenzen

Trotz des systematischen Vorgehens unterliegt die Literaturanalyse gewissen Grenzen, da die schiere Menge an Publikationen im Bereich der Wirtschaftsinformatik eine vollständige Erfassung aller Quellen zu einer Sisyphusarbeit macht.¹⁰⁶ Es ist daher unvermeidlich, dass eine Vielzahl von Arbeiten im Suchprozess unberücksichtigt bleibt, was den Anspruch auf absolute Vollständigkeit einschränkt. Zudem kann die mangelnde Dokumentation des Suchprozesses in manchen Basisartikeln die Replikation erschweren und somit die methodische Strenge der zugrunde liegenden Literatur beeinflussen. Schließlich können redaktionelle Einschränkungen in der Veröffentlichungspraxis, wie etwa Begrenzungen der Seitenanzahl oder der Literaturverzeichnisse, die Tiefe der dokumentierten Analyse in den Primärquellen limitieren.

Über die quantitative Begrenzung hinaus ergeben sich inhaltliche Limitationen aus der Natur des Untersuchungsgegenstandes. Viele der analysierten Empfehlungssysteme und Monitoring-Logiken basieren auf proprietären Algorithmen großer Plattformbetreiber, deren exakte Funktionsweise als Geschäftsgeheimnis geschützt ist. Diese mangelnde Transparenz führt dazu, dass wissenschaftliche Analysen oft auf einer „Black-Box“-Betrachtung oder auf Reverse Engineering angewiesen sind.¹⁰⁷ Zudem erschweren die schnellen technologischen Entwicklungen im Bereich der KI eine zeitlose theoretische Fixierung, da neue Verfahren (z. B. im Deep Learning) die untersuchten Mechanismen der Verhaltensbeeinflussung laufend verändern und erweitern.

¹⁰⁶Vgl. Brocke u. a.(2009), S. 1.

¹⁰⁷Vgl. Pasquale(2015), S. 1.

3 KI-gestützte Monitoring-Systeme in digitalen Informationsumgebungen

Die theoretischen und technologischen Grundlagen digitaler Informationssysteme finden in modernen digitalen Umgebungen ihre praktische Anwendung, wobei KI-gestützte Monitoring-Systeme als zentrale operative Einheiten fungieren. Diese Systeme operieren innerhalb von Plattformen, die nicht mehr nur als neutrale Vermittler, sondern als extraktive Apparate verstanden werden können, die darauf ausgelegt sind, menschliche Erfahrung systematisch in Verhaltensdaten zu übersetzen.¹⁰⁸¹⁰⁹ In diesem Kontext werden die in Kapitel 2 erläuterten soziotechnischen Strukturen genutzt, um massive Volumina an Verhaltensdaten zu sammeln, zu verarbeiten und zu analysieren, was die Grundlage für Personalisierung, Empfehlungen und Vorhersageprozesse bildet.¹¹⁰¹¹¹ Der folgende Abschnitt verdeutlicht, wie diese Systeme die Grenze zwischen digitaler Infrastruktur und sozialer Interaktion auflösen, um Verhalten messbar und schließlich steuerbar zu machen.

3.1 Datenerfassung und digitale Verhaltensanalyse

Die digitale Verhaltensanalyse beginnt mit einer umfassenden Architektur der Datenerfassung, die jeden Aspekt der Nutzerinteraktion in ein quantifizierbares Format transformiert. Dieser Prozess der Datafizierung bildet die notwendige Voraussetzung dafür, dass Monitoring-Systeme ein kontinuierliches Abbild der Realität erstellen und darauf basierend algorithmische Entscheidungen treffen können.

3.1.1 Social-Media-Plattformen

Social-Media-Plattformen fungieren als primäre digitale Informationssysteme, in denen menschliche Kommunikation und soziale Beziehungen in maschinenlesbare Datenströme übersetzt werden.¹¹² Jede Interaktion – sei es ein „Like“, ein Kommentar, das Teilen eines Beitrags oder die bloße Verweildauer auf einem Inhalt – dient als Datenquelle für KI-gestützte Monitoring-Systeme.¹¹³ In Plattformen wie Facebook, Instagram oder TikTok wird das Nutzerverhalten nicht nur punktuell erfasst, sondern einer kontinuierlichen Überwachung unterzogen, die darauf abzielt, einen sogenannten Verhaltensüberschuss (Behavioral Surplus) zu generieren.¹¹⁴

Die Rolle der Künstlichen Intelligenz besteht hierbei darin, diese massiven, oft unstrukturierten Datenmengen in Echtzeit zu analysieren, um Muster in den Präferenzen und

¹⁰⁸Vgl. Srnicek(2017), S. 21.

¹⁰⁹Vgl. Zuboff(2019), S. 4.

¹¹⁰Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 1.

¹¹¹Vgl. Lyon(2012), S. 2.

¹¹²Vgl. Dijck(2014), S. 1.

¹¹³Vgl. Narayanan(2023), S. 12.

¹¹⁴Vgl. Zuboff(2019), S. 4.

emotionalen Zuständen der Nutzer zu erkennen.¹¹⁵ Beispielsweise nutzt TikTok einen rein algorithmisch gesteuerten Feed, der auf einer extrem hohen Frequenz von Interaktionsdatensätzen basiert, um die Interaktionsprognose zu optimieren.¹¹⁶ Systeme wie FBLearner Flow von Facebook trainieren täglich tausende von Modellen an Billionen von Datenpunkten, um die persönliche Relevanz von Inhalten mit mathematischer Gewissheit vorherzusagen.¹¹⁷ Social-Media-Plattformen verwandeln sich somit in gigantische Sensoren für gesellschaftliche Stimmungen und individuelles Verhalten, wobei die algorithmische Verarbeitung sicherstellt, dass die Informationsflüsse exakt auf die psychologischen Profile der Nutzer zugeschnitten werden.¹¹⁸¹¹⁹

3.1.2 Plattformökosysteme

Die organisatorische und technologische Einbettung dieser Monitoring-Prozesse erfolgt innerhalb von Plattformökosystemen, die durch eine spezifische ökonomische Logik gekennzeichnet sind. Plattformen agieren als mehrseitige Märkte, die Interaktionen zwischen Nutzern, Werbetreibenden und Anbietern von Zusatzdiensten (Apps) koordinieren.¹²⁰¹²¹ Ein entscheidendes Element ist hierbei das Auftreten von Netzwerkeffekten: Je mehr Nutzer eine Plattform verwenden, desto wertvoller wird sie für alle Beteiligten, was zu einer natürlichen Tendenz zur Monopolisierung und einer immer umfassenderen Datensammlung führt.¹²²

Innerhalb dieser Ökosysteme wird Daten zur strategischen Ressource, die den Kern der wirtschaftlichen Wertschöpfung bildet. Die Plattform-Governance legt dabei die Regeln fest, nach denen Daten extrahiert und genutzt werden dürfen, wobei die Plattformbetreiber als zentrale Torwächter fungieren.¹²³¹²⁴ Durch die Integration verschiedener Dienste – wie Suche, soziale Netzwerke und Cloud-Infrastrukturen – können Unternehmen wie Amazon oder Google Daten aus unterschiedlichen Lebensbereichen konsolidieren, was die Vorhersagekraft ihrer Systeme massiv erhöht.¹²⁵¹²⁶ Diese Ökosysteme schaffen einen technologischen Rahmen, in dem die Sammlung von Verhaltensdaten nicht mehr als Nebenprodukt, sondern als primärer Zweck der Infrastruktur erscheint, um durch algorithmische Optimierung garantierte kommerzielle Ergebnisse zu erzielen.¹²⁷¹²⁸

¹¹⁵Vgl. Metzler & Garcia(2023), S. 1.

¹¹⁶Vgl. Narayanan(2023), S. 1.

¹¹⁷Vgl. Zuboff(2019), S. 18.

¹¹⁸Vgl. Dijck(2014), S. 1.

¹¹⁹Vgl. Lyon(2012), S. 2.

¹²⁰Vgl. Cusumano2019, S. 664.

¹²¹Vgl. Tiwana(2014), S. 1.

¹²²Vgl. Srnicek(2017), S. 20.

¹²³Vgl. Parker, Van Alstyne & Choudary(2016), S. 3.

¹²⁴Vgl. Tiwana(2014), S. 1.

¹²⁵Vgl. Srnicek(2017), S. 51.

¹²⁶Vgl. Cusumano2019, S. 712.

¹²⁷Vgl. Zuboff(2019), S. 4.

¹²⁸Vgl. Parker, Van Alstyne & Choudary(2016), S. 3.

3.1.3 Digitale Fußabdrücke und Nutzungsprofile

Das Resultat der kontinuierlichen Datenerfassung ist die Transformation von digitalen Fußabdrücken (Digital Footprints) in detaillierte Nutzungsprofile. Jede Online-Aktivität hinterlässt „virtuelle Brotkrumen“, die ein präziseres Bild der Persönlichkeit und des Lebens eines Individuums zeichnen können, als dies durch bewusste Selbstauskünfte möglich wäre.¹²⁹ Monitoring-Systeme aggregieren diese Spuren zu umfassenden Datensätzen, wobei zwischen freiwillig bereitgestellten, beobachteten und erschlossenen Daten (Inferred Data) unterschieden werden muss.¹³⁰ Durch komplexe Daten-Mining-Verfahren und statistische Korrelationen können Systeme sensible Merkmale wie sexuelle Orientierung, politische Gesinnung oder die psychische Verfassung aus scheinbar banalen Interaktionen wie „Likes“ ableiten.¹³¹¹³²

Diese datengetriebene Repräsentation von Individuen führt zur Erstellung von digitalen Dossiers oder algorithmischen Identitäten, die oft als „Schattenkörper“ (Shadow Bodies) bezeichnet werden, da sie nur jene Aspekte einer Person betonen, die für die algorithmische Logik lesbar sind.¹³³ Die Aggregation von Daten über verschiedene Plattformen hinweg ermöglicht es, Verhaltensmuster über lange Zeiträume zu modellieren und Individuen in immer feingranularere Segmente zu klassifizieren.¹³⁴¹³⁵ Diese Profile dienen nicht nur der Analyse der Vergangenheit, sondern bilden das Fundament für die Vorhersage und gezielte Beeinflussung zukünftigen Verhaltens durch algorithmische Steuerungsmechanismen.¹³⁶¹³⁷

Die systematische Erfassung von Verhaltensdaten und deren Verdichtung zu präzisen Nutzungsprofilen stellt jedoch nur die erste Phase des KI-gestützten Monitorings dar. Sobald ein stabiles Abbild des Nutzers existiert, greifen die im nächsten Kapitel behandelten algorithmischen Steuerungs- und Bewertungsmechanismen, die durch Empfehlungssysteme, Rankings und Scoring-Verfahren aktiv in den Informationsfluss eingreifen, um die Interaktion zu maximieren und Handlungen gezielt zu lenken.

3.2 Algorithmische Steuerungs- und Bewertungsmechanismen

Die systematische Erfassung von Verhaltensdaten bildet die infrastrukturelle Grundlage für die operative Ebene KI-gestützter Monitoring-Systeme, die durch spezifische algorithmische Verfahren eine aktive Steuerung von Informationsflüssen und Nutzerhandlungen vollziehen. Diese Mechanismen fungieren als instrumentelle Logik, die nicht nur Informa-

¹²⁹Vgl. Zuboff(2019), S. 28.

¹³⁰Vgl. **OECD2011**, S. 375.

¹³¹Vgl. Dijck(2014), S. 1.

¹³²Vgl. Acquisti, Brandimarte & Loewenstein(2015), S. 1.

¹³³Vgl. Gillespie(2014), S. 1.

¹³⁴Vgl. Kitchin(2014), S. 1.

¹³⁵Vgl. Lyon(2012), S. 2.

¹³⁶Vgl. Zuboff(2019), S. 86.

¹³⁷Vgl. **OECD2011**, S. 379.

tionen filtert, sondern gezielt Relevanz konstruiert und so die digitale Realität der Nutzer strukturiert.¹³⁸¹³⁹ Im Folgenden werden die technischen Funktionsweisen dieser Steuerungsmechanismen sowie deren Konsequenzen für die individuelle Verhaltenssteuerung erläutert.

3.2.1 Personalisierung

Die technische Realisierung einer individualisierten Informationsumgebung erfolgt primär durch Empfehlungssysteme (Recommender Systems), deren Kernaufgabe in der Schätzung des Nutzwerts (Utility) von bisher ungesehenen Objekten für einen spezifischen Nutzer besteht.¹⁴⁰ Der Prozess basiert auf der Extrapolation bekannter Präferenzen in einen multidimensionalen Raum, wobei zwei grundlegende Paradigmen dominieren: Das inhaltsbasierte Filtern (Content-based Filtering) empfiehlt Objekte, die Ähnlichkeiten zu früher präferierten Inhalten aufweisen, während das kollaborative Filtern (Collaborative Filtering) Übereinstimmungen zwischen den Bewertungsmustern verschiedener Nutzer identifiziert, um Vorhersagen auf Basis von „People-to-People“-Korrelationen zu treffen.¹⁴¹¹⁴² Hybride Systeme kombinieren diese Ansätze häufig mit wissensbasierten Methoden, um die Vorhersagegenauigkeit weiter zu steigern und technologische Hürden wie das Kaltstart-Problem zu überwinden.¹⁴³

Die Konsequenz dieser technologisch geschaffenen Umgebungen ist eine zunehmende Einengung des Informationshorizonts. Pariser (2011) beschreibt dieses Phänomen als Filterblase (Filter Bubble), in der die algorithmische Selektion dazu führt, dass Individuen primär mit dem vertrauten „Ghetto des Einen“ konfrontiert werden.¹⁴⁴ Da die Identität des Nutzers die Medieninhalte prägt und diese wiederum die Überzeugungen des Nutzers bestärken, entsteht eine Feedback-Schleife, die als „You Loop“ bezeichnet wird.¹⁴⁵ In der Logik des Überwachungskapitalismus dient diese Personalisierung nicht mehr nur der Nutzerzufriedenheit, sondern der Gewinnung eines Verhaltensüberschusses, indem das Individuum in eine algorithmisch lesbare und damit vorhersagbare Identität gedrängt wird.¹⁴⁶¹⁴⁷

3.2.2 Ranking-Algorithmen

Während die Personalisierung den individuellen Zuschnitt definiert, bestimmen Ranking-Algorithmen die hierarchische Ordnung und damit die Sichtbarkeit von Informationen

¹³⁸ Vgl. Gillespie(2014), S. 1.

¹³⁹ Vgl. Zuboff(2019), S. 5.

¹⁴⁰ Vgl. Adomavicius & Tuzhilin(2005), S. 1.

¹⁴¹ Vgl. Burke(2002), S. 1.

¹⁴² Vgl. Adomavicius & Tuzhilin(2005), S. 1.

¹⁴³ Vgl. Burke(2002), S. 1.

¹⁴⁴ Vgl. Pariser(2011), S. 4.

¹⁴⁵ Vgl. Pariser(2011), S. 4.

¹⁴⁶ Vgl. Zuboff(2019), S. 4.

¹⁴⁷ Vgl. Gillespie(2014), S. 1.

innerhalb digitaler Plattformen.¹⁴⁸ Diese Algorithmen fungieren als neue Torwächter, die den Fluss von Wissen nach spezifischen, oft proprietären Relevanzkriterien steuern.¹⁴⁹¹⁵⁰ Ein zentraler Mechanismus moderner Plattformen ist hierbei die Interaktionsprognose, bei der Inhalte danach gewichtet werden, mit welcher Wahrscheinlichkeit ein Nutzer eine Interaktion (Likes, Kommentare, Shares) vollziehen wird.¹⁵¹ Ein prominentes Beispiel ist das Meaningful Social Interaction (MSI)-Modell von Facebook, das durch maschinelles Lernen Wahrscheinlichkeiten für verschiedene Interaktionstypen berechnet und den News Feed entsprechend priorisiert.¹⁵²

Die daraus resultierende algorithmische Priorisierung transformiert soziale Interaktionen in eine ökonomische Logik, in der Aufmerksamkeit zur zentralen Währung wird. Da Ranking-Algorithmen bestimmen, was für die Öffentlichkeit wahrnehmbar ist, konstituieren sie sogenannte „berechnete Öffentlichkeiten“ (Calculated Publics), die politische Diskurse und gesellschaftliche Wahrnehmungen massiv beeinflussen können.¹⁵³ Die Konsequenz dieser Machtasymmetrie besteht darin, dass Plattformbetreiber durch die Manipulation der Sichtbarkeit – etwa durch die algorithmische Herabstufung (Demotion) von Inhalten – gezielte Verhaltenssteuerung betreiben können, ohne dass die zugrunde liegenden Bewertungskriterien für den Nutzer transparent sind.¹⁵⁴¹⁵⁵

3.2.3 Reputations- und Scoring-Systeme

Eine spezifische Form der algorithmischen Bewertung ist die Umwandlung von Verhaltensdaten in automatisierte Scores, die zur Klassifikation und Hierarchisierung von Individuen dienen.¹⁵⁶ Durch die Aggregation von digitalen Fußabdrücken, wie etwa Klickströmen, Standortdaten oder sozialen Kontakten, werden Profile erstellt, die beispielsweise die Kreditwürdigkeit oder Zuverlässigkeit bewerten.¹⁵⁷ Solche e-Scores fungieren als Instrumente zur Reduktion von Unsicherheit für Unternehmen, indem sie Individuen in mathematische Wahrscheinlichkeitskategorien einteilen.¹⁵⁸¹⁵⁹

Diese Scoring-Verfahren haben tiefgreifende Konsequenzen für die soziale Teilhabe und Gerechtigkeit. O’Neil (2016) bezeichnet solche Modelle als „Weapons of Math Destruction“ (WMD), da sie oft auf undurchsichtigen Kriterien basieren, Vorurteile kodifizieren und für die Betroffenen lebensverändernde Folgen haben können – etwa den Ausschluss von

¹⁴⁸ Vgl. Gillespie(2014), S. 2.

¹⁴⁹ Vgl. Gillespie(2014), S. 1.

¹⁵⁰ Vgl. Pasquale(2015), S. 1.

¹⁵¹ Vgl. Narayanan(2023), S. 1.

¹⁵² Vgl. Narayanan(2023), S. 1.

¹⁵³ Vgl. Gillespie(2014), S. 1.

¹⁵⁴ Vgl. Narayanan(2023), S. 1.

¹⁵⁵ Vgl. Gillespie(2014), S. 1.

¹⁵⁶ Vgl. Pasquale(2015), S. 1.

¹⁵⁷ Vgl. O’Neil(2016), S. 2.

¹⁵⁸ Vgl. **OECD2011**, S. 519 f..

¹⁵⁹ Vgl. O’Neil(2016), S. 2.

Finanzprodukten oder Arbeitsplätzen –, ohne dass Einspruchsmöglichkeiten bestehen.¹⁶⁰ Die algorithmische Bewertung tarnt dabei diskriminierende Praktiken, wie das „Redlining“ auf Basis von Postleitzahlen, als objektive mathematische Evidenz und etabliert so eine Form der algorithmischen Governance, die das Leben des Einzelnen permanent überwacht und bewertet.^{161 162}

3.2.4 Interaktionsoptimierung und Verhaltensprognosen

Die Integration von Personalisierung, Ranking und Scoring mündet in der systematischen Optimierung der Interaktion, um Verhaltensprognosen zu kommerzialisieren und Handlungen gezielt zu lenken. Plattformen nutzen hierbei Mechanismen des Bestärkenden Lernens (Reinforcement Learning), bei dem Agenten kontinuierlich aus Nutzerreaktionen lernen, um jene Aktionen (Policies) zu identifizieren, die den erwarteten Reward – in Form von Aufmerksamkeit oder Klicks – maximieren.^{163 164} Unterstützt wird dieser Prozess durch psychologische Trigger des Fogg Behavior Models, die Motivation und Fähigkeit des Nutzers adressieren, um durch gezielte Reize (Sparks/Signals) ein gewünschtes Zielverhalten zu automatisieren.¹⁶⁵

Praktische Anwendungen demonstrieren die Wirksamkeit dieser Verhaltensmodifikation. Die Facebook-Studie zur „Emotional Contagion“ bewies, dass die algorithmische Manipulation von emotionalen Inhalten im News Feed die Stimmungslage von Millionen Nutzern ohne deren Wissen verändern kann.^{166 167} Das Beispiel von Cambridge Analytica verdeutlicht zudem, wie psychometrische Profile (OCEAN-Analyse) für politisches Micro-Targeting genutzt wurden, um Wahlentscheidungen durch maßgeschneiderte Botschaften zu beeinflussen.^{168 169} Schließlich führen diese Mechanismen zur Verstärkung von Echo-Kammern, in denen homophile Cluster und die algorithmische Belohnung von Emotionalität die soziale Polarisierung vorantreiben und die individuelle Autonomie zugunsten eines „Instrumentarismus“ untergraben.^{170 171 172}

3.3 Vergleich unterschiedlicher Systemlogiken

Die Funktionsweise KI-gestützter Monitoring-Systeme folgt je nach politischem und ökonomischem Rahmen unterschiedlichen Logiken, die jedoch auf einer gemeinsamen

¹⁶⁰ Vgl. O’Neil(2016), S. 2.

¹⁶¹ Vgl. Pasquale(2015), S. 1.

¹⁶² Vgl. O’Neil(2016), S. 2.

¹⁶³ Vgl. Sutton & Barto(2018), S. 1.

¹⁶⁴ Vgl. Narayanan(2023), S. 1.

¹⁶⁵ Vgl. Fogg(2009), S. 1.

¹⁶⁶ Vgl. Zuboff(2019), S. 20.

¹⁶⁷ Vgl. Kramer, Guillory & Hancock(2014), S. 1.

¹⁶⁸ Vgl. Isaak & Hanna(2018), S. 1.

¹⁶⁹ Vgl. Zuboff(2019), S. 7.

¹⁷⁰ Vgl. Cinelli u. a.(2021), S. 1.

¹⁷¹ Vgl. Metzler & Garcia(2023), S. 1.

¹⁷² Vgl. Zuboff(2019), S. 30.

technologischen Basis der massenhaften Datenauswertung beruhen. Während westliche Systeme primär marktgesteuerten Akkumulationszielen folgen, zielen staatlich integrierte Systeme auf die Steuerung gesellschaftlicher Compliance ab. Der folgende Abschnitt analysiert diese Systemlogiken und stellt sie einander vergleichend gegenüber.

3.3.1 Plattformzentrierte Systeme westlicher Plattformunternehmen

In westlich geprägten Wirtschaftsräumen operieren Monitoring-Systeme innerhalb einer Logik, die als Überwachungskapitalismus beschrieben wird und in der menschliche Erfahrung als kostenloses Rohmaterial für die Extraktion von Verhaltensdaten dient.¹⁷³ Plattformunternehmen wie Google, Meta (Facebook), YouTube, TikTok und Amazon fungieren hierbei als zentrale Vermittler, deren digitale Infrastrukturen darauf ausgelegt sind, einen kontinuierlichen Fluss an Verhaltensüberschüssen zu generieren.¹⁷⁴¹⁷⁵ Diese Systeme nutzen Algorithmen zur Personalisierung, um Informationsumgebungen so zu gestalten, dass sie die individuelle Relevanz maximieren und dadurch die Verweildauer sowie die Interaktionsrate erhöhen.¹⁷⁶¹⁷⁷

Die zentralen Ziele dieser plattformzentrierten Monitoring-Logik sind Interaktion, Wachstum und Monetarisierung. Die Interaktionsprognose, also die Vorhersage der Interaktionswahrscheinlichkeit, bildet den Kern der algorithmischen Steuerung, da ein engagierter Nutzer häufiger zur Plattform zurückkehrt und somit mehr Werbeeinnahmen generiert.¹⁷⁸ Netzwerkeffekte verstärken diesen Prozess, da ein steigendes Nutzeraufkommen den Wert der Plattform erhöht und noch umfassendere Datensammlungen ermöglicht, was wiederum die Vorhersagekraft der Algorithmen für Werbetreibende verbessert.¹⁷⁹¹⁸⁰ Diese ökonomische Dynamik führt zur Entstehung von „berechneten Öffentlichkeiten“, in denen Ranking-Algorithmen die Sichtbarkeit von Inhalten nach kommerziellen Kriterien priorisieren, was oft zu einer Verengung des Informationshorizonts in Form von Filterblasen führt.¹⁸¹ Die Konsequenz dieser Logik ist eine instrumentelle Macht, die das Verhalten der Nutzer nicht durch Zwang, sondern durch subtile algorithmische Anstöße und psychologische Trigger im Sinne der Plattformökonomie optimiert.¹⁸²¹⁸³

Diese marktgetriebene Ausrichtung auf individuelle Präferenzen findet ihr Gegenstück in Systemen, die Monitoring-Technologien zur Sicherung staatlicher Autorität und gesellschaftlicher Ordnung einsetzen.

¹⁷³ Vgl. Zuboff(2019), S. 4.

¹⁷⁴ Vgl. Srnicek(2017), S. 19.

¹⁷⁵ Vgl. Parker, Van Alstyne & Choudary(2016), S. 8.

¹⁷⁶ Vgl. Pariser(2011), S. 4.

¹⁷⁷ Vgl. Adomavicius & Tuzhilin(2005), S. 1.

¹⁷⁸ Vgl. Narayanan(2023), S. 1.

¹⁷⁹ Vgl. Srnicek(2017), S. 20.

¹⁸⁰ Vgl. Parker, Van Alstyne & Choudary(2016), S. 17.

¹⁸¹ Vgl. Gillespie(2014), S. 1.

¹⁸² Vgl. Zuboff(2019), S. 4.

¹⁸³ Vgl. Fogg(2009), S. 1.

3.3.2 Staatlich integrierte Monitoring-Systeme

Staatlich integrierte Monitoring-Systeme, wie sie insbesondere in China entwickelt werden, nutzen dieselben technologischen Werkzeuge wie westliche Plattformen, jedoch unter einer fundamental anderen Zwecksetzung: der Sicherung von Compliance und staatlicher Governance. Das Herzstück dieser Entwicklung ist das Social Credit System (SCS), das darauf abzielt, durch die Integration von Regierungsdaten und privaten Informationen ein umfassendes Maß an „Aufrichtigkeit“ in wirtschaftlichen, sozialen und politischen Belangen zu erzwingen.¹⁸⁴ Dieses System fungiert als kybernetischer Regelkreis, der Verhalten durch ein System von Belohnungen und Bestrafungen (Joint Punishment System) steuert, wobei Regelverstöße in einem Bereich zu Einschränkungen in allen Lebensbereichen führen können.^{185 186}

Technologisch stützt sich dieser digitale Autoritarismus auf eine omnipräsente Überwachungsinfrastruktur, die Künstliche Intelligenz mit massiven Videonetzwerken wie dem „Skynet“- oder „Sharp Eyes“-Projekt kombiniert.^{187 188} Regierungsbehörden setzen Verfahren wie Gesichtserkennung, Biometrie und Big-Data-Analysen ein, um Individuen in Echtzeit zu identifizieren, zu klassifizieren und Profile zu erstellen, die eine prädiktive Überwachung ermöglichen.¹⁸⁹ Im Bereich des Smart Policing erlaubt die „Integrated Joint Operations Platform“ (IJOP) die Aggregation verschiedener Datenquellen, um verdächtige Verhaltensmuster automatisiert zu erkennen und präventive polizeiliche Maßnahmen einzuleiten.^{190 191} Diese Form der algorithmischen Governance zielt darauf ab, gesellschaftliche Risiken zu minimieren und die Stabilität des Regimes durch eine lückenlose Erfassung des Bürgerverhaltens sicherzustellen.^{192 193}

Der Vergleich dieser staatlichen Kontrolllogik mit der westlichen Plattformlogik verdeutlicht sowohl strukturelle Ähnlichkeiten als auch fundamentale Differenzen in der Zielsetzung und Machtausübung.

3.3.3 Vergleich westlicher Plattformlogiken und staatlicher Monitoring-Systeme

Ein Vergleich westlicher plattformzentrierter Systeme mit staatlich integrierten Monitoring-Systemen offenbart eine technologische Konvergenz bei gleichzeitiger Divergenz der zugrunde liegenden Governance-Strukturen. Beide Systemtypen basieren auf der massenhaften Sammlung digitaler Fußabdrücke und deren Transformation in automatisierte Scoring- und Klassifikationssysteme, sei es zur Ermittlung der Kreditwürdigkeit (e-Scores)

¹⁸⁴ Vgl. Creemers(2018), S. 1.

¹⁸⁵ Vgl. Creemers(2018), S. 1.

¹⁸⁶ Vgl. Qiang(2019), S. 1.

¹⁸⁷ Vgl. Qiang(2019), S. 1.

¹⁸⁸ Vgl. U.S.-China Economic and Security Review Commission(2020), S. 1.

¹⁸⁹ Vgl. Qiang(2019), S. 1.

¹⁹⁰ Vgl. U.S.-China Economic and Security Review Commission(2020), S. 4.

¹⁹¹ Vgl. Qiang(2019), S. 1.

¹⁹² Vgl. Creemers(2018), S. 1.

¹⁹³ Vgl. Lyon(2012), S. 2.

oder der sozialen Vertrauenswürdigkeit (Social Credit).¹⁹⁴¹⁹⁵ Ebenso nutzen beide Seiten Mechanismen der Verhaltensmodifikation; während westliche Plattformen Nutzer durch Anstöße zu Konsumhandlungen bewegen, setzen staatliche Systeme auf eine offene Paternalisierung zur Einübung staatsbürgerlicher Tugenden.¹⁹⁶¹⁹⁷

Die wesentlichen Unterschiede liegen in den Zielsetzungen und den Adressaten der Systeme. Westliche Logiken sind auf Interaktion vs. Compliance ausgerichtet: Das Ziel ist die Maximierung der Nutzeraktivität zur Monetarisierung von Aufmerksamkeit in einer Werbeökonomie, während staatliche Systeme auf die Einhaltung von Normen und Gesetzen zielen.¹⁹⁸¹⁹⁹ Dies spiegelt sich im Gegensatz von Wachstum vs. Governance wider; Plattformen streben nach globaler Expansion durch Netzwerkeffekte, wohingegen staatliches Monitoring der administrativen Effizienz und Risikokontrolle dient.²⁰⁰²⁰¹ Der Adressat wird entsprechend unterschiedlich konstruiert: als Nutzer (Konsument/Datenquelle) im Westen und als Bürger im staatlich integrierten Modell.²⁰²²⁰³

Ein weiterer markanter Unterschied besteht in der Form der Überwachung und Transparenz. Westliche Systeme operieren oft als Schwarze Kästen, deren proprietäre Algorithmen geheim gehalten werden, um Wettbewerbsvorteile zu sichern.²⁰⁴ Im Gegensatz dazu strebt das chinesische Modell eine Form der radikalen Transparenz an, bei der Informationen über die Vertrauenswürdigkeit von Individuen und Unternehmen teilweise öffentlich bekannt gemacht werden, um den sozialen Druck zur Konformität zu erhöhen.²⁰⁵ Dennoch verschwimmen die Grenzen zusehends, da westliche Sicherheitsbehörden verstärkt auf die Datenbestände privater Plattformen zugreifen, während staatliche Systeme zunehmend Daten aus dem Privatsektor integrieren, was zu einem hybriden Überwachungskontext führt, in dem ökonomische und staatliche Steuerungslogiken ineinandergreifen.²⁰⁶²⁰⁷

¹⁹⁴ Vgl. Pasquale(2015), S. 1.

¹⁹⁵ Vgl. Creemers(2018), S. 1.

¹⁹⁶ Vgl. Zuboff(2019), S. 16.

¹⁹⁷ Vgl. Creemers(2018), S. 1.

¹⁹⁸ Vgl. Narayanan(2023), S. 1.

¹⁹⁹ Vgl. Creemers(2018), S. 1.

²⁰⁰ Vgl. Srnicek(2017), S. 20.

²⁰¹ Vgl. U.S.-China Economic and Security Review Commission(2020), S. 1.

²⁰² Vgl. Zuboff(2019), S. 71.

²⁰³ Vgl. U.S.-China Economic and Security Review Commission(2020), S. 1.

²⁰⁴ Vgl. Pasquale(2015), S. 1.

²⁰⁵ Vgl. Creemers(2018), S. 1.

²⁰⁶ Vgl. Lyon(2012), S. 2.

²⁰⁷ Vgl. Creemers(2018), S. 1.

4 Sozioökonomische und gesellschaftliche Implikationen

Die im vorangegangenen Kapitel dargelegten technologischen Funktionsweisen und Systemlogiken KI-gestützter Monitoring-Systeme bilden die Grundlage für eine weitreichende Transformation gesellschaftlicher und ökonomischer Strukturen. Während Kapitel 3 den Fokus auf die technische Realisierung der Datenerfassung und algorithmischen Verarbeitung legte, widmet sich das folgende Kapitel den daraus resultierenden Konsequenzen für das Individuum und die Gemeinschaft. In der modernen Informationsgesellschaft fungieren Monitoring-Systeme nicht mehr lediglich als passive Instrumente der Datenverarbeitung, sondern als aktive Gestalter digitaler Informationsumgebungen, die zunehmend Einfluss auf politische, soziale und wirtschaftliche Prozesse nehmen.²⁰⁸²⁰⁹

Der Kern dieser Entwicklung liegt in der wachsenden Bedeutung von Verhaltensdaten, die im Kontext des sogenannten Überwachungskapitalismus als strategische Ressource für die Extraktion von Verhaltensüberschüssen dienen.²¹⁰²¹¹ Durch den Prozess der Datafizierung werden ehemals private Aspekte des menschlichen Lebens in quantifizierbare Datenströme übersetzt, was eine kontinuierliche Überwachung und prädiktive Analyse ermöglicht.²¹² Diese Systeme streben dabei eine Neuausrichtung von reinem Wissen hin zur Ausübung von Macht an: Es genügt nicht mehr, Informationsflüsse über Individuen zu automatisieren; das Ziel besteht zunehmend darin, das Verhalten der Nutzer selbst in großem Maßstab zu formen und zu automatisieren.²¹³ Diese Verschiebung markiert den Aufstieg einer instrumentellen Macht, die durch eine allgegenwärtige rechnergestützte Architektur das menschliche Handeln auf die Ziele dritter Akteure hin ausrichtet.²¹⁴

Dabei erweisen sich KI-gestützte Systeme als „zweischneidige Schwerter“, die je nach Anwendung und Governance sowohl erhebliche Chancen als auch tiefgreifende Risiken bergen.²¹⁵ Einerseits bieten sie das Potenzial, drängende gesellschaftliche Herausforderungen in Bereichen wie Gesundheit, Klimaschutz oder öffentlicher Verwaltung effizienter zu bewältigen und das menschliche Wohlergehen zu fördern.²¹⁶ Andererseits führen dieselben Mechanismen der Personalisierung, des Rankings und Scorings zu kritischen Bedenken hinsichtlich der menschlichen Autonomie, der informationellen Selbstbestimmung und der

²⁰⁸ Vgl. Gillespie(2014), S. 1.

²⁰⁹ Vgl. Pasquale(2015), S. 1.

²¹⁰ Vgl. Zuboff(2019), S. 4.

²¹¹ Vgl. OECD2011, S. 531.

²¹² Vgl. Dijck(2014), S. 1.

²¹³ Vgl. Zuboff(2019), S. 4 ff..

²¹⁴ Vgl. Zuboff(2019), S. 59.

²¹⁵ Vgl. Cusumano2019, S. 812 ff..

²¹⁶ Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 1.

Stabilität demokratischer Diskurse.²¹⁷²¹⁸²¹⁹ Die algorithmische Autorität, die oft hinter undurchsichtigen „Schwarzen Kästen“ verborgen bleibt, schafft asymmetrische Machtverhältnisse zwischen Plattformbetreibern und Nutzern, die herkömmliche Regulierungs- und Kontrollmechanismen vor massive Herausforderungen stellt.²²⁰²²¹

Um diese Dynamiken umfassend zu durchdringen, analysiert dieses Kapitel zunächst die Auswirkungen auf die digitale Informationsumgebung sowie die daraus resultierenden Verhaltensdynamiken und Personalisierungseffekte. Darauf aufbauend werden die ökonomischen Interessen der Plattformbetreiber und die politischen Einflussmechanismen untersucht. Abschließend werden bestehende Governance- und Kontrollstrukturen sowie ethische Leitlinien zur Sicherstellung einer vertrauenswürdigen Künstlichen Intelligenz diskutiert, um das Spannungsfeld zwischen technologischer Innovation und dem Schutz fundamentaler Rechte zu beleuchten.²²²²²³

4.1 Auswirkungen auf digitale Informationsumgebungen

Die Integration von KI-gestützten Monitoring-, Empfehlungs- und Ranking-Systemen hat zu einer fundamentalen Transformation digitaler Informationsumgebungen geführt. Diese Umgebungen fungieren nicht länger als neutrale Infrastrukturen für den Datenaustausch, sondern haben sich zu aktiven, kuratierten Räumen entwickelt, in denen die Verfügbarkeit und Wahrnehmung von Informationen durch algorithmische Logiken präfiguriert werden.²²⁴ In der Wirtschaftsinformatik wird dieser Wandel als Übergang zu datengetriebenen Informationsökosystemen verstanden, in denen die Grenze zwischen technologischer Vermittlung und sozialer Realität zunehmend verschwimmt.²²⁵

Mechanismen der algorithmischen Transformation Der Prozess der Transformation beginnt mit der systematischen Datafizierung menschlicher Interaktionen. Plattformen übersetzen jede Online-Aktivität – von Klickmustern und Verweildauern bis hin zu sozialen Verknüpfungen – in quantifizierbare Metadaten.²²⁶ Diese Erfassung von „digitalen Fußabdrücken“ bildet das Rohmaterial für die Erstellung hochgradig detaillierter Nutzungsprofile.²²⁷ Gillespie (2014) beschreibt diesen Vorgang als Vorbereitung der Daten für den algorithmischen Zugriff, wobei komplexe Informationen in maschinenlesbare Kategorien formalisiert werden müssen.²²⁸ Solche Profile dienen als Grundlage für „Zyklen der

²¹⁷Vgl. Zuboff(2019), S. 15.

²¹⁸Vgl. O’Neil(2016), S. 2.

²¹⁹Vgl. Pasquale(2015), S. 1.

²²⁰Vgl. Pasquale(2015), S. 1.

²²¹Vgl. Acquisti, Brandimarte & Loewenstein(2015), S. 1.

²²²Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 1.

²²³Vgl. Lyon(2012), S. 2.

²²⁴Vgl. Gillespie(2014), S. 13.

²²⁵Vgl. Dijck(2014), S. 1.

²²⁶Vgl. Dijck(2014), S. 1.

²²⁷Vgl. Kitchin(2014), S. 1.

²²⁸Vgl. Gillespie(2014), S. 1.

Antizipation“, in denen Plattformbetreiber versuchen, die Bedürfnisse und das zukünftige Verhalten ihrer Nutzer präzise vorherzusagen.²²⁹

Auf Basis dieser Profile operieren algorithmische Selektions- und Empfehlungsmechanismen. Der technologische Kern moderner Plattformen wie TikTok, Facebook oder YouTube ist die Interaktionsprognose.²³⁰ Diese Systeme berechnen die Wahrscheinlichkeit, mit der ein Nutzer mit einem bestimmten Inhalt interagieren wird, um aus einer nahezu unendlichen Menge an Informationen eine personalisierte Auswahl zu treffen.²³¹ Ziel dieser Mechanismen ist es primär, die Informationsüberlastung (Information Overload) zu bewältigen, indem Relevanz nicht mehr absolut, sondern als individuelle Korrelation definiert wird.²³²

Die strukturelle Ordnung dieser Auswahl wird durch Ranking- und Filterprozesse festgelegt. Algorithmen zur Priorisierung bestimmen die hierarchische Position von Informationen in Feeds oder Suchergebnissen und steuern damit maßgeblich die Sichtbarkeit von Inhalten.²³³ Diese „Public Relevance Algorithms“ besitzen die Macht, Wissen nach spezifischen, oft proprietären Kriterien zu zertifizieren und so die Regeln für die Teilnahme am öffentlichen Diskurs festzulegen.²³⁴ Der Zugriff auf Inhalte wird somit durch die Plattform mediert, wobei algorithmische Torwächter die traditionelle redaktionelle Logik menschlicher Experten weitgehend ersetzen.²³⁵²³⁶

Konsequenzen für die Informationsumgebung Diese technologischen Mechanismen führen zu einer tiefgreifenden Individualisierung der Informationsumgebungen. Pariser (2011) prägte hierfür den Begriff der Filterblase (Filter Bubble), in der die algorithmische Selektion dazu führt, dass Individuen primär mit Inhalten konfrontiert werden, die ihren bestehenden Überzeugungen entsprechen.²³⁷ Diese Form der algorithmischen Zugangskontrolle schafft eine ungleiche Sichtbarkeit von Informationen, da interaktionsstarke, oft emotionale oder polarisierende Inhalte algorithmisch bevorzugt werden, während dissonante oder komplexe Perspektiven aus dem Aufmerksamkeitsfokus verdrängt werden.²³⁸²³⁹

In der wissenschaftlichen Debatte werden diese Phänomene häufig mit dem Konzept der Echokammern verknüpft. Während Filterblasen als Resultat algorithmischer Filterung verstanden werden, beschreiben Echokammern homophile Cluster in sozialen Netzwerken, in denen sich Nutzer mit Gleichgesinnten um eine geteilte Erzählung gruppieren.²⁴⁰

²²⁹ Vgl. Gillespie(2014), S. 1.

²³⁰ Vgl. Narayanan(2023), S. 8.

²³¹ Vgl. Areeb u. a.(2023), S. 1.

²³² Vgl. Areeb u. a.(2023), S. 1.

²³³ Vgl. Gillespie(2014), S. 1.

²³⁴ Vgl. Gillespie(2014), S. 1.

²³⁵ Vgl. Gillespie(2014), S. 1.

²³⁶ Vgl. Narayanan(2023), S. 1.

²³⁷ Vgl. Pariser(2011), S. 4.

²³⁸ Vgl. Gillespie(2014), S. 1.

²³⁹ Vgl. Narayanan(2023), S. 1.

²⁴⁰ Vgl. Cinelli u. a.(2021), S. 1.

Dies kann zu einer Informationsfragmentierung führen, bei der die Grundlage für einen gemeinsamen öffentlichen Diskurs erodiert, da Nutzer unterschiedliche Versionen der Realität wahrnehmen.²⁴¹ Pasquale (2015) betont in diesem Kontext die wachsende Informationsasymmetrie und Opazität: Die algorithmischen Entscheidungsprozesse operieren oft als „Schwarze Kästen“, deren Kriterien für den Nutzer und selbst für externe Experten undurchsichtig bleiben.²⁴²

Die empirische Forschung mahnt jedoch zur Differenzierung und warnt vor einer rein technologisch-deterministischen Sichtweise. Areeb et al. (2023) stellen fest, dass Filterblasen zwar experimentell nachweisbar sind, ihre Auswirkungen jedoch stark vom Design der Empfehlungssysteme abhängen.²⁴³ Cinelli et al. (2021) zeigen auf, dass die Entstehung von Echokammern maßgeblich von der Plattformarchitektur beeinflusst wird: Während Facebook und Twitter durch ihre Netzwerkstrukturen die Bildung homophiler Cluster begünstigen, weisen Plattformen wie Reddit eine höhere Integration unterschiedlicher Meinungen innerhalb von Interessengemeinschaften auf.²⁴⁴ Dies deutet darauf hin, dass nicht der Algorithmus allein, sondern das Zusammenspiel aus technologischer Struktur und sozialer Dynamik entscheidend ist.²⁴⁵

Zudem belegen Studien von Kelm et al. (2023), dass die algorithmische Selektion politische Polarisierung zwar geringfügig beeinflussen kann, die Voreinstellungen der Nutzer und ihr aktives Selektionsverhalten jedoch oft eine deutlich stärkere Wirkung entfalten.²⁴⁶ In ihren Experimenten verstärkten algorithmisch ausgewählte Argumente die bestehenden Einstellungen nur minimal stärker als zufällig ausgewählte Argumente, was die Annahme einer automatischen Radikalisierung durch Algorithmen relativiert.²⁴⁷ Es muss daher präzise zwischen dem Einfluss der Algorithmen, den Strukturen der sozialen Netzwerke und der individuellen Wahlentscheidung differenziert werden, wobei alle drei Faktoren in komplexen Feedback-Schleifen interagieren.²⁴⁸

Zusammenfassend lässt sich festhalten, dass KI-gestützte Monitoring-Systeme die digitale Informationswelt von einem explorativen zu einem prädiktiv strukturierten Raum transformieren. Die strukturelle Veränderung der Informationsumgebung bildet den Rahmen, innerhalb dessen sich individuelle Wahrnehmungs- und Entscheidungsprozesse vollziehen. Die daraus resultierende Verschiebung der Informationsasymmetrien zugunsten der Plattformbetreiber erschwert es Individuen, die Verzerrungen ihrer eigenen Informationsumgebung zu erkennen.²⁴⁹ Wie diese algorithmisch kuratierten Umgebungen gezielt

²⁴¹ Vgl. Gillespie(2014), S. 1.

²⁴² Vgl. Pasquale(2015), S. 4.

²⁴³ Vgl. Areeb u. a.(2023), S. 1.

²⁴⁴ Vgl. Cinelli u. a.(2021), S. 1.

²⁴⁵ Vgl. Cinelli u. a.(2021), S. 1.

²⁴⁶ Vgl. Kelm, Dohle & Bernhard(2023), S. 1.

²⁴⁷ Vgl. Kelm, Dohle & Bernhard(2023), S. 1.

²⁴⁸ Vgl. Metzler & Garcia(2023), S. 1.

²⁴⁹ Vgl. Pasquale(2015), S. 1.

die psychologischen Mechanismen des Einzelnen adressieren und welche Auswirkungen dies auf die menschliche Autonomie hat, ist Gegenstand des folgenden Kapitels zu den Verhaltensdynamiken und Personalisierungseffekten.

4.2 Verhaltensdynamiken und Personalisierungseffekte

Die Transformation digitaler Informationsumgebungen durch KI-gestützte Monitoring-Systeme findet ihre Fortsetzung in der gezielten Beeinflussung individueller Verhaltensdynamiken. In der Wirtschaftsinformatik und Psychologie wird dieser Prozess als Übergang von einer rein informativen Unterstützung hin zu einer aktiven Verhaltenssteuerung verstanden, die menschliche Entscheidungsprozesse proaktiv gestaltet.²⁵⁰ Während die strukturelle Ebene den Rahmen setzt, operieren auf der psychologischen Ebene Mechanismen, die darauf ausgerichtet sind, Nutzer durch datenbasierte Adaptation, Empfehlungen und Feedback-Schleifen in ihren Handlungen zu lenken.²⁵¹

Mechanismen der personalisierten Verhaltenssteuerung Der grundlegende Mechanismus dieser Steuerung beruht auf der kontinuierlichen Erfassung und Analyse von Verhaltensdaten, die in hochpräzise Nutzungsprofile überführt werden.²⁵² Diese Profile ermöglichen es Systemen, die individuelle Empfänglichkeit eines Nutzers gegenüber verschiedenen Überzeugungsstrategien einzuschätzen, ein Konzept, das als „Überzeugungsprofilerstellung“ bezeichnet wird.²⁵³ Persuasion Profiles sind Sammlungen von Schätzungen über die erwarteten Effekte verschiedener Einflussprinzipien für ein spezifisches Individuum.²⁵⁴ Diese Profile werden durch automatisierte Prozesse laufend aktualisiert, wobei jede Nutzerreaktion auf einen digitalen Stimulus als Feedback-Signal dient, um die Vorhersagegenauigkeit des Systems zu optimieren.²⁵⁵

Die technologische Basis für diese iterative Optimierung bilden oft Verfahren des bestärkenden Lernens (Reinforcement Learning), bei denen ein System lernt, jene Aktionen zu wählen, die eine maximale Belohnung – in diesem Kontext meist Nutzer-Interaktion – versprechen.²⁵⁶ Dabei werden Belohnungssignale genutzt, um die interne Strategie (Policy) des Systems so anzupassen, dass zukünftige Reize exakter auf die psychologischen Trigger des Nutzers abgestimmt sind.²⁵⁷ Dieser Prozess schafft geschlossene Rückkopplungsschleifen, in denen das System nicht nur das Verhalten misst, sondern durch die Auswahl der präsentierten Inhalte aktiv die Wahrscheinlichkeit zukünftiger Handlungen erhöht.²⁵⁸

Ein wesentliches Element der gestalterischen Umsetzung ist das „Verhaltensdesign“, wel-

²⁵⁰ Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

²⁵¹ Vgl. Zuboff(2019), S. 4.

²⁵² Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

²⁵³ Vgl. Kaptein, Markopoulos, Ruyter & Aarts(2015), S. 1.

²⁵⁴ Vgl. Kaptein, Markopoulos, Ruyter & Aarts(2015), S. 1.

²⁵⁵ Vgl. Kaptein, Markopoulos, Ruyter & Aarts(2015), S. 1.

²⁵⁶ Vgl. Sutton & Barto(2018), S. 1.

²⁵⁷ Vgl. Sutton & Barto(2018), S. 46.

²⁵⁸ Vgl. Metzler & Garcia(2023), S. 1.

ches psychologische Modelle wie das Fogg Behavior Model (FBM) operationalisiert.²⁵⁹ Nach diesem Modell ist ein Verhalten das Produkt aus drei gleichzeitig auftretenden Faktoren: Motivation, Fähigkeit (Ability) und einem Auslöser (Trigger).²⁶⁰ Digitale Systeme nutzen diese Erkenntnisse, um durch zeitlich und inhaltlich präzise platzierte Trigger Handlungen zu automatisieren.²⁶¹ Wenn diese Trigger durch Big-Data-Analysen und Echtzeit-Monitoring gesteuert werden, entsteht eine Form der dynamischen Regulierung, die als „Hyper-Anstöße“ bezeichnet wird.²⁶² Im Gegensatz zu statischen Anstößen passen sich Hyper-Anstöße adaptiv an den aktuellen Kontext und die spezifischen Schwachstellen des Nutzers an, was ihre Effektivität massiv erhöht.²⁶³

Konsequenzen und Auswirkungen auf das Nutzerverhalten Die Anwendung dieser Mechanismen führt zu Veränderungen in der Aufmerksamkeit und im Informationskonsum der Nutzer. Durch die algorithmische Priorisierung von Inhalten, die eine hohe Interaktionswahrscheinlichkeit versprechen, werden bestehende Gewohnheiten und Präferenzen systematisch verstärkt.²⁶⁴ Nutzer geraten dabei in Feedback-Schleifen, in denen das vergangene Verhalten die zukünftigen Möglichkeiten determiniert.²⁶⁵ Diese Form der Habitualisierung kann dazu führen, dass die Erkundung neuer Informationen abnimmt und eine passive Konsumhaltung begünstigt wird.²⁶⁶

Darüber hinaus belegen Studien die Möglichkeit einer emotionalen Beeinflussung durch digital kuratierte Umgebungen.²⁶⁷ Das Experiment zur emotionalen Ansteckung (Emotional Contagion) auf Facebook demonstrierte, dass bereits geringfügige Änderungen in der emotionalen Gewichtung des News Feeds ausreichen, um die Stimmungslage und das eigene Posting-Verhalten von Millionen von Nutzern messbar zu verändern.²⁶⁸ Solche subliminalen Reize können die individuelle Autonomie beeinträchtigen, da sie jenseits der Schwelle bewusster Wahrnehmung operieren und die Fähigkeit zur selbstbestimmten emotionalen Regulation stören.²⁶⁹

In diesem Zusammenhang ist eine klare Differenzierung zwischen Persuasion, Einfluss und Manipulation notwendig.²⁷⁰ Während Persuasion als offener Appell an die rationale Entscheidungsfähigkeit verstanden wird, kennzeichnet Manipulation einen verdeckten Einfluss, der die Entscheidungsgewalt des Individuums untergräbt.²⁷¹ Manipulative Prakti-

²⁵⁹ Vgl. Fogg(2009), S. 1.

²⁶⁰ Vgl. Fogg(2009), S. 1.

²⁶¹ Vgl. Fogg(2009), S. 1.

²⁶² Vgl. Yeung(2017).

²⁶³ Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

²⁶⁴ Vgl. Narayanan(2023), S. 12.

²⁶⁵ Vgl. Narayanan(2023), S. 1.

²⁶⁶ Vgl. Zuboff(2019), S. 298.

²⁶⁷ Vgl. Kramer, Guillory & Hancock(2014), S. 1.

²⁶⁸ Vgl. Kramer, Guillory & Hancock(2014), S. 1.

²⁶⁹ Vgl. Susser, Roessler & Nissenbaum(2019), S. 16.

²⁷⁰ Vgl. Susser, Roessler & Nissenbaum(2019), S. 2.

²⁷¹ Vgl. Susser, Roessler & Nissenbaum(2019), S. 3.

ken zeichnen sich dadurch aus, dass sie kognitive oder emotionale Schwachstellen gezielt ausbeuten, um den Nutzer zu Handlungen zu bewegen, die primär den Zielen des Systembetreibers dienen.²⁷² Die Verdecktheit des Einflusses ist hierbei das entscheidende Kriterium: Der Nutzer fühlt sich zwar als Autor seiner Handlungen, folgt jedoch einer technologisch präfigurierten Wahlarchitektur.²⁷³

Die Auswirkungen dieser Dynamiken variieren jedoch zwischen verschiedenen Nutzergruppen, wobei insbesondere Jugendliche oft als vulnerable Zielgruppe thematisiert werden.²⁷⁴ Specification Curve Analysen von Orben und Przybylski zeigen jedoch, dass der Zusammenhang zwischen Technologienutzung und psychischem Wohlbefinden bei Jugendlichen insgesamt sehr gering ist und höchstens 0,4 % der Varianz erklärt.²⁷⁵ Diese Effekte sind im Vergleich zu anderen Faktoren wie Schlafmangel oder Mobbing als klein einzustufen.²⁷⁶ Dennoch bleibt die Anfälligkeit für sozialen Vergleich und die Suche nach Bestätigung ein Faktor, der durch algorithmische Feedback-Signale verstärkt werden kann.²⁷⁷

Zusammenfassend lässt sich festhalten, dass Personalisierung weit über die bloße Anpassung an Nutzerpräferenzen hinausgeht. Durch die Kombination von kontinuierlichem Monitoring, psychologischem Profiling und adaptiven Trigger-Mechanismen werden Architekturen geschaffen, die Verhaltensmuster aktiv formen.²⁷⁸ Diese Verhaltensdynamiken bilden den Kern einer neuen Form der Machtausübung, deren Effektivität direkt mit der Undurchsichtigkeit der zugrunde liegenden Logiken korreliert.²⁷⁹ Die Frage, welche treibenden Kräfte hinter der Implementierung dieser Systeme stehen und wie diese in die globale Plattformökonomie eingebettet sind, führt direkt zur Analyse der ökonomischen Interessen und Plattformlogiken im nächsten Kapitel.

4.3 Ökonomische Interessen und Plattformlogiken

Die ökonomische Dimension KI-gestützter Monitoring-Systeme verdeutlicht, dass diese nicht lediglich technologische Infrastrukturen darstellen, sondern das Fundament neuartiger Geschäftsmodelle bilden, die Verhaltensdaten, Nutzeraufmerksamkeit und Vorhersagewissen systematisch in ökonomischen Wert transformieren.^{280,281} In der modernen Plattformökonomie fungieren digitale Informationssysteme als extraktive Apparate, deren primärer Zweck in der Erfassung und Verwertung von Daten als strategische Ressource liegt.²⁸² Dieser Abschnitt erläutert die ökonomischen Mechanismen dieser Transformation

²⁷² Vgl. Susser, Roessler & Nissenbaum(2019), S. 26.

²⁷³ Vgl. Susser, Roessler & Nissenbaum(2019), S. 28.

²⁷⁴ Vgl. Orben & Przybylski(2019), S. 1.

²⁷⁵ Vgl. Orben & Przybylski(2019), S. 1.

²⁷⁶ Vgl. Orben & Przybylski(2019), S. 6.

²⁷⁷ Vgl. Metzler & Garcia(2023), S. 1.

²⁷⁸ Vgl. Zuboff(2019), S. 283.

²⁷⁹ Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

²⁸⁰ Vgl. Srnicek(2017), S. 18.

²⁸¹ Vgl. Zuboff(2019), S. 4.

²⁸² Vgl. Srnicek(2017), S. 21.

sowie die daraus resultierenden strukturellen Konsequenzen für Märkte und Individuen.

Ökonomische Mechanismen der Datenverwertung Der Kern dieser ökonomischen Logik liegt in der Transformation menschlicher Erfahrung in Verhaltensdaten, ein Prozess, den Zuboff (2019) als Grundlage des Überwachungskapitalismus beschreibt.²⁸³ Dabei wird ein „Verhaltensüberschuss“ (Behavioral Surplus) generiert, der über die für die bloße Serviceverbesserung notwendigen Daten hinausgeht und als Rohmaterial für die Herstellung von Vorhersageprodukten dient.²⁸⁴ Diese Daten fungieren im 21. Jahrhundert ähnlich wie das Öl im Industriezeitalter: Sie müssen extrahiert, raffiniert und in verschiedenen wertschöpfenden Prozessen eingesetzt werden.²⁸⁵ Die Datafizierung ermöglicht es dabei, ehemals wertlose Nebenprodukte digitaler Dienste in wertvolle Ressourcen zu verwandeln, die Aufschluss über Präferenzen, Stimmungen und zukünftige Absichten der Nutzer geben.²⁸⁶²⁸⁷

Die ökonomische Überlegenheit moderner Plattformen basiert maßgeblich auf dem Masterplan von Analytik und Vorhersagefähigkeiten. Unternehmen, die „auf Basis von Analysen konkurrieren“ (Competing on Analytics), nutzen komplexe statistische Modelle und maschinelles Lernen, um jeden Aspekt ihrer Geschäftsprozesse zu optimieren und individuelle Kundenbedürfnisse mit mathematischer Präzision vorherzusagen.²⁸⁸ Datengetriebene Wettbewerbsvorteile entstehen hierbei durch geschlossene Feedback-Schleifen: Je mehr Daten eine Plattform sammelt, desto besser werden ihre Algorithmen, was wiederum mehr Nutzer anzieht und den Wert der Vorhersageprodukte für Werbetreibende erhöht.²⁸⁹²⁹⁰

Die strukturelle Basis hierfür bilden Plattformökosysteme, die als mehrseitige Märkte (Multi-sided Markets) fungieren und Interaktionen zwischen verschiedenen Gruppen wie Nutzern, Werbetreibenden und Drittanbietern koordinieren.²⁹¹²⁹² Ein entscheidendes Merkmal sind Netzwerkeffekte, bei denen der Nutzen der Plattform für einen Teilnehmer mit der Anzahl der Nutzer auf der anderen Seite des Marktes steigt.²⁹³ Um diese Effekte zu maximieren, setzen Plattformen häufig auf Strategien der Quersubventionierung, bei denen Dienste für Nutzer kostenlos angeboten werden, um eine kritische Masse zu erreichen, während die Monetarisierung über die Werbeindustrie oder den Verkauf von Daten erfolgt.²⁹⁴²⁹⁵ In dieser Logik werden Metadaten zur „Währung“, mit der Bürger für

²⁸³ Vgl. Zuboff(2019), S. 4.

²⁸⁴ Vgl. Zuboff(2019), S. 4.

²⁸⁵ Vgl. Srnicek(2017), S. 18.

²⁸⁶ Vgl. Dijck(2014), S. 1.

²⁸⁷ Vgl. **MayerSchoenberger2013**, S. 30.

²⁸⁸ Vgl. Davenport(2006), S. 1.

²⁸⁹ Vgl. Parker, Van Alstyne & Choudary(2016), S. 3.

²⁹⁰ Vgl. **Cusumano2019**, S. 564.

²⁹¹ Vgl. Evans & Schmalensee(2016).

²⁹² Vgl. Tiwana(2014), S. 1.

²⁹³ Vgl. Parker, Van Alstyne & Choudary(2016), S. 17.

²⁹⁴ Vgl. Srnicek(2017), S. 20.

²⁹⁵ Vgl. Dijck(2014), S. 1.

Kommunikationsdienste und Bequemlichkeit bezahlen.²⁹⁶

Konsequenzen der Plattformdominanz Die beschriebenen Mechanismen führen zu einer massiven Konzentration von Marktmacht. Netzwerkeffekte und geringe Grenzkosten begünstigen „Winner-take-all“- oder „Winner-take-most“-Dynamiken, in denen wenige dominante Akteure wie Alphabet, Amazon oder Meta den Markt kontrollieren.²⁹⁷²⁹⁸ Dies schafft eine tiefe Abhängigkeit von Nutzern und Komplementoren (z. B. App-Entwicklern), da die Plattformbesitzer als zentrale Torwächter fungieren, welche die Regeln des Ökosystems und die Verteilung der Wertschöpfung einseitig festlegen.²⁹⁹³⁰⁰

Ein kritisches Resultat dieser Dominanz sind tiefgreifende Informationsasymmetrien zwischen Plattformen und Individuen. Während die Betreiber durch die Aggregation massiver Datensätze über ein nahezu „perfektes Gedächtnis“ verfügen, bleibt die Funktionsweise ihrer Entscheidungslogiken für den Einzelnen undurchsichtig.³⁰¹³⁰² Diese Opazität der „Gesellschaft des Schwarzen Kastens“ führt dazu, dass algorithmische Bewertungen – etwa Kredit-Scores oder Reputationswerte – lebensverändernde Konsequenzen haben können, ohne dass die Betroffenen die zugrunde liegenden Kriterien verstehen oder anfechten können.³⁰³ Die Plattformbetreiber nutzen diesen Wissensvorsprung gezielt aus, um das Nutzerverhalten durch subtile „Anstöße“ in eine für das Unternehmen profitable Richtung zu lenken.³⁰⁴³⁰⁵

Schließlich entsteht ein permanentes Spannungsfeld zwischen Personalisierung, Profitabilität und Privatsphäre. Während personalisierte Dienste einen hohen Nutzwert versprechen, erfordern sie gleichzeitig eine lückenlose Überwachung, die herkömmliche Konzepte der informationellen Selbstbestimmung untergräbt.³⁰⁶³⁰⁷ Die ökonomischen Imperative des Plattformkapitalismus verlangen nach immer tieferen Einblicken in die Privatsphäre, um die Genauigkeit der Vorhersagemodelle zu steigern, was dazu führt, dass ehemals private Handlungen zunehmend quantifiziert und kommerzialisiert werden.³⁰⁸³⁰⁹

Zusammenfassend lässt sich festhalten, dass KI-gestützte Monitoring-Systeme die infrastrukturelle Voraussetzung für eine Form des Kapitalismus geschaffen haben, die auf der systematischen Ausbeutung von Verhaltensüberschüssen beruht.³¹⁰ Die ökonomi-

²⁹⁶ Vgl. Dijck(2014), S. 1.

²⁹⁷ Vgl. Cusumano2019, S. 558.

²⁹⁸ Vgl. Srnicek(2017), S. 20.

²⁹⁹ Vgl. Tiwana(2014), S. 1.

³⁰⁰ Vgl. Parker, Van Alstyne & Choudary(2016), S. 3.

³⁰¹ Vgl. Pasquale(2015), S. 5.

³⁰² Vgl. Acquisti, Brandimarte & Loewenstein(2015), S. 1.

³⁰³ Vgl. Pasquale(2015), S. 1.

³⁰⁴ Vgl. Acquisti, Brandimarte & Loewenstein(2015), S. 1.

³⁰⁵ Vgl. Zuboff(2019), S. 4.

³⁰⁶ Vgl. OECD2011, S. 4.

³⁰⁷ Vgl. Acquisti, Brandimarte & Loewenstein(2015), S. 1.

³⁰⁸ Vgl. Srnicek(2017), S. 18.

³⁰⁹ Vgl. Dijck(2014), S. 1.

³¹⁰ Vgl. Zuboff(2019), S. 4.

sche Logik der Plattformen zielt nicht mehr nur auf die Vermittlung von Informationen ab, sondern auf die Erlangung einer instrumentellen Macht, die durch algorithmische Steuerung garantierte kommerzielle Ergebnisse sicherstellt.³¹¹ Diese Verschiebung von ökonomischer zu gesellschaftlicher Macht führt unmittelbar zur Analyse der politischen Dimension dieser Systeme, die im folgenden Kapitel über politische und gesellschaftliche Einflussmechanismen untersucht wird.

4.4 Politische und gesellschaftliche Einflussmechanismen

Die Einbettung KI-gestützter Monitoring-Systeme in politische Prozesse markiert einen Übergang von der rein funktionalen Informationsvermittlung hin zu einer proaktiven Steuerung des öffentlichen Diskurses und des sozialen Verhaltens. In der modernen Informationsgesellschaft fungieren diese Systeme nicht mehr lediglich als passive Beobachter, sondern als aktive Architekten der politischen Realität, indem sie die Sichtbarkeit von Themen, die Kommunikation zwischen Akteuren und die emotionalen Reaktionen der Bürger gezielt beeinflussen.³¹²³¹³ Die politische Dimension dieser technologischen Infrastrukturen manifestiert sich dabei sowohl in demokratischen als auch in autoritären Kontexten, wobei die Mechanismen der algorithmischen Selektion und der automatisierten Kommunikation als Instrumente der Machtausübung dienen.³¹⁴³¹⁵

Mechanismen der politischen Einflussnahme Ein zentraler Mechanismus der politischen Steuerung ist die algorithmische Verstärkung und Sichtbarkeitssteuerung. Empfehlungssysteme und Ranking-Algorithmen determinieren maßgeblich, wer im digitalen Raum gehört wird und welche Themen die öffentliche Aufmerksamkeit dominieren.³¹⁶ Gillespie (2014) beschreibt diese Systeme als „Public Relevance Algorithms“, die Wissen nicht nur organisieren, sondern durch spezifische Kriterien erst zertifizieren.³¹⁷ Diese Macht zur Priorisierung ermöglicht es, politische Symbole über expansive Netzwerke zu verbreiten und durch Verfahren wie das „Downranking“ unliebsame Stimmen faktisch unsichtbar zu machen.³¹⁸³¹⁹

Darauf aufbauend ermöglicht die systematische Datenerfassung eine personalisierte politische Kommunikation, die oft als Micro-Targeting bezeichnet wird. Durch die Analyse digitaler Fußabdrücke können politische Botschaften exakt auf die psychologischen Profile und Schwachstellen individueller Wähler zugeschnitten werden.³²⁰ Cambridge Analytica

³¹¹ Vgl. Zuboff(2019), S. 62.

³¹² Vgl. Bradshaw & Howard(2018), S. 1.

³¹³ Vgl. Narayanan(2023), S. 1.

³¹⁴ Vgl. Feldstein(2019), S. 32.

³¹⁵ Vgl. Woolley & Howard(2017), S. 1.

³¹⁶ Vgl. Narayanan(2023), S. 5.

³¹⁷ Vgl. Gillespie(2014), S. 1.

³¹⁸ Vgl. Narayanan(2023), S. 6.

³¹⁹ Vgl. Gillespie(2014), S. 1.

³²⁰ Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

dient hierbei als prominentes Beispiel für die Nutzung von psychometrischen Profilen, um „innere Dämonen“ zu adressieren und Wähler in eine gewünschte Richtung zu lenken.³²¹ Diese Form der Beeinflussung operiert oft im Verborgenen, was Yeung (2017) als Hyper-Anstöße charakterisiert – eine Form der dynamischen, datengesteuerten Regulierung, die sich adaptiv an den Kontext des Nutzers anpasst und herkömmliche Überzeugungsarbeit durch eine subtile Wahlarchitektur ersetzt.³²²³²³

Zusätzlich werden Bots und koordinierte Manipulationskampagnen eingesetzt, um den öffentlichen Diskurs künstlich zu verzerren. Sogenannte „Cyber Troops“ – staatliche oder parteinahe Akteure – nutzen automatisierte Konten, um die Illusion eines breiten Konsenses zu erzeugen (Astroturfing) oder Oppositionelle durch konzertierte Angriffe zu diffamieren.³²⁴³²⁵ Diese Form der Computational Propaganda nutzt die Algorithmen der Plattformen gezielt aus, indem sie durch massenhafte Interaktionen bestimmte Keywords in die Trends befördert und so die Agenda der traditionellen Medien beeinflusst.³²⁶

Die Wirksamkeit dieser Kampagnen wird durch die algorithmische Bevorzugung emotionaler und polarisierender Inhalte verstärkt. Plattformen optimieren primär auf Interaktion, was dazu führt, dass sensationelle oder empörende Informationen eine höhere Reichweite erzielen als sachliche Diskurse.³²⁷³²⁸ Experimentelle Studien zur emotionalen Ansteckung (Emotional Contagion) belegen zudem, dass die gezielte Manipulation des News Feeds die Stimmungslage von Millionen von Nutzern messbar verändern kann.³²⁹ In autoritären Staaten wie China wird diese technologische Kapazität zur staatlichen Überwachung und Zensur perfektioniert. Die Integration von KI in Systeme wie das SCS oder die „Great Firewall“ erlaubt eine lückenlose Kontrolle des Informationsflusses und die Identifikation potenzieller Dissidenten durch Mustererkennung in Echtzeit.³³⁰³³¹

Gesellschaftliche und politische Konsequenzen Die Anwendung dieser Mechanismen hat tiefgreifende Konsequenzen für die Stabilität demokratischer Institutionen. Eine wesentliche Folge ist die Manipulation des öffentlichen Diskurses durch die systematische Verbreitung von Desinformation. Da soziale Medien sensationelle Inhalte bevorzugen, verbreiten sich „Junk News“ oft schneller und weiter als professioneller Journalismus.³³²³³³ Dies untergräbt das Vertrauen in Medien, Wissenschaft und öffentliche Institutionen, was

³²¹ Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

³²² Vgl. Yeung(2017).

³²³ Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

³²⁴ Vgl. Bradshaw & Howard(2018), S. 1.

³²⁵ Vgl. Woolley & Howard(2017), S. 1.

³²⁶ Vgl. Bradshaw & Howard(2018), S. 2.

³²⁷ Vgl. Narayanan(2023), S. 25.

³²⁸ Vgl. Woolley & Howard(2017), S. 1.

³²⁹ Vgl. Kramer, Guillory & Hancock(2014), S. 1.

³³⁰ Vgl. Creemers(2018), S. 1.

³³¹ Vgl. Qiang(2019), S. 1.

³³² Vgl. Woolley & Howard(2017), S. 1.

³³³ Vgl. Bradshaw & Howard(2018), S. 1.

die Grundlage für eine faktenbasierte demokratische Meinungsbildung erodiert.³³⁴

Ein weiteres viel diskutiertes Phänomen ist die Polarisierung und Fragmentierung der Gesellschaft. Während Filterblasen als Resultat algorithmischer Personalisierung Individuen in homogenen Informationsräumen isolieren, beschreiben Echokammern soziale Strukturen, in denen sich Gleichgesinnte gegenseitig in ihren Weltbildern bestärken.³³⁵³³⁶ Metzler und Garcia (2023) betonen jedoch, dass Algorithmen hierbei oft bestehende soziale Treiber lediglich verstärken.³³⁷ Empirische Befunde zeigen, dass die Plattformarchitektur entscheidend ist: Während Facebook homophile Cluster begünstigt, fördern andere Strukturen eher den Kontakt mit dissonanten Meinungen.³³⁸ Dennoch kann die ständige Konfrontation mit extremen Positionen die wahrgenommene Polarisierung erhöhen und gemäßigte Mehrheiten unsichtbar machen.³³⁹

Diese Dynamiken beeinflussen auch die politische Partizipation und Mobilisierung. Einerseits bieten soziale Netzwerke neue Wege für bürgerschaftliche Beteiligung und die Koordination von Protestbewegungen, wie sie während des Arabischen Frühlings beobachtet wurden.³⁴⁰ Andererseits führt die omnipräsente Überwachung zu einem Chilling Effect, bei dem Bürger aus Angst vor Repressionen oder sozialer Ausgrenzung auf die freie Meinungsäußerung verzichten.³⁴¹ In autoritären Regimen wird KI-gestütztes Monitoring genutzt, um Proteste bereits im Keim zu ersticken, indem Bewegungen prädiktiv analysiert und deren Anführer gezielt neutralisiert werden.³⁴²

Schließlich führt die flächendeckende Implementierung dieser Systeme zu einer Normalisierung von Überwachung und sozialer Kontrolle. In China wird das Streben nach einer „perfekten Erinnerung“ des Staates an seine Bürger durch das SCS institutionalisiert, wobei algorithmische Bewertungen über den Zugang zu grundlegenden Dienstleistungen entscheiden.³⁴³³⁴⁴ Diese Entwicklung markiert den Aufstieg eines digitalen Autoritarismus, der nicht mehr auf physischen Zwang allein, sondern auf die algorithmische Disziplinierung durch Belohnung und Bestrafung setzt.³⁴⁵³⁴⁶

Zusammenfassend lässt sich festhalten, dass KI-gestützte Monitoring-Systeme Politik und Gesellschaft fundamental transformieren, indem sie die Bedingungen der Kommunikation und des sozialen Austauschs neu definieren. Die daraus resultierenden Risiken für

³³⁴ Vgl. Bradshaw & Howard(2018), S. 1.

³³⁵ Vgl. Cinelli u. a.(2021), S. 1.

³³⁶ Vgl. Gillespie(2014), S. 1.

³³⁷ Vgl. Metzler & Garcia(2023), S. 1.

³³⁸ Vgl. Cinelli u. a.(2021), S. 1.

³³⁹ Vgl. Metzler & Garcia(2023), S. 1.

³⁴⁰ Vgl. Bradshaw & Howard(2018), S. 1.

³⁴¹ Vgl. Bradshaw & Howard(2018), S. 1.

³⁴² Vgl. Feldstein(2019), S. 34.

³⁴³ Vgl. Creemers(2018), S. 1.

³⁴⁴ Vgl. Qiang(2019), S. 1.

³⁴⁵ Vgl. Qiang(2019), S. 1.

³⁴⁶ Vgl. U.S.-China Economic and Security Review Commission(2020), S. 1.

die individuelle Autonomie und die demokratische Ordnung fordern bestehende regulatorische Rahmenbedingungen heraus. Die Frage, wie diese mächtigen technologischen Infrastrukturen rechtlich und ethisch eingehegt werden können, um eine vertrauenswürdige KI sicherzustellen, ist Gegenstand des abschließenden Kapitels über Governance- und Kontrollstrukturen.

4.5 Governance- und Kontrollstrukturen

Die umfassenden sozioökonomischen und politischen Auswirkungen KI-gestützter Monitoring-Systeme verdeutlichen die Notwendigkeit robuster Governance-Strukturen, um algorithmische Macht einzuhegen und Verantwortlichkeiten zu klären. Effektive Governance erfordert dabei ein integratives Zusammenspiel aus rechtlichen Normen, ethischen Prinzipien, organisatorischen Risikomanagement-Prozessen und technischen Kontrollmechanismen.³⁴⁷³⁴⁸ Der folgende Abschnitt analysiert zunächst die zentralen Herausforderungen der Regulierung und stellt darauf aufbauend die wichtigsten Governance-Ansätze dar.

Herausforderungen der algorithmischen Governance Die primäre Hürde für eine wirksame Kontrolle liegt in der konstitutiven Opazität algorithmischer Entscheidungsprozesse. Pasquale (2015) beschreibt moderne Informations- und Finanzsysteme als „Schwarze Kästen“, deren interne Logiken durch eine Kombination aus technischer Komplexität, echtem Geheimwissen und rechtlichem Schutz von Geschäftsgeheimnissen der öffentlichen Einsicht entzogen werden.³⁴⁹ Diese Undurchsichtigkeit führt zu massiven Informationsasymmetrien, da Plattformbetreiber zwar über ein nahezu perfektes Wissen über die Nutzer verfügen, deren eigene Bewertungskriterien jedoch im Verborgenen bleiben.³⁵⁰³⁵¹

In diesem Kontext entstehen erhebliche Risiken für automatisierte Klassifikationen und Diskriminierung. O’Neil (2016) charakterisiert problematische Modelle als „Weapons of Math Destruction“, die oft auf fehlerhaften Daten oder voreingenommenen Annahmen basieren und bestehende soziale Ungleichheiten mathematisch zementieren, ohne dass für die Betroffenen Einspruchsmöglichkeiten bestehen.³⁵² Die lückenlose Erfassung von Verhaltensdaten untergräbt zudem die menschliche Autonomie und die informationelle Selbstbestimmung, da Individuen oft die Kontrolle darüber verlieren, wie ihre digitalen Fußabdrücke aggregiert und zur Verhaltensbeeinflussung genutzt werden.³⁵³³⁵⁴ Eine unklare Zuweisung von Verantwortung erschwert zudem die Rechenschaftspflicht (Accountability), wenn algorithmische Entscheidungen zu materiellen oder immateriellen

³⁴⁷ Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 1.

³⁴⁸ Vgl. National Institute of Standards and Technology(2023), S. 1.

³⁴⁹ Vgl. Pasquale(2015), S. 1.

³⁵⁰ Vgl. Pasquale(2015), S. 1.

³⁵¹ Vgl. Zuboff(2019), S. 4.

³⁵² Vgl. O’Neil(2016), S. 2.

³⁵³ Vgl. Lyon(2012), S. 2.

³⁵⁴ Vgl. Dijck(2014), S. 1.

Schäden führen.³⁵⁵³⁵⁶

Rechtliche Regulierungsansätze im EU-Kontext Zur Bewältigung dieser Herausforderungen hat die Europäische Union einen multidimensionalen Rechtsrahmen etabliert, der auf verschiedenen Ebenen ansetzt. Die Datenschutz-Grundverordnung (DSGVO) bildet das fundamentale Fundament für den Schutz personenbezogener Daten und adressiert spezifisch die Risiken von Profiling und automatisierter Entscheidungsfindung. Gemäß Artikel 22 der DSGVO haben betroffene Personen grundsätzlich das Recht, nicht einer ausschließlich auf einer automatisierten Verarbeitung beruhenden Entscheidung unterworfen zu werden, die ihnen gegenüber rechtliche Wirkung entfaltet oder sie in ähnlicher Weise erheblich beeinträchtigt.³⁵⁷ Die DSGVO fordert zudem die Einhaltung zentraler Prinzipien wie Datenminimierung, Zweckbindung und Transparenz, was die extraktiven Praktiken des Überwachungskapitalismus rechtlich begrenzt.³⁵⁸³⁵⁹

Ergänzend dazu führt das Gesetz über Künstliche Intelligenz (Artificial Intelligence (AI) Act) einen risikobasierten Ansatz ein, der KI-Systeme nach ihrem Gefährdungspotenzial klassifiziert. Bestimmte Praktiken, wie etwa der Einsatz manipulativer Techniken zur Beeinflussung des Nutzerverhaltens oder KI-basiertes Citizen Scoring durch staatliche Stellen, werden explizit untersagt.³⁶⁰ Hochrisiko-KI-Systeme, zu denen insbesondere Monitoring-Systeme in den Bereichen Beschäftigung, Bildung und Strafverfolgung zählen, unterliegen strengen Anforderungen an das Risikomanagement, die Datenqualität und die technische Dokumentation.³⁶¹ Ein zentrales Element des AI Act ist die Forderung nach menschlicher Aufsicht (Human Oversight), um sicherzustellen, dass KI-Systeme die menschliche Autonomie nicht untergraben und Entscheidungen jederzeit durch natürliche Personen korrigiert werden können.³⁶²

Für digitale Plattformen schafft das Gesetz über digitale Dienste (Digital Services Act – DSA) zusätzliche Verantwortlichkeiten. Sehr große Online-Plattformen werden verpflichtet, systemische Risiken zu bewerten, die von ihren Diensten ausgehen – insbesondere im Hinblick auf die Verbreitung von Desinformation oder negative Auswirkungen auf Grundrechte.³⁶³ Der DSA fordert zudem eine erhöhte Transparenz für Empfehlungssysteme; Plattformbetreiber müssen die wichtigsten Parameter ihrer Algorithmen offenlegen und den Nutzern Optionen zur Verfügung stellen, die Reihenfolge der Inhalte zu beeinflussen.³⁶⁴ Diese regulatorischen Maßnahmen zielen darauf ab, die algorithmische Kuratierung

³⁵⁵ Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 4.

³⁵⁶ Vgl. Pasquale(2015), S. 1.

³⁵⁷ Vgl. Europäisches Parlament und Rat(2016), S. 1.

³⁵⁸ Vgl. Europäisches Parlament und Rat(2016), S. 1.

³⁵⁹ Vgl. Zuboff(2019), S. 471.

³⁶⁰ Vgl. Europäisches Parlament und Rat(2024), S. 1.

³⁶¹ Vgl. Europäisches Parlament und Rat(2024), S. 1.

³⁶² Vgl. Europäisches Parlament und Rat(2024), S. 4.

³⁶³ Vgl. Europäisches Parlament und Rat(2022), S. 24.

³⁶⁴ Vgl. Europäisches Parlament und Rat(2022), S. 17.

kontrollierbar zu machen und Informationsasymmetrien abzubauen.³⁶⁵

Ethische Leitlinien und organisatorisches Risikomanagement Über die rein gesetzlichen Verpflichtungen hinaus bilden ethische Leitlinien einen Orientierungsrahmen für eine vertrauenswürdige KI. Die Ethik-Leitlinien der High-Level Expert Group on AI definieren Vertrauenswürdigkeit durch drei Komponenten: KI sollte rechtmäßig, ethisch und robust sein.³⁶⁶ Zu den sieben Kernanforderungen zählen unter anderem Vorrang menschlichen Handelns, technische Robustheit, Transparenz sowie Vielfalt und Nichtdiskriminierung.³⁶⁷ Diese Prinzipien dienen als Grundlage für die Entwicklung einer ethischen Kultur innerhalb von Organisationen und sollen sicherstellen, dass KI-Systeme zum menschlichen Wohlergehen beitragen.³⁶⁸³⁶⁹

Die praktische Operationalisierung dieser Werte erfolgt durch Rahmenwerke wie das NIST AI Risk Management Framework. Dieses Framework schlägt einen iterativen Prozess vor, der die Funktionen Regieren (Govern), Abbilden (Map), Messen (Measure) und Verwalten (Manage) umfasst.³⁷⁰ Governance wird hierbei als querschnittliche Funktion verstanden, die eine Risikokultur im gesamten Unternehmen verankert und klare Linien der Rechenschaftspflicht zwischen Management und technischen Teams etabliert.³⁷¹ Organisationen werden dazu angehalten, regelmäßige Audits, Folgenabschätzungen und ein kontinuierliches Monitoring durchzuführen, um unvorhergesehene negative Auswirkungen frühzeitig zu erkennen und abzumildern.³⁷²³⁷³

Zusammenfassend lässt sich festhalten, dass eine effektive Governance KI-gestützter Monitoring-Systeme nicht durch ein einzelnes Instrument erreicht werden kann. Vielmehr ist eine Kombination aus verbindlicher Gesetzgebung, ethischer Selbstverpflichtung und technischer Kontrolle erforderlich. Dennoch kann Regulierung allein keine vollständige Lösung bieten, da technologische Innovationen die regulatorische Kapazität oft überholen.³⁷⁴³⁷⁵ Die ständige Spannung zwischen technologischer Dynamik, ökonomischen Interessen und dem Schutz fundamentaler Rechte erfordert daher eine kontinuierliche gesellschaftliche Debatte über die Grenzen algorithmischer Steuerung. Diese abschließende Betrachtung leitet über zum Fazit der Arbeit, in dem die Ergebnisse zusammengeführt und ein Ausblick auf die zukünftige Gestaltung digitaler Informationsumgebungen gegeben wird.

³⁶⁵Vgl. Europäisches Parlament und Rat(2022), S. 93.

³⁶⁶Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 1.

³⁶⁷Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 4.

³⁶⁸Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 1.

³⁶⁹Vgl. National Institute of Standards and Technology(2023), S. 2.

³⁷⁰Vgl. National Institute of Standards and Technology(2023), S. 10.

³⁷¹Vgl. National Institute of Standards and Technology(2023), S. 11.

³⁷²Vgl. National Institute of Standards and Technology(2023), S. 18.

³⁷³Vgl. O’Neil(2016), S. 2.

³⁷⁴Vgl. Pasquale(2015), S. 1.

³⁷⁵Vgl. Lyon(2012), S. 2.

5 Kritische Betrachtung

Die vorangegangenen Kapitel dieser Arbeit haben die technologische Funktionsweise, die Systemlogiken sowie die sozioökonomischen Implikationen KI-gestützter Monitoring-Systeme durch einen literaturbasierten und konzeptionellen Ansatz systematisch analysiert. Um die eingangs formulierte Forschungsfrage jedoch verantwortungsvoll und ganzheitlich zu beantworten, ist eine kritische Reflexion der zugrunde liegenden Annahmen, der synthetisierten Befunde und der methodischen Entscheidungen unerlässlich.³⁷⁶ Die in dieser Untersuchung dargelegten Erkenntnisse dürfen nicht als absolute Wahrheiten missverstanden werden, sondern müssen innerhalb spezifischer Limitationen interpretiert werden, die sich aus der Natur digitaler Ökosysteme und der gewählten Forschungsstrategie ergeben.

Eine zentrale Herausforderung stellt die mangelnde Transparenz proprietärer Algorithmen und interner Plattformdaten dar, die in der Literatur treffend als „Schwarze Kästen“ charakterisiert werden und eine unabhängige wissenschaftliche Überprüfung der tatsächlichen Wirkmechanismen massiv erschweren.³⁷⁷ Diese informationelle Asymmetrie wird durch die rasante technologische Entwicklung im Bereich der Künstlichen Intelligenz verschärft, welche die Gefahr birgt, dass theoretische Fixierungen bereits zum Zeitpunkt ihrer Niederschrift von der technischen Realität überholt werden.³⁷⁸ Darüber hinaus erfordern die Selektion und die inhärente Heterogenität der herangezogenen Literaturbasis eine kritische Würdigung, da die Synthese bestehenden Wissens immer auch die Perspektiven und etwaige Verzerrungen der Primärquellen übernimmt.

Besonderes Augenmerk verdient zudem die Diskrepanz zwischen theoretischen Modellen und widersprüchlichen empirischen Befunden. Während konzeptionelle Ansätze oft von einer automatischen Radikalisierung oder Isolation in Filterblasen ausgehen, mahnt die aktuelle Forschung zur Differenzierung, da viele Effekte stark kontextabhängig sind und durch das individuelle Nutzerverhalten überlagert werden.³⁷⁹³⁸⁰ Das Fehlen eigener empirischer Primärdaten in dieser Arbeit begrenzt zudem die Möglichkeit, die theoretisch hergeleiteten Verhaltensdynamiken unmittelbar zu verifizieren oder deren Transferierbarkeit über verschiedene Plattformen und politische Systeme hinweg abschließend zu bewerten. Schließlich muss die Grenze zwischen einer normativen Kritik am „Instrumentarismus“ und den tatsächlich nachweisbaren, oft geringfügigen Effekten auf das menschliche Wohlbefinden präzise reflektiert werden, um eine wissenschaftlich fundierte Einordnung der Machtverhältnisse in digitalen Räumen zu ermöglichen.³⁸¹³⁸²

³⁷⁶Vgl. Brocke u. a.(2009), S. 1.

³⁷⁷Vgl. Pasquale(2015), S. 1.

³⁷⁸Vgl. National Institute of Standards and Technology(2023), S. 1.

³⁷⁹Vgl. Areeb u. a.(2023), S. 1.

³⁸⁰Vgl. Kelm, Dohle & Bernhard(2023), S. 1.

³⁸¹Vgl. Orben & Przybylski(2019), S. 6.

³⁸²Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 4.

Diese notwendige kritische Auseinandersetzung beginnt im folgenden Abschnitt mit der Untersuchung der technologischen Analysevoraussetzungen und den damit verbundenen Grenzen der algorithmischen Durchdringung.

5.1 Grenzen der technologischen Analyse

Die technologische Analyse der vorliegenden Arbeit konzentriert sich primär auf die Funktionsweise von KI-gestützten Monitoring-Systemen als integrierte Bestandteile digitaler Informationsumgebungen. Der Untersuchung liegt dabei ein idealtypischer Monitoring-Zyklus zugrunde, der die Phasen Datenerfassung → Profilbildung → Analyse → Prognose und Bewertung → algorithmische Intervention → erneute Datenerfassung umfasst. Es muss jedoch kritisch angemerkt werden, dass diese Abfolge eine analytische Vereinfachung darstellt, um die komplexen Wirkmechanismen der Verhaltenssteuerung theoretisch handhabbar zu machen. In der technologischen Realität sind die Grenzen zwischen diesen Phasen oft fließend, und die zugrunde liegende Infrastruktur ist weitaus heterogener, als es das generalisierte Modell vermuten lässt.³⁸³

Ein wesentlicher limitierender Faktor dieser Untersuchung ist, dass Teilsysteme wie Empfehlungsalgorithmen, Ranking-Verfahren oder Scoring-Mechanismen zwar detailliert analysiert wurden, diese jedoch lediglich spezifische operative Komponenten innerhalb einer weitaus umfassenderen Monitoring-Infrastruktur darstellen.³⁸⁴ Die Arbeit fokussiert sich stark auf die Ebenen der Analyse, Prognose und Verhaltensbeeinflussung, während die tieferliegenden technologischen Schichten weitgehend abstrahiert werden. Hierzu zählen insbesondere die physikalische Beschaffenheit und Platzierung von Sensortechnologien, die spezifischen Protokolle der Datenübertragung sowie die komplexen Speicher- und Hardwarearchitekturen, die für die Verarbeitung massiver Datenvolumina in Echtzeit erforderlich sind.³⁸⁵ Ohne eine tiefgehende Betrachtung dieser basalen Infrastrukturebene bleibt die technologische Durchdringung des Gesamtprozesses auf einer funktionalen Ebene stehen.

Ein weiteres zentrales Problem für die wissenschaftliche Genauigkeit der technologischen Analyse ist die konstitutive Opazität der untersuchten Systeme. Da es sich bei den Plattformen von Unternehmen wie Meta, Google oder TikTok um proprietäre Architekturen handelt, sind weder die exakten Trainingsdaten noch die spezifischen Modellparameter oder die algorithmischen Gewichtungen für die externe Forschung zugänglich.³⁸⁶ Die Funktionsweise realer Systeme kann daher lediglich konzeptionell auf Basis veröffentlichter Literatur, technischer Whitepaper und Leaks rekonstruiert werden. Es ist einzuräumen, dass diese Arbeit kein technisches Audit realer Plattformen leisten kann, sondern eine

³⁸³ Vgl. Russell & Norvig(2010), S. 24.

³⁸⁴ Vgl. Narayanan(2023), S. 1.

³⁸⁵ Vgl. K. C. Laudon, J. P. Laudon & Elragal(2016), S. 1.

³⁸⁶ Vgl. Pasquale(2015), S. 1.

theoriegeleitete Synthese der systemischen Zusammenhänge bietet.³⁸⁷ Die hier beschriebenen Mechanismen operieren somit notwendigerweise innerhalb einer „Black-Box“-Logik, bei der die internen Rechenoperationen nur über ihre Ein- und Ausgabewerte erschlossen werden können.³⁸⁸

Zudem führt die Vereinfachung heterogener Technologien in ein allgemeines Prozessmodell zu einer Vernachlässigung sektoraler und geografischer Unterschiede. KI-gestützte Monitoring-Systeme unterscheiden sich massiv in ihrer technischen Ausgestaltung, je nachdem, ob sie in kommerziellen westlichen Märkten oder in staatlich integrierten Governance-Strukturen wie dem chinesischen Social Credit System eingesetzt werden.³⁸⁹ Auch die rasante technologische Entwicklungsgeschwindigkeit im Bereich des Deep Learning limitiert die langfristige Validität spezifischer technischer Beschreibungen, da neue Verfahren (etwa im Bereich der Transformer-Modelle) die Mechanismen der Mustererkennung und Vorhersage laufend verändern.³⁹⁰

Schließlich ist kritisch zu reflektieren, dass die in der Arbeit beobachteten Nutzerreaktionen und Verhaltensdynamiken nicht monokausal auf algorithmische Interventionen zurückgeführt werden können. Algorithmen operieren niemals in einem sozialen Vakuum; vielmehr interagieren sie permanent mit sozialen, organisatorischen und individuellen Faktoren.³⁹¹ Ein Monitoring-System kann zwar Wahrscheinlichkeiten für Verhalten berechnen und durch Anstöße beeinflussen, doch das tatsächliche Ergebnis einer Interaktion ist immer das Produkt eines komplexen soziotechnischen Gefüges, in dem die menschliche Agency und soziale Kontexte eine unvorhersehbare Rolle spielen.³⁹²

Zusammenfassend bietet dieses Unterkapitel eine notwendige Einordnung der technologischen Analysetiefe dieser Arbeit. Während die zentralen funktionalen Zusammenhänge und Systemlogiken präzise herausgearbeitet wurden, stößt die Untersuchung bei der detaillierten technischen Rekonstruktion interner Plattformprozesse an systemimmanente Grenzen. Diese technologischen Limitationen hängen eng mit der Beschaffenheit der verfügbaren wissenschaftlichen Quellen zusammen, deren Selektion und Heterogenität im folgenden Abschnitt zu den Grenzen der Literaturbasis kritisch gewürdigt werden.

5.2 Grenzen der Literaturbasis

Die vorliegende Arbeit stützt sich auf eine breite Auswahl wissenschaftlicher Quellen, um die komplexen Wirkmechanismen KI-gestützter Monitoring-Systeme theoretisch zu erfassen. Es muss jedoch kritisch reflektiert werden, dass die herangezogene Literaturbasis inhärente Limitationen aufweist, die die Generalisierbarkeit der Ergebnisse einschrän-

³⁸⁷Vgl. National Institute of Standards and Technology(2023), S. 18.

³⁸⁸Vgl. Pasquale(2015), S. 1.

³⁸⁹Vgl. Lyon(2012), S. 2.

³⁹⁰Vgl. Goodfellow, Bengio & Courville(2016), S. 210.

³⁹¹Vgl. Lyon(2012), S. 5.

³⁹²Vgl. National Institute of Standards and Technology(2023), S. 2.

ken. Da die Untersuchung an der Schnittstelle von Wirtschaftsinformatik, Soziologie, Rechtswissenschaft und Psychologie angesiedelt ist, unterliegen die Quellen sehr unterschiedlichen konzeptionellen und methodischen Ansätzen.³⁹³ Während die theoretischen Grundlagen der Informationssysteme auf etablierten Lehrbuchinhalten basieren, stammen Erkenntnisse über die gesellschaftlichen Auswirkungen oft aus normativ-kritischen Werken oder hochspezialisierten empirischen Studien, was die Integration in ein einheitliches Gesamtbild erschwert.³⁹⁴

Ein zentraler kritischer Aspekt ist die Heterogenität der wissenschaftlichen Evidenz zu den untersuchten Phänomenen. Die Befunde zu Filterblasen, Echokammern und der algorithmischen Polarisierung erweisen sich in der Literatur teilweise als widersprüchlich oder stark kontextabhängig.³⁹⁵ Während konzeptionelle Arbeiten wie die von Pariser (2011) vor einer drohenden informationalen Isolation warnen, zeigen systematische Reviews, dass empirische Belege für die Existenz von Filterblasen in Empfehlungssystemen uneinheitlich sind und stark vom spezifischen Design der Algorithmen abhängen.³⁹⁶ Auch im Bereich der sozialen Dynamiken belegen Studien von Cinelli et al. (2021), dass die Entstehung von Echokammern maßgeblich von der jeweiligen Plattformarchitektur beeinflusst wird, wodurch Befunde von einer Plattform (z. B. Facebook) nicht ohne Weiteres auf andere Umgebungen (z. B. Reddit oder TikTok) übertragbar sind.³⁹⁷

Des Weiteren konzentrieren sich viele der verfügbaren empirischen Untersuchungen auf spezifische Nutzergruppen oder geografische Räume. Dies gilt insbesondere für die Forschung zum Wohlbefinden von Jugendlichen im digitalen Kontext, wobei Orben und Przybylski (2019) aufzeigen, dass viele Studien auf Sekundäranalysen großer Datensätze basieren, deren hohe „analytische Flexibilität“ zu statistisch signifikanten, aber in der praktischen Bedeutung vernachlässigbaren Effekten führen kann.³⁹⁸ Diese methodische Unsicherheit in der Primärliteratur schränkt die Aussagekraft der darauf aufbauenden Synthese in dieser Arbeit ein. Zudem erschwert die konstitutive Opazität der „Gesellschaft des Schwarzen Kastens“ die unabhängige Forschung massiv, da der fehlende Zugriff auf interne Plattformdaten und proprietäre Algorithmen dazu führt, dass viele Autoren auf indirekte Beobachtungen oder theoretische Extrapolationen angewiesen sind.³⁹⁹

Darüber hinaus limitiert die technologische Dynamik die zeitliche Relevanz der Literaturbasis. Ältere, fundamentale Werke zur Plattformökonomie oder zu Filterblasen können den rasanten Aufstieg neuer KI-Verfahren, wie etwa generativer Modelle oder hochfrequenter Feedback-Schleifen in Echtzeit-Monitoring-Systemen, nur begrenzt berücksichtigen.⁴⁰⁰

³⁹³ Vgl. Pasquale(2015), S. 1.

³⁹⁴ Vgl. Brocke u. a.(2009), S. 1.

³⁹⁵ Vgl. Areeb u. a.(2023), S. 1.

³⁹⁶ Vgl. Areeb u. a.(2023), S. 1.

³⁹⁷ Vgl. Cinelli u. a.(2021), S. 1.

³⁹⁸ Vgl. Orben & Przybylski(2019), S. 1.

³⁹⁹ Vgl. Pasquale(2015), S. 1.

⁴⁰⁰ Vgl. Narayanan(2023), S. 1.

Schließlich ist einzuräumen, dass die für diese Arbeit getroffene Literatúrauswahl trotz systematischer Vorgehensweise keinen Anspruch auf absolute Vollständigkeit erheben kann.⁴⁰¹ Die Synthese umfasst zudem Quellen mit unterschiedlichen Evidenzgraden – von peer-reviewten Fachartikeln über juristische Gesetzestexte bis hin zu Berichten internationaler Organisationen –, was bei der Interpretation der Ergebnisse eine differenzierte Gewichtung der jeweiligen Argumentationsstränge erfordert.

Zusammenfassend lässt sich festhalten, dass die Literaturbasis eine fundierte Grundlage für eine konzeptionelle Analyse bietet, jedoch keine allgemeingültigen Schlussfolgerungen für sämtliche Monitoring-Systeme zulässt. Die dargelegten Unsicherheiten in der Datengrundlage und die Abhängigkeit von spezifischen Kontexten führen unmittelbar zu der Frage, welche Konsequenzen dies für die methodische Belastbarkeit der Gesamtarbeit hat. Diese Aussagekraft und methodischen Limitationen werden im folgenden Abschnitt eingehender untersucht.

5.3 Aussagekraft und methodische Limitationen

Die Aussagekraft der vorliegenden Untersuchung ist untrennbar mit ihrem qualitativen, literaturbasierten und konzeptionellen Forschungsansatz verknüpft. Da im Rahmen dieser Arbeit keine eigenen Primärdaten in Form von Interviews, Laborexperimenten, Umfragen oder direkten Zugriffen auf Plattformdaten erhoben wurden, zielt die Argumentation primär auf die systematische Rekonstruktion und Synthese des vorhandenen wissenschaftlichen Wissens ab.⁴⁰² Dieser Ansatz ermöglicht zwar eine fundierte theoretische Durchdringung der Funktionsweisen KI-gestützter Monitoring-Systeme, stößt jedoch an methodische Grenzen, sobald es um den Nachweis konkreter kausaler Effekte in spezifischen Anwendungskontexten geht. Die gewonnenen Erkenntnisse stellen somit eine Integration bestehender Theorien und Befunde dar, können jedoch keine empirische Beweiskraft für die unmittelbare Wirkung einzelner Algorithmen auf das Nutzerverhalten beanspruchen.⁴⁰³

Ein wesentlicher limitierender Faktor für die Validität der Schlussfolgerungen ist die Abhängigkeit von der Qualität, Vergleichbarkeit und Interpretation der herangezogenen Sekundärquellen. Da die wissenschaftliche Evidenz zu zentralen Phänomenen wie Filterblasen oder der algorithmischen Polarisierung oft uneinheitlich ist, hängen die Ergebnisse dieser Arbeit maßgeblich davon ab, welche empirischen Studien als Referenz gewählt wurden.⁴⁰⁴ Es ist kritisch einzuräumen, dass die Resultate nicht gleichermaßen auf alle Plattformen, Länder oder Nutzergruppen verallgemeinert werden können. Monitoring-Systeme operieren in hochgradig unterschiedlichen soziotechnischen Kontexten, wobei geografische Unterschiede oder die spezifische Architektur einer Plattform (z. B. TikTok vs. Facebook) die Generalisierbarkeit der beschriebenen Mechanismen massiv einschrän-

⁴⁰¹ Vgl. Brocke u. a.(2009), S. 1.

⁴⁰² Vgl. Brocke u. a.(2009), S. 1.

⁴⁰³ Vgl. Kelm, Dohle & Bernhard(2023), S. 1.

⁴⁰⁴ Vgl. Areeb u. a.(2023), S. 1.

ken.⁴⁰⁵

Darüber hinaus erweist sich die Isolation kausaler Beziehungen zwischen Algorithmen und menschlichem Verhalten als methodisch äußerst komplex. Die in der Literatur beobachteten Verhaltensdynamiken sind stets das Resultat eines Zusammenspiels vielfältiger Faktoren, bei dem soziale Einflüsse, individuelle psychologische Dispositionen sowie ökonomische und politische Rahmenbedingungen die rein technologische Wirkung überlagern.⁴⁰⁶ Ein Monitoring-System kann zwar Wahrscheinlichkeiten für Reaktionen berechnen, doch die tatsächliche Stärke dieses Einflusses im Vergleich zu anderen Lebensumständen bleibt oft unklar. Empirische Analysen zeigen beispielsweise, dass technologische Effekte auf das Wohlbefinden im Vergleich zu basalen sozialen Faktoren wie Schlaf oder Ernährung oft nur einen minimalen Anteil der Varianz erklären.⁴⁰⁷ Die vorliegende Arbeit kann daher zwar plausible Zusammenhänge und Muster identifizieren, ist jedoch nicht in der Lage, die exakte Wirkstärke dieser Interventionen quantitativ zu messen.

Schließlich bildet die konstitutive Opazität proprietärer Systeme eine Barriere für die vollständige methodische Verifizierung. Da die internen Logiken der „Gesellschaft des Schwarzen Kastens“ weitgehend unter Verschluss stehen, müssen wissenschaftliche Analysen häufig auf hypothetischen Modellen oder den Ausgabewerten der Systeme basieren.⁴⁰⁸ Dies begrenzt die Möglichkeit, die theoretisch hergeleiteten Verhaltensprognosen unmittelbar an der technischen Realität zu spiegeln. Zusammenfassend lässt sich festhalten, dass diese Arbeit einen hohen konzeptionellen Erklärungswert besitzt, indem sie die strukturellen Logiken und Mechanismen der algorithmischen Governance transparent macht, während ihre empirische und kausale Validität durch die dargelegten methodischen Rahmenbedingungen notwendigerweise limitiert bleibt. Diese Erkenntnis führt unmittelbar zu der Notwendigkeit, die Ergebnisse vor dem Hintergrund normativer Zielsetzungen und zukünftiger empirischer Forschungsbedarfe einzuordnen, was im abschließenden Abschnitt zu den normativen und empirischen Perspektiven thematisiert wird.

5.4 Normative und empirische Perspektiven

Die vorliegende Arbeit hat verdeutlicht, dass die Bewertung KI-gestützter Monitoring-Systeme in einem Spannungsfeld zwischen weitreichenden normativen Zielsetzungen und einer oft lückenhaften empirischen Evidenzbasis steht. Während die Kapitel 4.5 und 5.1 bis 5.3 die regulatorischen Ansätze und methodischen Grenzen aufgezeigt haben, erfordert der Abschluss der kritischen Betrachtung eine präzise Differenzierung zwischen dem, was technologisch und gesellschaftlich wünschenswert ist (normative Perspektive), und dem, was wissenschaftlich gesichert über die tatsächliche Wirkung dieser Systeme gesagt werden kann (empirische Perspektive).

⁴⁰⁵ Vgl. Cinelli u. a.(2021), S. 1.

⁴⁰⁶ Vgl. National Institute of Standards and Technology(2023), S. 2.

⁴⁰⁷ Vgl. Orben & Przybylski(2019), S. 1.

⁴⁰⁸ Vgl. Pasquale(2015), S. 1.

In der normativen Perspektive werden die Prinzipien definiert, die das Design und den Einsatz von Monitoring-Systemen leiten sollten, um das menschliche Wohlergehen und fundamentale Rechte zu schützen. Im Zentrum steht hierbei der Vorrang menschlichen Handelns und der menschlichen Aufsicht (Human Oversight), um sicherzustellen, dass algorithmische Entscheidungen die individuelle Autonomie nicht untergraben.⁴⁰⁹⁴¹⁰ Weitere zentrale Anforderungen umfassen Transparenz, Rechenschaftspflicht (Accountability), Fairness und den Schutz der Privatsphäre.⁴¹¹⁴¹² Diese rechtlichen und ethischen Rahmenwerke, wie die DSGVO oder der AI Act, markieren einen gesellschaftlichen Konsens über erstrebenswerte Standards der „Vertrauenswürdigen KI“. ⁴¹³⁴¹⁴ Es muss jedoch kritisch reflektiert werden, dass die Existenz solcher regulatorischen Vorgaben für sich genommen noch keinen Beweis für das tatsächliche Verhalten der Systeme in der Praxis darstellt. Normative Forderungen beschreiben einen Soll-Zustand, dessen faktische Umsetzung aufgrund der dargelegten technologischen Opazität und ökonomischen Interessenlagen der Plattformbetreiber oft im Verborgenen bleibt.⁴¹⁵⁴¹⁶

Die empirische Perspektive hingegen offenbart, dass viele zentrale Fragen zur tatsächlichen Wirkstärke und den Langzeitfolgen von Monitoring-Systemen weiterhin offen sind und dringenden Forschungsbedarf signalisieren. Ein kritisches Desiderat ist die Messung des realen Einflusses algorithmischer Interventionen auf das menschliche Verhalten. Während konzeptionelle Modelle vor manipulativer Verhaltenssteuerung warnen, zeigen empirische Studien oft nur geringfügige Effekte, die stark von der individuellen Suszeptibilität und dem sozialen Kontext abhängen.⁴¹⁷⁴¹⁸ Ebenso bleibt unklar, wie sich Personalisierung und Interaktionsoptimierung über lange Zeiträume auf die kognitiven Prozesse und die politische Meinungsbildung auswirken, da kausale Zusammenhänge zwischen Algorithmen und gesellschaftlicher Polarisierung methodisch schwer zu isolieren sind.⁴¹⁹⁴²⁰ O’Neil (2016) betont zudem das Problem der Feedback-Schleifen, bei denen automatisierte Bewertungen soziale Ungleichheiten unbemerkt verstärken können, ohne dass bisher ausreichende unabhängige Audits dieser proprietären Scoring-Systeme vorliegen.⁴²¹

Zukünftige Forschung muss daher die Lücke zwischen normativen Ansprüchen und empirischen Befunden schließen. Hierzu ist ein erweiterter Zugang zu internen Plattformdaten und proprietären Algorithmen erforderlich, wie ihn der Digital Services Act für

⁴⁰⁹Vgl. High-Level Expert Group on Artificial Intelligence(2019), S. 4.

⁴¹⁰Vgl. Europäisches Parlament und Rat(2024), S. 4.

⁴¹¹Vgl. Europäisches Parlament und Rat(2024), S. 3.

⁴¹²Vgl. National Institute of Standards and Technology(2023), S. 5.

⁴¹³Vgl. Europäisches Parlament und Rat(2016), S. 1.

⁴¹⁴Vgl. National Institute of Standards and Technology(2023), S. 1.

⁴¹⁵Vgl. Pasquale(2015), S. 1.

⁴¹⁶Vgl. Zuboff(2019), S. 4.

⁴¹⁷Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

⁴¹⁸Vgl. Orben & Przybylski(2019), S. 6.

⁴¹⁹Vgl. Kelm, Dohle & Bernhard(2023), S. 1.

⁴²⁰Vgl. Areeb u. a.(2023), S. 1.

⁴²¹Vgl. O’Neil(2016), S. 2.

zugelassene Forscher prinzipiell vorsieht.⁴²² Eine verantwortungsvolle Beantwortung der Forschungsfrage setzt voraus, dass konzeptionelle Analysen durch eine Kombination aus plattformübergreifenden Längsschnittstudien, kontrollierten Online-Experimenten, qualitativen Interviews und vergleichenden Fallstudien über verschiedene politische Systeme hinweg ergänzt werden.⁴²³ Nur durch eine solche methodische Triangulation kann die Effektivität bestehender Governance-Mechanismen überprüft und die Grenze zwischen legitimer Personalisierung und unzulässiger Manipulation präzise bestimmt werden.⁴²⁴

Zusammenfassend lässt sich festhalten, dass die wissenschaftliche Auseinandersetzung mit KI-gestütztem Monitoring eine kontinuierliche Reflexion der normativen Grundlagen und eine mutige Ausweitung der empirischen Prüfverfahren erfordert. Die in dieser Arbeit identifizierten Mechanismen bilden das theoretische Fundament, auf dem zukünftige Untersuchungen die tatsächlichen Machtverhältnisse in digitalen Informationsumgebungen weiter entschlüsseln müssen. Diese abschließende Würdigung der Perspektiven leitet direkt über zum Fazit der Arbeit, in dem die zentralen Ergebnisse zusammengeführt und die Forschungsfrage final beantwortet wird.

⁴²²Vgl. Europäisches Parlament und Rat(2022), S. 30.

⁴²³Vgl. National Institute of Standards and Technology(2023), S. 28.

⁴²⁴Vgl. Susser, Roessler & Nissenbaum(2019), S. 28.

6 Fazit und Ausblick

Die vorliegende Arbeit verfolgte das Ziel, KI-gestützte Monitoring-Systeme in ihrer Funktion als digitale Informationssysteme systematisch zu untersuchen und zu analysieren, inwiefern diese Technologien eine datenbasierte Analyse und gezielte Beeinflussung menschlichen Verhaltens ermöglichen. Im Zentrum der Untersuchung stand die Forschungsfrage, welche Mechanismen der algorithmischen Steuerung zugrunde liegen und welche sozio-ökonomischen sowie gesellschaftlichen Konsequenzen sich aus deren Anwendung ergeben. Die Beantwortung dieser Frage erforderte eine interdisziplinäre Betrachtung technologischer Architekturen, ökonomischer Verwertungslogiken und staatlicher Governance-Strukturen.

Die wesentlichen Ergebnisse der Arbeit verdeutlichen, dass modernes Monitoring weit über die bloße Beobachtung hinausgeht und als geschlossener kybernetischer Regelkreis operiert. Dieser zentrale Monitoring-Zyklus umfasst die Phasen Datenerfassung → Profilbildung → Analyse → Prognose und Bewertung → algorithmische Intervention → erneute Datenerfassung. Durch die kontinuierliche Übersetzung menschlicher Erfahrung in quantifizierbare Verhaltensdaten werden Individuen in maschinenlesbaren Nutzungsprofilen formalisiert. Auf dieser Basis transformieren Teilsysteme wie Empfehlungsalgorithmen, Ranking-Verfahren, Scoring-Modelle und Personalisierungsmechanismen den sogenannten Verhaltensüberschuss in präzise Vorhersagen und automatisierte Entscheidungen. Die algorithmische Intervention greift aktiv in die Informationsumgebung ein, um das künftige Verhalten der Nutzer im Sinne spezifischer Zielvorgaben zu optimieren.

Dabei wurde zwischen zwei grundlegenden Systemlogiken differenziert, die zwar auf ähnlichen technologischen Verfahren beruhen, jedoch divergierende Ziele verfolgen. Kommerzielle Plattformen wie Meta, TikTok oder Google operieren nach der Logik des Überwachungskapitalismus, wobei das Monitoring primär der Interaktionsoptimierung, dem Wachstum und der Monetarisierung von Aufmerksamkeit dient.⁴²⁵ Im Gegensatz dazu nutzen staatlich integrierte Systeme, wie das chinesische Social Credit System, Monitoring-Infrastrukturen zur Sicherung von Compliance, Governance und umfassender sozialer Kontrolle.⁴²⁶ Während die westliche Logik Nutzer durch subtile ökonomische Anstöße lenkt, setzt das chinesische Modell auf eine offene algorithmische Disziplinierung zur Einübung staatsbürgerlicher Tugenden.

In der abschließenden Bewertung ist festzustellen, dass KI-gestützte Monitoring-Systeme eine signifikante Bedrohung für die demokratische Willensbildung, das freie Denken und die individuelle Autonomie darstellen können, wenn sie ohne hinreichende Transparenz und wirksame Kontrollinstanzen operieren. Das Risiko einer schleichenden Entmach-

⁴²⁵ Vgl. Zuboff(2019), S. 4.

⁴²⁶ Vgl. Creemers(2018), S. 1.

tung des Individuums resultiert aus dem synergetischen Zusammenspiel von lückenloser Überwachung, psychologischem Profiling, personalisierten Informationsräumen und der algorithmischen Verstärkung emotionaler oder polarisierender Inhalte. Die Fälle Cambridge Analytica, die US-Wahlkämpfe sowie die Brexit-Kampagne haben exemplarisch verdeutlicht, wie datengetriebene politische Kommunikation gezielt psychologische Schwachstellen ausbeuten kann, um öffentliche Diskurse zu manipulieren.⁴²⁷ Das chinesische Sozialkreditsystem markiert hierbei die bisher weitestgehende Ausprägung einer algorithmischen Governance, die das Leben des Bürgers bis in private Bereiche hinein bewertet und sanktioniert.⁴²⁸

Dennoch muss betont werden, dass Algorithmen den freien Willen nicht automatisch eliminieren oder als monokausale Ursache für Radikalisierung betrachtet werden dürfen. Die tatsächliche Wirkung dieser Systeme ist stets von einem komplexen Gefüge aus sozialen, psychologischen und politischen Faktoren sowie dem individuellen Selektionsverhalten der Nutzer abhängig. Die Aussagekraft dieser Arbeit unterliegt zudem spezifischen Limitationen, die sich aus dem literaturbasierten Ansatz und dem fehlenden Zugriff auf proprietäre Systemdaten ergeben. Die synthetisierten Befunde basieren auf einer heterogenen Evidenzlage und lassen aufgrund geografischer und plattformspezifischer Unterschiede keine uneingeschränkte Generalisierung zu.

Der Ausblick auf künftige Entwicklungen macht deutlich, dass die technologische Gestaltung digitaler Räume eine permanente gesellschaftliche und regulatorische Begleitung erfordert. Zukünftige Forschung sollte verstärkt auf unabhängige Audits von Empfehlungs- und Scoring-Systemen setzen und den durch den Digital Services Act geschaffenen Datenzugang für die Wissenschaft nutzen.⁴²⁹ Um die Langzeitfolgen von Interaktionsoptimierung und Personalisierung besser zu verstehen, sind plattformübergreifende Längsschnittstudien und kontrollierte Experimente unerlässlich. Schließlich wird die Wirksamkeit aktueller Regulierungsrahmen wie der DSGVO, des Digital Services Act und des AI Act einer kontinuierlichen Evaluierung unterzogen werden müssen, um sicherzustellen, dass technologische Innovationen nicht zu Lasten fundamentaler Menschenrechte und der menschlichen Autonomie gehen.

⁴²⁷ Vgl. Susser, Roessler & Nissenbaum(2019), S. 1.

⁴²⁸ Vgl. Qiang(2019), S. 1.

⁴²⁹ Vgl. Europäisches Parlament und Rat(2022), S. 34.

Literaturverzeichnis

- Acquisti, Alessandro, Brandimarte, Laura & Loewenstein, George (2015). „Privacy and Human Behavior in the Age of Information“. In: *Science* 347.6221, S. 509–514. DOI: 10.1126/science.aaa1465.
- Adomavicius, Gediminas & Tuzhilin, Alexander (2005). „Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions“. In: *IEEE Transactions on Knowledge and Data Engineering* 17.6, S. 734–749. DOI: 10.1109/TKDE.2005.99.
- Areeb, Qazi Mudassar u. a. (2023). „Filter Bubbles in Recommender Systems: Fact or Fallacy – A Systematic Review“. In: *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* 13.6, e1512. DOI: 10.1002/widm.1512.
- Bradshaw, Samantha & Howard, Philip N. (2018). *Challenging Truth and Trust: A Global Inventory of Organized Social Media Manipulation*. Computational Propaganda Project Working Paper 2018.1. Oxford: Oxford Internet Institute.
- Brocke, Jan vom u. a. (2009). „Reconstructing the Giant: On the Importance of Rigour in Documenting the Literature Search Process“. In: *Proceedings of the 17th European Conference on Information Systems (ECIS)*, S. 2206–2217.
- Burke, Robin (2002). „Hybrid Recommender Systems: Survey and Experiments“. In: *User Modeling and User-Adapted Interaction* 12.4, S. 331–370. DOI: 10.1023/A:1021240730564.
- Chandola, Varun, Banerjee, Arindam & Kumar, Vipin (2009). „Anomaly Detection: A Survey“. In: *ACM Computing Surveys* 41.3, S. 1–58. DOI: 10.1145/1541880.1541882.
- Cinelli, Matteo u. a. (2021). „The Echo Chamber Effect on Social Media“. In: *Proceedings of the National Academy of Sciences* 118.9, e2023301118. DOI: 10.1073/pnas.2023301118.
- Creemers, Rogier (2018). „China’s Social Credit System: An Evolving Practice of Control“. In: *SSRN Electronic Journal*. DOI: 10.2139/ssrn.3175792.
- Davenport, Thomas H. (2006). „Competing on Analytics“. In: *Harvard Business Review* 84.1, S. 98–107.
- Dijck, José van (2014). „Datafication, Dataism and Dataveillance: Big Data Between Scientific Paradigm and Ideology“. In: *Surveillance & Society* 12.2, S. 197–208. DOI: 10.24908/ss.v12i2.4776.
- Europäisches Parlament und Rat (2016). *Verordnung (EU) 2016/679 – Datenschutz-Grundverordnung (DSGVO)*. URL: https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=LEGISSUM:310401_2 (besucht am 14.06.2026).

- Europäisches Parlament und Rat (2022). *Verordnung (EU) 2022/2065 – Gesetz über digitale Dienste (Digital Services Act)*. URL: <https://eur-lex.europa.eu/eli/reg/2022/2065/oj> (besucht am 14.06.2026).
- Europäisches Parlament und Rat (2024). *Verordnung (EU) 2024/1689 – Gesetz über Künstliche Intelligenz (AI Act)*. URL: <https://eur-lex.europa.eu/eli/reg/2024/1689/oj> (besucht am 14.06.2026).
- Evans, David S. & Schmalensee, Richard (2016). *Matchmakers: The New Economics of Multisided Platforms*. Boston: Harvard Business Review Press.
- Feldstein, Steven (2019). „The Global Expansion of AI Surveillance“. In: *Carnegie Endowment for International Peace*, S. 1–47.
- Fogg, B. J. (2009). „A Behavior Model for Persuasive Design“. In: *Proceedings of the 4th International Conference on Persuasive Technology*, S. 1–7. DOI: 10.1145/1541948.1541999.
- Gillespie, Tarleton (2014). „The Relevance of Algorithms“. In: *Media Technologies: Essays on Communication, Materiality, and Society*, S. 167–194.
- Goodfellow, Ian, Bengio, Yoshua & Courville, Aaron (2016). *Deep Learning*. Cambridge, MA: MIT Press.
- High-Level Expert Group on Artificial Intelligence (2019). *Ethics Guidelines for Trustworthy AI*. Brussels: European Commission. URL: <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>.
- Isaak, Jim & Hanna, Mina J. (2018). „User Data Privacy: Facebook, Cambridge Analytica, and Privacy Protection“. In: *Computer* 51.8, S. 56–59. DOI: 10.1109/MC.2018.3191268.
- Jordan, Michael I. & Mitchell, Tom M. (2015). „Machine Learning: Trends, Perspectives, and Prospects“. In: *Science* 349.6245, S. 255–260. DOI: 10.1126/science.aaa8415.
- Kaptein, Maurits u. a. (2015). „Personalizing Persuasive Technologies: Explicit and Implicit Personalization Using Persuasion Profiles“. In: *International Journal of Human-Computer Studies* 77, S. 38–51. DOI: 10.1016/j.ijhcs.2015.01.004.
- Kelm, Ole, Dohle, Marco & Bernhard, Uli (2023). „How Algorithmically Curated Online Environments Influence Political Polarization: Evidence From Two Experimental Studies“. In: *New Media & Society*. DOI: 10.1177/14614448231180584.
- Kitchin, Rob (2014). *The Data Revolution: Big Data, Open Data, Data Infrastructures and Their Consequences*. London: SAGE Publications.
- Kramer, Adam D. I., Guillory, Jamie E. & Hancock, Jeffrey T. (2014). „Experimental Evidence of Massive-Scale Emotional Contagion Through Social Networks“. In: *Proceedings of the National Academy of Sciences* 111.24, S. 8788–8790. DOI: 10.1073/pnas.1320040111.
- Laudon, Kenneth C., Laudon, Jane P. & Elragal, Ahmed (2016). *Management Information Systems: Managing the Digital Firm*. 14. Aufl. Harlow: Pearson.
- Lyon, David (2012). *Surveillance Studies: An Overview*. Cambridge: Polity Press.

- Metzler, Hannah & Garcia, David (2023). „Social Drivers and Algorithmic Mechanisms on Digital Media“. In: *Perspectives on Psychological Science* 18.3, S. 728–750. DOI: 10.1177/17456916221109892.
- Mitchell, Tom M. (1997). *Machine Learning*. New York: McGraw-Hill.
- Narayanan, Arvind (2023). *Understanding Social Media Recommendation Algorithms*. New York: Knight First Amendment Institute.
- National Institute of Standards and Technology (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. NIST AI 100-1. Gaithersburg, MD: U.S. Department of Commerce. DOI: 10.6028/NIST.AI.100-1.
- O’Neil, Cathy (2016). *Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy*. New York: Crown.
- OECD (2013). *Exploring the Economics of Personal Data: A Survey of Methodologies for Measuring Monetary Value*. OECD Digital Economy Papers 220. Paris: Organisation for Economic Co-operation und Development. DOI: 10.1787/5k486qtxldmq-en.
- Orben, Amy & Przybylski, Andrew K. (2019). „The Association Between Adolescent Well-Being and Digital Technology Use“. In: *Nature Human Behaviour* 3.2, S. 173–182. DOI: 10.1038/s41562-018-0506-1.
- Pariser, Eli (2011). *The Filter Bubble: What the Internet Is Hiding from You*. New York: Penguin Press.
- Parker, Geoffrey G., Van Alstyne, Marshall W. & Choudary, Sangeet Paul (2016). *Platform Revolution: How Networked Markets Are Transforming the Economy and How to Make Them Work for You*. New York: W. W. Norton.
- Pasquale, Frank (2015). *The Black Box Society: The Secret Algorithms That Control Money and Information*. Cambridge, MA: Harvard University Press.
- Qiang, Xiao (2019). „The Road to Digital Unfreedom: President Xi’s Surveillance State“. In: *Journal of Democracy* 30.1, S. 53–67. DOI: 10.1353/jod.2019.0004.
- Russell, Stuart & Norvig, Peter (2010). *Artificial Intelligence: A Modern Approach*. 3. Aufl. Upper Saddle River, NJ: Pearson.
- Srnicek, Nick (2017). *Platform Capitalism*. Cambridge: Polity Press.
- Susser, Daniel, Roessler, Beate & Nissenbaum, Helen (2019). „Online Manipulation: Hidden Influences in a Digital World“. In: *Georgetown Law Technology Review* 4.1, S. 1–45.
- Sutton, Richard S. & Barto, Andrew G. (2018). *Reinforcement Learning: An Introduction*. 2. Aufl. Cambridge, MA: MIT Press.
- Tiwana, Amrit (2014). *Platform Ecosystems: Aligning Architecture, Governance, and Strategy*. Waltham, MA: Morgan Kaufmann.
- U.S.-China Economic and Security Review Commission (2020). *China’s Social Credit System: Speculation vs. Reality*. Staff Research Report. Washington, DC: Senate Foreign Relations Committee.

- Woolley, Samuel C. & Howard, Philip N. (2017). „Computational Propaganda Worldwide: Executive Summary“. In: *Working Paper Series on Computational Propaganda*. Oxford: Oxford Internet Institute.
- Yeung, Karen (2017). „Hypernudge: Big Data as a Mode of Regulation by Design“. In: *Information, Communication & Society* 20.1, S. 118–136. DOI: 10.1080/1369118X.2016.1186713.
- Zuboff, Shoshana (2019). *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*. New York: PublicAffairs.

Ehrenwörtliche Erklärung

Hiermit versichere ich, dass die vorliegende Arbeit von mir selbstständig und ohne unerlaubte Hilfe angefertigt worden ist, insbesondere, dass ich alle Stellen, die wörtlich oder annähernd wörtlich aus Veröffentlichungen entnommen sind, durch Zitate als solche gekennzeichnet habe. Ich versichere auch, dass die von mir eingereichte schriftliche Version mit der digitalen Version übereinstimmt. Weiterhin erkläre ich, dass die Arbeit in gleicher oder ähnlicher Form noch keiner Prüfungsbehörde/Prüfungsstelle vorgelegen hat. Ich erkläre mich damit einverstanden, dass die Arbeit der Öffentlichkeit zugänglich gemacht wird. Ich erkläre mich damit einverstanden, dass die Digitalversion dieser Arbeit zwecks Plagiatsprüfung auf die Server externer Anbieter hochgeladen werden darf. Die Plagiatsprüfung stellt keine Zurverfügungstellung für die Öffentlichkeit dar.

(Ort, Datum)

(Eigenhändige Unterschrift)